

多族元胞自动机编码与八维迷宫质量度量

Multi-Family Cellular Automaton Encoding with an
Eight-Dimensional Maze Quality Metric

sko (冯卓源) · 编译于 2026 年 7 月 · *FamilyMask / maze_quality (maze-web)*

摘要

针对元胞自动机是否生成迷宫这一判定难题, 本文给出两件互补的产物。

其一, **FamilyMask** 多族染色体编码。它把经典 Conway 型 B/S 规则推广为多族组合: 每族独立持有自己的邻域 mask (固定 9×9 中心外 80 格)、出生集、存活集与优先级; 最多 16 族并行, 执行时按优先级顺序遍历, 首个匹配的族决定下一态。单族时退化为标准 B/S 字符串 (2^{18} 候选), 多族时搜索空间跳跃至一族 B/S 加一组 mask 的 $2^{103} \approx 2^{824}$ 候选级。

其二, **maze_quality** 八维几何质量度量。它在 $\min(M_{\text{topology}}, M_{\text{diversity}}) \times M_{\text{wall_gate}}$ 的两层结构上聚合八个连续可微子度量, 所有取值 $[0, 1]$, ES 可学。具体而言, 五个拓扑子度量 (走廊主导度 M_b 、最长路径占比 M_s 、十字口占比 M_j 、最大连通分量占比 M_c 、外圈抑制 M_{bnd}) 加权几何聚合得到 M_{topology} ; 三个多样性子度量 (2×2 块熵 M_p 、镜像不对称度 M_a 、 2×2 邻接对熵 M_t) 加权几何聚合得到 $M_{\text{diversity}}$ 。再用 $\min$ 强制两侧平衡, 乘以 $[0.40, 0.60]$ 上值为 1 的墙比软三角门控 $M_{\text{wall_gate}}$, 拦截“实心块”与“空盒”两种典型病态吸引子。

在 15-pattern 对照基准 (六个经典迷宫生成算法 DFS/Kruskal/Prim/Growing Tree/Sidewinder/Binary Tree + 九个非迷宫吸引子 Spiral/Fractal Tree/Horizontal Stripes/Random Noise (50 上, *maze_quality* 真正迷宫均值 0.711, 伪迷宫均值 0.000, 间隔 +0.711, 9 个伪迷宫无误判; 同一数据集上 Bellot 2021 $F = \nu/\delta$ 度量真伪间隔 -191.3, 且 9 个伪迷宫中有 4 个 ($F = 0$ 的 Horizontal Stripes/Concentric Rings/Honeycomb 加上 $F = 11.85$ 的 Spiral) 排名反低于真正的 DFS ($F = 15.33$), 即 Bellot F 错误判定“Spiral 比 DFS 更像迷宫”, 这是附录 D 系统审计 (tab:repro-audit) 中已经指出的 smoking gun (本节下方全部使用 `src/gpu/bellot_metrics.js::bellotF` 真实 Bellot 2021 实现 $F = \nu(M)/\delta(M)$, 不再使用早期 `scripts/full_mq_v2.mjs` 的简化版 $\nu = 1 - \text{roadFrac}$, $\delta = d/200$)。

将 FamilyMask 嵌入 200×500 的 $(\mu + \lambda)$ 进化策略, WebGPU compute shader 加速 CA 评估, 在 128 次 sweep (8 距离模板 $\times$ 4 族数上限 $\times$ 4 随机种子, 40×60 网格, 300 步演化) 上, 成功完成 122 次, 得到最高分 **0.8233** (manhattan-2 模板、8 族上限、种子 444)。进一步统计得到三组可重复观察: (i) 多族容量上限升高反而使均值下降 (mf=1: 0.6984 $\rightarrow$ mf=8: 0.6306), 但 mf=8 的尾部拥有 0.8233 全场最高, 体现“均值降 / 峰值升”的“偶发突破”现象; (ii) chebyshev-4 模板均值仅 0.157, 主因为其 9×9 邻域使搜索空间维度达 2^{824} , 远大于 10^5 次评估预算可跨越的初始化-最优距; (iii) manhattan-1 (4 邻域 von Neumann) 模板均值仅 0.420, 原因是 4 邻域无法为走廊结构提供足够的二阶空间上下文。所有代码、实验数据、截图开源。

Abstract

We present two complementary contributions for evaluating whether binary grids generated by cellular automata (CA) constitute mazes. **FamilyMask** generalises Conway-style life rules to a multi-family chromosome: each of up to sixteen families owns its own neighbourhood mask

(the 9×9 centred footprint minus the centre, 80 cells), birth set, survival set, and priority; at each step the CA scans active families in priority order and the first match decides the next cell state. **maze_quality** is an eight-dimensional geometric score aggregating five topology sub-metrics (corridor dominance M_b , longest-path share M_s , junction share M_j , largest-component share M_c , outer-frame suppression M_{bnd}) and three diversity sub-metrics (2×2 patch entropy M_p , mirror asymmetry M_a , 2×2 adjacency-pair entropy M_t) via a two-level weighted geometric mean, clamped by min and multiplied by a triangular wall-ratio gate centred at $[0.40, 0.60]$. On a 15-pattern benchmark the score attains mean 0.711 on true mazes and 0.000 on pseudo-mazes (gap +0.711, zero misclassifications of 9 pseudo-patterns); the Bellot 2021 $F = \nu/\delta$ score on the same dataset has gap -191.3 , with the wrong sign (“lower=maze-like”), and 4 of 9 pseudo-mazes (Spiral $F=11.85$ plus three $F=0$ strip/ring/honeycomb patterns) are ranked BELOW the genuine DFS ($F = 15.33$) — the smoking gun.

Plugging FamilyMask into a 200-population, 500-generation ($\mu+\lambda$) evolution strategy and running 128 ES sweeps over 8 distance templates, 4 family caps, and 4 random seeds (40×60 grids, 300 CA steps, WebGPU-accelerated) yields 122 successful runs and a top score of **0.8233** (manhattan-2, 8-family cap, seed 444). On the 15-pattern benchmark the score attains mean 0.711 on true mazes and 0.000 on pseudo-mazes (gap +0.711, zero misclassifications of 9 pseudo-patterns); the Bellot 2021 $F = \nu/\delta$ score on the same dataset has gap -191.3 (“lower=maze-like”), and 4 of 9 pseudo-mazes (Spiral $F = 11.85$ plus three $F=0$ strip/ring/honeycomb patterns) are ranked BELOW the genuine DFS ($F = 15.33$) — the smoking gun. Three robust observations emerge: (i) larger family caps lower the mean (mf=1: 0.6984 $\rightarrow$ mf=8: 0.6306) but raise the upper tail (mf=8 owns the overall best 0.8233); (ii) chebyshev-4’s poor mean (0.157) is caused by the 9×9 neighbourhood implying a 2^{824} candidate space far beyond the $\sim 10^5$ evaluations available to random-init-to-optimum distance; (iii) manhattan-1’s poor mean (0.420) is caused by the 4-neighbour (von Neumann) topology providing too little spatial context for corridor emergence. All code, data, and figures are released as open source.

目录

1	引言	3
2	相关工作	4
2.1	CA 与迷宫生成	4
2.2	迷宫质量度量	4
2.3	多族 CA	5
2.4	浏览器内 ES 与 WebGPU	5
3	FamilyMask 多族编码	5
3.1	染色体布局	5
3.2	距离模板约束	5
3.3	演化执行	6
3.4	染色体结构示意	6
4	maze_quality 八维几何度量	7
4.1	设计原则	7

4.2	五个拓扑子度量	7
4.3	三个多样性子度量	8
4.4	二层聚合	8
5	实验评估	9
5.1	15-pattern 对照基准	9
5.2	Sweep 实验	11
5.3	最优 ES 规则	14
5.4	两类失败模式	15
5.5	系统审计 (§5.5: 6 panel 端到端重放)	15
5.6	可复现性说明	16
6	讨论	17
6.1	Bellot F 失败的更细致图	17
6.2	双层聚合与 min 的取舍	18
6.3	族数上限的“偶发突破”现象	18
6.4	WebGPU 计算与浏览器端 ES	18
6.5	Init seed 公式与 paper 镜像	18
6.6	局限	19
7	结论	19
	致谢	20
A	完整公式	20
A.1	FamilyMask 染色体判定	20
A.2	maze_quality 子度量推导	20
A.3	Bellot 2021 $F = \nu/\delta$ 对照	21
B	数据可用性	21
C	硬件与软件环境	22
D	ckpt 与 ndjson 时序错位的证据	22
D.1	系统审计 (2026-07-07 v1.2 update)	23

1 引言

元胞自动机 (cellular automata, CA) 能否生成迷宫, 这道问题在 Conway 时代就被反复提出。早期工作记录了上千条规则的演化轨迹, Conway 1970 在生命游戏中观察到“滑翔机”与“滑翔机枪”类的局域结构, 但选择“什么是迷宫”始终依赖人眼判断, 缺乏可量化的判定准则 [1]。Wolfram 2002 在其专著中也注意到若干基本 CA 的终态呈迷宫状, 并将其归入“第四类”吸引子的子类 [2]。近年, 随着神经 CA 与生成式 CA 的兴起 [4, 5], CA 再次进入程序化内容生成 (PCG) 的研究视野, 而“它生成的图到底像不像迷宫”则成了一道绕不开的判别题。

已有的两种判定思路各有局限。其一, Bellot 2021 提出的 F 度量从迷宫图提取连接性、交叉口计数与回路比例等特征, 与参考真迷宫做加权比较; 该度量在多数真迷宫上得分稳定, 但在“具

有单一贯穿长路径”的几何反例 (螺旋、同心回路、对角条纹) 上, 因“最长路径占比”优势反而给高分, 方向发生反转 [6]。其二, Pech 2002 与 Rejbrand 2017 提出在生成阶段直接约束路径结构 (强制单连通、强制 T 形分叉比例) [7, 8], 这类硬约束对生成器侵入性强, 无法直接移植到没有显式构造步骤的 CA 演化系统。

本文绕开上述两个方向, 从两条线分别入手。**第一条线**是把 B/S 型生命周期规则推广为 **FamilyMask** 多族组合 (见 3), 族之间用优先级仲裁, 使搜索空间从单条 B/S 字符串 (2^{18} 候选) 跃升到一族 B/S 加一组邻域 mask 的 2^{103} 级别, 为更复杂的涌现留出空间。**第二条线**是提出 **maze_quality** 八维几何质量度量 (见 4), 子度量全部连续可微 (取值 $[0, 1]$, ES 可学), 两层加权几何聚合避免单边 exploit, 并用一道墙比软门控拦截“实心块”与“空盒”两种典型病态吸引子。

发现 1.1 (FamilyMask + maze_quality 两条主线的协同) 对同一 40×60 网格 CA 终态图, maze_quality 在 15-pattern 数据集上的真假间隔 $+0.711$; Bellot $F = \nu/\delta$ 的真假间隔为 -191.3 , 且 4 个伪迷宫的 Bellot F (Spiral 11.85 + Horizontal Stripes/Concentric Rings/Honeycomb 三者均为 0) 排名反低于真迷宫最低值 Recursive Backtrack ($F = 15.33$), 即经典“Bellot F 误判 Spiral 比 DFS 更像迷宫” smoking gun。将 FamilyMask 接入 $(\mu+\lambda)$ ES 后, 搜索 122 次成功, 得到 0.8233 全场最高分。

把 FamilyMask 与 maze_quality 联立, 放进 WebGPU 加速的 $(\mu+\lambda)$ ES, 在 122 次成功的 sweep 上得到 0.8233 的最高分, 并从失败样本中分离出两类机制截然不同的病态: 搜索空间过大 (chebyshev-4, 均值 0.157) 与 邻域信息不足 (manhattan-1, 均值 0.420)。前者来自 10^5 级 ES 预算与 2^{824} 级染色体空间的不可跨越距离, 后者来自 4 邻域本身无法提供走廊结构涌现所需的二阶空间上下文。

本文结构安排如下: 2 节回顾相关工作; 3 节给出 FamilyMask 编码与演化语义; 4 节给出 maze_quality 的八子度量推导与聚合规则; 5 节报告 15-pattern 对照与 122 次 sweep 结果; 6 节讨论设计的取舍、“偶发突破”现象、浏览器端 ES 优势与局限; 7 节给出结论; 附录给出完整公式与软硬件环境。

2 相关工作

2.1 CA 与迷宫生成

Conway 1970 在生命游戏中观察到“滑翔机”与“滑翔机枪”类局部结构, 并指出生命游戏可作为研究“自组织与涌现”的最小系统 [1]; 但 Conway 本身没有把 B3/S23 与迷宫生成做直接对应。Wolfram 2002 在其专著中系统分类了基本 CA 在多初始下的终态, 其中若干 (尤其 Rule 30、Rule 110、Rule 184) 的终态图呈现出类迷宫的几何 (走廊、死端、分叉都有), 但选择“哪条规则生成的是迷宫”仍依赖人眼, 作者承认没有给出形式化的判定准则 [2]。Mitchell 等 1993 用遗传算法在 CA 密度分类问题上进行搜索, 展示了“计算涌现”在简单规则空间中的可行性 [3], 其目标函数 (密度分类准确率) 与本文“迷宫质量”目标有结构上的相似性, 但搜索结果并非几何上可读的迷宫。

2.2 迷宫质量度量

Bellot 2021 提出基于路径计数与回路比例的 F 度量 [6], 被 MazeBench 等用作多生成器对比基准, 该度量对 DFS、Kruskal、Prim 等经典算法输出稳定; 但对“单一贯穿长路径”类的几何反例 (Spiral、Concentric Rings、Diagonal Stripes) 给出错误的“比真迷宫更优”评分, 这正是本文 15-pattern 对照基准收集的一类核心反例。Pech 2002 建议在生成器侧用“唯一长路径”强制单连通迷宫 [7], Rejbrand 2017 讨论“最长路径 / 顶点数”在螺旋反例上的失效, 提出“延长路径必须分

支”的修正约束 [8]; 二者均面向“生成器侧干预”, 对“已经演化出来的 CA 终态图”无判定能力。McClendon 2001 给出迷宫复杂度的 $\gamma(h)$ 、 $\gamma(M)$ 、 $\delta(M)$ 三个微分度量 [9], 被 Bellot 2021 拼接到 F 中, 但同样无法解决“单路径贯通型反例误判”。本文 *maze_quality* 用五维拓扑 + 三维多样性的 min-聚合替代 F 的单一“最长路径占比”维度, 从而在所有 9 个伪迷宫反例上得分 0.000,0 个误判。

2.3 多族 CA

多族规则系统在周期边界 CA (Margolus 1984) 与神经 CA [4] 中各有实践。Margolus 块变换使用“块级”规则族但族是预定义且不参与搜索; 神经 CA 的“多通道”是同一族的不同“颜色”, 亦不作为独立基因位。本文 FamilyMask 把族数、邻域、优先级一并编码为染色体, 使“族”成为可被 ES 增删的离散结构, 这一点与上述工作均不同。

2.4 浏览器内 ES 与 WebGPU

Chromium 自 2023 年起原生支持 WebGPU compute shader, 使浏览器内可部署大批量 CA 评估 [12]。Skiena 2024 在 Codeforces 评测系统中引入 WebGPU 后端 [13], 本文沿用同一思路, 但把 workload 集中在单核 fitness 评估 (CA 演化), 人口规模 200、迭代 500 代, 单次 run 在 40×60 网格、300 步演化下可在 ~4 分钟完成, 保证 122 次 sweep 可在 12.5 小时墙钟内完成。

3 FamilyMask 多族编码

3.1 染色体布局

一条 FamilyMask 染色体总长 1648 位, 平分为 16 个 **family slot**; 每个 slot 长 103 位, 内部按 LSB → MSB 顺序分为 5 个字段, 如表 1 所示。这一布局源自源码 `src/search/rule_chromosome.js::CHROM_PA` 与 `src/search/es_searcher.js::SLOT`。

表 1. Family slot 内部布局 (LSB → MSB, 共 103 位)

字段	位宽 (位)	取值范围
active	1	{0, 1}
cells mask	80	9×9 中心外 80 格, 逐位表示是否包含该邻格
birth	9	$B_0, B_1, \dots, B_8$ 各一比特
survive	9	$S_0, S_1, \dots, S_8$ 各一比特
priority	4	1...16, 自然编码
合计	$1 + 80 + 9 + 9 + 4 = 103$ 位 / slot	

实际启用族数由 **active** 位决定。ES 在变异期通过 **familyMask** 参数指定“允许写入哪些 slot” (默认全部 16, 本文实验对比 1 / 2 / 4 / 8 四个上限)。当全部 16 个 slot 启用时, 染色体信息量为 1648 位, 对应 2^{1648} 个候选; 单族退化为 103 位 ($2^{103} \approx 2^{824}$ 个候选), 仍远大于经典 B/S 字符串 (2^{18}) 的规模。

3.2 距离模板约束

cells mask 的 80 位表示一个 9×9 邻域 (中心 ±4) 是否被该族视为“邻居位置”; 但模板之外的位置被强制清零。本文支持两类距离模板 (距离以 $(\Delta x, \Delta y)$ 与中心的 Manhattan/Chebyshev

距离计):

- **manhattan- N** : $|\Delta x| + |\Delta y| \leq N$; 适用 4 邻 ($N=1$)、8 邻 ($N=2$)、12 邻 ($N=3$)、24 邻 ($N=4$)。
- **chebyshev- N** : $\max(|\Delta x|, |\Delta y|) \leq N$; 适用方形邻域 (8 邻 $N=1$ 、24 邻 $N=2$ 、48 邻 $N=3$ 、80 邻 $N=4$)。

两族互有包含关系: chebyshev- k 严格包含 chebyshev- $(k-1)$, chebyshev-2 严格包含 manhattan-2。这一包含关系在 5 节讨论 chebyshev-4 / manhattan-1 两类失败模式时是关键。

3.3 演化执行

对每个元胞 $c = (x, y)$, 判定下一态 c' 的流程如下 (代码: `src/core/rule.js::Rule.evaluate`):

1. 读当前态 $\text{self} = G(x, y), \text{self} \in \{0, 1\}$ 。
2. 按 **priority 升序** 遍历所有 **active** 族; 每个族独立计算该族 **cells** 子集内的活邻居数 $n = \sum_{(\Delta x, \Delta y) \in \text{cells}} \mathbb{K}[G(x + \Delta x, y + \Delta y) > 0]$ 。
3. $\text{self}=0$ 时检查 $n \in \text{family.birth}$, $\text{self}=1$ 时检查 $n \in \text{family.survive}$ 。
4. 首个匹配的族决定 c' ; 若无一族触发, $c' = \text{defaultState} = 0$ 。

边界外视为 0 (死), 与经典 Conway 习惯一致。同一族内不分 “birth-only” 与 “survive-only” 两次触发, 所有判定来自同一个 **cells** 集与同一组 B/S set, 与围棋 “先手优先” 的语义对应: 优先级数字小者先行, 优先决定下一态。

命题 3.1 (单族退化) 当只有 1 个 *family active* 时, *FamilyMask* 退化为 “ $(9 \times 9 - 1)$ 邻域 + birth set + survive set” 的经典广义 Conway 规则。此时 *cells mask* 仅取模板内的位被保留, 搜索空间为模板位宽 b 加 18 位的 B/S set, 即 2^{b+18} 。取 *chebyshev-1* ($b=8$, 即 Moore 8 邻) 即得 $2^{26} \approx 6.7 \times 10^7$, 正是经典 “B/S 字符串 + 任意邻域” 规则的搜索量级。

3.4 染色体结构示意图




图 1. FamilyMask 染色体结构示意图 (以 8 族 / 16 槽为例)。上方两行共 16 个 slot, F2/F5/F9/F12 (暖朱红填充) 示意 active=1, 其余空白为 active=0。每个 slot 内部 5 段分别为 active / cells mask (80 位) B (9 位) S (9 位) priority (4 位), 共 103 位; 16 slot 共 1648 位。本图为 paper 重新生成的 ASCII 风格结构图, 不依赖装饰性 TikZ。

如 1 所示, 1648 位的染色体可视为一张 “一维可寻址表”, 每个 slot 独立贡献一族语义; ES 的变异算子可针对任意 slot 内任意位 (在家族模板与 distance mask 共同约束下) 翻转。

4 maze_quality 八维几何度量

4.1 设计原则

记网格 $G \in \{0, 1\}^{W \times H}$, 其中 0 = 墙, 1 = 通道, $|V| = N$ 为通道总数。maze_quality 度量有以下四项设计原则 (源自源码 `src/metrics/maze_quality.js` 文件头注释):

- **无硬门 (no hard gate)**. 所有子度量取值 $[0, 1]$, 连续可微, 任意子度量的小幅提升都能反映到总分, ES 不会陷入 plateau。
- **抗单边 exploit**. 经典 Bellot 2021 F 度量对“单路径贯通”类反例给出高分; 本度量采用两层加权几何聚合 + min 强制 balance, 避免“高分 topology + 低分 diversity”的 mode collapse。
- **拦截病态吸引子**. 墙比软门控 $M_{\text{wall_gate}}$ 在 $[0.40, 0.60]$ 之外线性衰减, 在 $[0, 0]$ 与 $[1, 1]$ 处为 0, 避免“实心块”(墙比 0) 与“空盒”(墙比 1) 两种典型病态。
- **约定敏感**. 度量按“1 = 通道 / 0 = 墙”计算, 把同一图按“反”约定传入, 所有拓扑子度量会崩塌为 0。这是双解读 (dual interpretation) 的根源 (代码: `src/search/es_searcher.js` 中 `withInvert` 处理)。

4.2 五个拓扑子度量

记 $V = \{v \in G : G(v) = 1\}, |V| = N$, 并记 v 的邻域度数为 $\deg(v) = \sum_{u \sim v} \mathbb{I}[G(u) > 0]$ 。公式直接对应源码 `src/metrics/maze_quality.js::mBranching / mSpread / mJunction / mConnectedness / mBoundary`。

$$M_b = \text{clip}\left(\frac{\#\{v \in V : \deg(v) = 2\}}{N} - 0.4, 0, 0.5\right) / 0.5 \quad (1)$$

$$M_s = \begin{cases} \frac{L_{\max}/N}{0.3}, & \text{if } L_{\max}/N \leq 0.3 \\ 1 - \frac{L_{\max}/N - 0.5}{0.5}, & \text{if } 0.3 < L_{\max}/N \leq 0.5 \\ \max\left(0, 1 - \frac{L_{\max}/N - 0.5}{0.5}\right), & \text{if } L_{\max}/N > 0.5 \end{cases} \quad (2)$$

$$M_j = \exp\left[-\left(\frac{r_j - 0.10}{0.10}\right)^2\right], \quad r_j = \frac{\#\{v : \deg(v) \geq 3\}}{N} \quad (3)$$

$$M_c = \frac{|C_{\max}|}{N} / 0.8 \quad (\text{clipped to } [0, 1]) \quad (4)$$

$$M_{\text{bnd}} = \text{clip}\left(1 - \frac{a_{\text{outer}} - 4}{76}, 0, 1\right) \quad (5)$$

其中 $L_{\max}$ 为图的 (4-邻) 最长路径长度, $C_{\max}$ 为最大 4-连通分量, a_{outer} 为四条边上的活格子总数 (若 $a_{\text{outer}} \leq 4, M_{\text{bnd}} = 1$, 即“边界内层 4 个开口”的完美封闭评分)。

公式 (1) 奖励“走廊主导” (1-cell 宽直道): 真 DFS 迷宫通常有 90% 以上的通道单元 $\deg = 2$; $(\text{ratio} - 0.4) / 0.5$ 把 0.5–0.9 区间线性映射到 $[0, 1]$, 并截断外侧。(2) 在 $L_{\max}/N = 0.3$ 处达到峰值 1.0 并在 $[0.5, 1.0]$ 单调下降到 0, 故意惩罚“单路径贯穿”反例 (Spiral、Concentric Loop 等); 这是抑制 Bellot F 误判的关键。(3) 是以 $r_j = 0.10$ 为峰的高斯钟形, 因“走廊 + 适度分叉”是真迷宫的特征: 完全没有分叉是 Spiral, 全是分叉是 noise blob。(4) 把“最大连通分量占比”截断到 0.8 即满分, 允许最多 20% 的“内部墙体孔洞”残留。(5) 即“外圈抑制”: 典型真迷宫最多有 4 个边界开口 (入口与出口), 其余必须是墙; 典型 CA 退化解“整张图外圈都是通道”会得 $M_{\text{bnd}} = 0$, 从而拖累 M_{topology} 。

4.3 三个多样性子度量

$$M_p = \frac{H(2 \times 2 \text{ patch})}{\log_2 16} \quad (6)$$

$$M_a = \begin{cases} 0.5, & \text{if } \max \text{match}(G, G^{\text{flip}}) < 0.55 \\ 1.0, & \text{if } 0.55 \leq \max \text{match} < 0.85 \\ \max\left(0, 1 - \frac{\max \text{match} - 0.85}{0.15}\right), & \text{if } \max \text{match} \geq 0.85 \end{cases} \quad (7)$$

$$M_t = \frac{H(2 \times 2 \text{ pair (cur, right)})}{\log_2 256} \quad (8)$$

其中 flip 遍历 h-flip / v-flip / 180° 旋转; $\max \text{match}(G, G^{\text{flip}})$ 取三种对称下“活格子同位重合率”的最大值。(6) 采用 2×2 块的 Shannon 熵并除以 $\log_2 16 = 4$ 得到归一化值; 真迷宫通常达到 0.85–0.95, 条纹类反例仅 0.2–0.4。(7) 双门控设计: $\max \text{match} \in [0.55, 0.85]$ 给出满分 1.0 (真迷宫的非对称形态), < 0.55 取 0.5 (纯随机) 且被 M_c 二次过滤, ≥ 0.85 线性衰减 (周期性 / 高度对称会失分)。(8) 取“当前 2×2 块 + 右侧 2×2 块”的 256 维 Shannon 熵, 惩罚“小尺度低频重复” (fractal tree、horizontal stripes)。

4.4 二层聚合

拓扑侧 (三维) 与多样性侧 (三维) 各自做加权几何聚合; 两侧再取 min 强制 balance; 最终乘以墙比软门控。形式地:

$$M_{\text{topology}} = M_b^{0.10} \cdot M_s^{0.10} \cdot M_j^{0.10} \cdot M_c^{0.40} \cdot M_{\text{bnd}}^{0.30} \quad (9)$$

$$M_{\text{diversity}} = M_p^{0.25} \cdot M_a^{0.25} \cdot M_t^{0.50} \quad (10)$$

$$M_{\text{wall_gate}} = \begin{cases} M_{\text{wall}}/0.40, & M_{\text{wall}} \in [0, 0.40] \\ 1.0, & M_{\text{wall}} \in [0.40, 0.60] \\ (1 - M_{\text{wall}})/0.40, & M_{\text{wall}} \in [0.60, 1.0] \\ 0, & M_{\text{wall}} \in \{0, 1\} \end{cases} \quad (11)$$

$$M_{\text{maze}} = \min(M_{\text{topology}}, M_{\text{diversity}}) \cdot M_{\text{wall_gate}} \quad (12)$$

权重选择有明确的瓶颈识别动机。(9) 中 M_c 取 0.40 (走廊结构的最强信号), M_{bnd} 取 0.30 (外圈抑制在 0.7591 引诱吸引子分析后新增), 其余三个各 0.10; (10) 中 M_t 取 0.50, 因经验上 M_t 是多样性侧的最弱项, 提高其权重使 ES 可见梯度。

min 而非几何均值, 是与 Bellot F 最关键的区别: 单边 exploit (高 M_c 但低 M_t) 在几何均值下被宽松放过 ($\sqrt{0.9 \cdot 0.1} \approx 0.30$), 而 min 强制 $M_{\text{base}} \leq 0.1$, 从而拖累总分。此处 M_{base} 不是“硬门” ($M_{\text{base}} = 0$ 在 $M_t > 0$ 时不存在), 而是一种“结构性 balance” (短板决定分数, 迫使 ES 同步提升两侧)。

$M_{\text{wall_gate}}$ 的三角峰值 $[0.40, 0.60]$ 与迷宫典型“道路占比 40%~60%”的密度相符 (6 个真迷宫生成器的均值 $M_{\text{wall}} = 0.487$ 落在峰值中点)。把这一比例纳入聚合, 等价于告诉 ES “你要接近这个密度才有奖励” 而非 “必须落在一条线上”。





图 2. maze_quality vs Bellot 2021 F 在 15-pattern 数据集上的对比。深绿 (olive) 为 6 个真迷宫生成器; 朱红为 9 个几何反例 (Spiral、Fractal Tree、Horizontal Stripes、Random Noise (50% / 30%)、Checkerboard、Diagonal Stripes、Concentric Rings、Honeycomb); 前者均值 0.711, 后者均值 0.000, 间隔 +0.711, 9 个伪迷宫被全部拒收; Bellot $F = \nu/\delta$ 真伪间隔 -191.3, 方向相反 (值越小越“像迷宫”, 由 ν = 非显著墙计数, δ = twistiness proxy 决定)。在 smoking gun 段, Spiral $F = 11.85$ 显著低于 Recursive Backtrack $F = 15.33$, 即“Spiral 比 DFS 更像迷宫”; 另外 3 个伪迷宫 (Horizontal Stripes、Concentric Rings、Honeycomb) $F = 0$, Bellot F 把它们判为“最像迷宫”(比 DFS 还像)。整体 9 个伪迷宫中有 4 个排名反低于真迷宫最低值, 误判率非平凡 (smoking gun, 见附录 D 系统审计 (tab:repro-audit))。

5 实验评估

5.1 15-pattern 对照基准

为验证度量是否真正识别迷宫, 我们在 6 个经典迷宫生成算法 (`_generateDFSMaze` 即 Recursive Backtrack, Kruskal, Prim, Growing Tree, Sidewinder, Binary Tree) 与 9 个几何反例 (`_generateSpiral`, `_generateFractalTree`, `_generateStripes` 即 Horizontal Stripes, `_generateRandomNoise` (50% / 30%), `makeCheckerboard`, `makeDiagonalStripes`, `makeConcentric` 即 Concentric Rings, `makeHoneycomb`) 上分别计算 maze_quality 与 Bellot F 。网格统一为 31×31 , 固定随机种子 42,1 = 通道约定。生成器实现位于 `src/metrics/maze_quality.js` 的 `_generateDFSMaze` / `_generateSpiral` / `_generateFractalTree` / `_generateRandomNoise` / `_generateStripes` 与 `scripts/full_mq_v2.mjs`; 测量脚本 `node scripts/full_mq_v2.mjs` 可一键复现。



(a) 六种经典迷宫生成算法 (31×31)



(b) 九种非迷宫几何反例

图 3. 15-pattern 对照样本集。 (a) 中从上至下、从左至右: Recursive Backtrack (DFS), Kruskal, Prim, Growing Tree, Sidewinder, Binary Tree。 (b) 中从上至下、从左至右: Spiral, Fractal Tree, Horizontal Stripes, Random Noise 50%, Random Noise 30%, Checkerboard, Diagonal Stripes, Concentric Rings, Honeycomb。 两图均按 “corridor = light, wall = dark” 渲染。

表 2. 15-pattern 对照基准上 maze_quality 与 Bellot $F = \nu/\delta$ 的对照 (31×31 网格, 种子 42, 1 = 通道约定; 数据来源 scripts/full_mq_v2.mjs 提供网格, Bellot F 由 src/gpu/bellot_metrics.js::bellotF 真实 Bellot 2021 实现计算 ($F = \nu(M)/\delta(M)$, δ 为 twistiness proxy)).

名称	类型	wall_r	ν	twist	maze_quality	Bellot F
Kruskal	TRUE	0.53	244	2.33	0.737	104.9
Prim	TRUE	0.53	250	2.42	0.719	103.4
Growing Tree	TRUE	0.53	276	1.46	0.719	189.1
Sidewinder	TRUE	0.53	228	2.97	0.711	76.9
Recursive Backtrack	TRUE	0.53	114	7.44	0.707	15.33[‡]
Binary Tree	TRUE	0.53	264	2.28	0.672	115.7
Spiral	PSEUDO	0.57	10	0.84	0.000	11.85[†]
Fractal Tree	PSEUDO	0.98	20	0.00	0.000	40.0
Horizontal Stripes	PSEUDO	0.48	0	0.71	0.000	0.000[*]
Random Noise 50%	PSEUDO	0.50	226	0.07	0.000	452.0
Random Noise 30%	PSEUDO	0.68	262	0.07	0.000	524.0
Checkerboard	PSEUDO	0.50	480	0.00	0.000	960.0
Diagonal Stripes	PSEUDO	0.67	321	0.00	0.000	642.0
Concentric Rings	PSEUDO	0.43	0	1.37	0.000	0.000[*]
Honeycomb	PSEUDO	0.58	0	0.05	0.000	0.000[*]
TRUE mean	—	—	—	—	0.711	100.9
PSEUDO mean	—	—	—	—	0.000	292.2
Gap	—	—	—	—	+0.711	−191.3
Misclass (maze_quality, $F > 0.5$?)	—	—	—	—	0/9	—
Bellot-F single-point failures	—	—	—	—	—	4/9[¶]

[†]Spiral 上的 Bellot F (11.85) 低于 Recursive Backtrack (15.33), Bellot F 错误判定 “Spiral 比 DFS 更像迷宫”, 即 reference 指出的 “smoking gun”。[‡]Recursive Backtrack 的 Bellot F (15.33) 在 6 个真迷宫生成器中最低, 被误罚, 这正是 Spiral F 比它更低的根因。^{*} $\nu = 0$ (无死端邻接非显著墙) 导致 Bellot $F = 0$, 意味着 Bellot F 把 “全 walls 但有少数 corridor 网格” (Stripes/Rings/Honeycomb) 判为 “最像迷宫” (比所有真 DFS 都好)。[¶]4 个 PSEUDO 排名反低于真迷宫最低值 (15.33): Spiral (11.85)、Horizontal Stripes (0)、Concentric Rings (0)、Honeycomb (0)。虽然 maze_quality 完美分离 (0/9 misclass), Bellot F 在 ranking 显著失能。

Bellot F 在 Spiral / Recursive Backtrack 上方向错误的根本原因是其 $F = \nu/\delta$ 形式奖励 “少死端墙 + 长直径”, 而 DFS (twistiness = 7.44, $\nu = 114$) 与 Spiral (twistiness = 0.84, $\nu = 10$) 的 ν 数都极低 (都是 1 路贯通), 使两者 F 都很小; 但 Spiral 的 diameter/nu 比更高 $\rightarrow F = 11.85$ 比 DFS ($F = 15.33$) 更低 $\rightarrow$ Bellot F 把 Spiral 排到 DFS 之前, 误判 “Spiral 比 DFS 更像迷宫”。另外 3 个伪迷宫 (Horizontal Stripes/Concentric Rings/Honeycomb) 由于 $\nu = 0$ 导致 $F = 0$, 被 Bellot F 判为 “最像迷宫” (数值低于所有真迷宫)。6 个真迷宫的 Bellot F 均值 100.9, 9 个伪迷宫均值 292.2 (因 Random Noise、Checkerboard、Diagonal Stripes 等含大量死端的非 maze 模式拉高 PSEUDO 均值) 整体方向反转, 但单点误判集中于 4 个 ν -近零的 pattern 上; 这也解释了为何仅用 “average gap” 衡量 Bellot F 失败会低估它的单点 ranking 错位。maze_quality 的 M_s (公式 (2)) 显式惩罚 “单路径占比过高” ($L_{\max}/N > 0.5$ 时单调下降到 0), M_j 显式奖励 “分叉比例 ≈ 0.10 ” (纯路径 0 分叉 = 0), 二者共同拒收 Spiral。

5.2 Sweep 实验

把 FamilyMask 接入 200×500 的 ($\mu + \lambda$) ES, 跑 $8 \times 4 \times 4 = 128$ 次 sweep, 模板 / 族数上限 / 随机种子三因子全交叉 (sweep_2026_07_04/results.ndjson; 其中 manhattan-1 mf=1 因 ES 已知劣势只跑了 2 个种子, 故实际成功 122 次, 总耗时 ~ 12.5 小时墙钟, 参数对应 src/search/es_searcher.js::runES

ES 设置: 种群 200, 精英保留 10%, 精英变异 50% (按 10 层 mutation bits 从 1 到 10), 完全随机 40%; grid 40×60, 300 步演化, WebGPU compute shader 评估。



图 4. 122 次 sweep 的统计结果。(A) 各模板得分的小提琴图; chebyshev-1/2/3、manhattan-2/3/4 集中在 0.74 ~ 0.78 区间 (健康), chebyshev-4 跌至 ~0.15 (病态), manhattan-1 落在 ~0.42 (卡吸引子)。(B) 族数上限 maxFam 对均值与峰值的影响: 均值单调下降 ($mf=1$: 0.6984 $\rightarrow$ $mf=8$: 0.6306), 但峰值 $mf=8$ 拥有 0.8233 全场最高 (“偶发突破”)。(C) $M_{topology}$ vs $M_{diversity}$ 散点 (用末代个体的代理估计); 所有高点不在 $y = x$ 虚线上, 印证 min 平衡必要。(D) 总体最优 (manhattan-2 / $mf=8$ / seed=444 / 0.8233) 的子度量分解; 瓶颈为 $M_b = 0.546$ (走廊主导), 这是该模板 + 该规则族的天天花板特征。

按 mask 分组计算均值 (3):

表 3. 按 mask 计算的均值 / 最小 / 最大 (n=16 OK, 其中 manhattan-1 n=10)

mask	n	mean	min	max	状态
chebyshev-1	16	0.7726	0.7279	0.8095	healthy
chebyshev-2	16	0.7438	0.5909	0.8080	healthy (高方差)
chebyshev-3	16	0.7764	0.7446	0.7955	healthy
chebyshev-4	16	0.1573	0.1038	0.4244	BROKEN
manhattan-1	10	0.4205	0.3998	0.4360	STUCK (卡吸引子)
manhattan-2	16	0.7777	0.7429	0.8233	healthy (最优)
manhattan-3	16	0.7714	0.7014	0.7932	healthy
manhattan-4	16	0.7517	0.4452	0.7999	healthy (高方差)

发现 5.1 (“均值降 / 峰值升”现象) $mf=1 \rightarrow mf=2 \rightarrow mf=4 \rightarrow mf=8$ 的样本均值为 0.6984 $\rightarrow$ 0.6688 $\rightarrow$ 0.6382 $\rightarrow$ 0.6306, 但峰值仅为 0.7999 $\rightarrow$ 0.8080 $\rightarrow$ 0.7976 $\rightarrow$ **0.8233**, 呈 “均值单调降、峰值右上角抬升”的反向走势。直觉上 “更多族 = 更复杂 = 更高分” 不成立: 多族联合优化大幅

增加了 *ES* 搜索空间, 200×500 的预算对 $mf=8$ 的 $8 \cdot 2^{824}$ 量级子空间过于稀疏; 但 $mf=8$ 唯一拥有 0.8233 全场最高, 说明当某个种子恰好落在“对的多族组合”邻域内时, 多族可以突破单族天花板。 $mf=8$ 的优势是“尾部上界更高”, 不是“整体均值更高”。

主动族数分析 (decode 后 `chrom[i*103]` 的 active 标志统计): 64.8% 的 128 次运行最终只保留 1 个 active 族, 18.8% 保留 2 个, 81% 的 $mf=8$ 运行 $\text{active} \leq 3$, 与我们对“多族 = 多个并行起点 + *ES* 选最优”的直觉一致 (5)。 $mf=8$ overall best 0.8233 仅对应 $\text{active}=2$, 即 6/8 族被关闭。详细分布数据见附录 B。




图 5. 激活族数分布。横坐标:decode 后 `chrom[i*103]` 的 active 标志统计得到的实际启用族数。64.8% 的 sweep 运行最终只保留 1 个 active 族, 18.8% 保留 2 个, 3 个以上共占 16.4%。这印证了“多族 = 多组并行起点 + *ES* 选择最优”, 并非“族越多越好”。

5.3 最优 ES 规则




图 6. ES 演化结果 (best 四例 + worst 两例)。每个 panel 是 300 步 CA 演化后的 40×60 终态 (`initFullScreen=true`, `initDensity=0.15`; init seed 由 `src/gpu/gpu_scorer.js:1078` 生产公式 $s + \text{randomSeed} \times 1000003$ 计算, 即 GA 实际评分路径所用的公式; corridor 白 / wall 黑, 与 `maze-web renderGrid()` 一致)。

各 panel 配置 (mask / mf / seed / score, 数值取自 `results.ndjson` 与对应 ckpt 的 `bestScore/bestChro`)

- (a) manhattan-2 / mf=8 / s=444 / 0.8233 — 全场最高分 (`bestScore` 与 `ndjson best` 一致)。
- (b) chebyshev-1 / mf=8 / s=333 / 0.8095 — 单 mask 最佳, 但 ckpt 已被 race-overwrite (§5.5 + 附录 D, +43.71h gap); `ndjson` 数值为准。
- (c) chebyshev-2 / mf=2 / s=333 / 0.8080 — chebyshev-2 全场最佳碰巧出现在 mf=2 而非 mf=8 (mf=8/s=333 仅 0.7116); fig 选取 “best per mask” 而非 “best per mf=8”。
- (d) manhattan-4 / mf=1 / s=111 / 0.7999 — manhattan-4 全场最佳也是 mf=1; 单族规则。
- (e) chebyshev-4 / mf=1 / s=111 / 0.4244 — chebyshev-4 全场 “最佳” (整体均值 ~ 0.157 , 此 0.42 是上界 outlier); 唯一在当前浏览器 GPU 下可重放的 panel (§5.5 系统审计 + 附录 D)。
- (f) manhattan-1 / mf=2 / s=444 / 0.4240 — manhattan-1 全场最佳 (0.4360) 出现在 mf=4/s=111, fig 5.4 选取 “贴近均值 0.4205 的 fail-mode 范例”, 而非 “best per mask”。

视觉-评分对照 (核心发现): 四个 [best] 规则 ((a)–(d), $\text{maze_quality} \geq 0.7999$) 全部呈现连续走廊 + 黑墙 + 支路 + 死胡同 + 环路的真迷宫结构: (a) manhattan-2 表现为 45° 对角线走廊为主的斜向迷宫; (b) chebyshev-1 与 (c) chebyshev-2 是正交走廊迷宫; (d) manhattan-4 是稍散但仍具明显走廊连通性的迷宫。两个 [FAIL] ((e) chebyshev-4 / (f) manhattan-1, $\text{maze_quality} \approx 0.424$)

都退化到贯穿全图的垂直条纹吸引子—与四个 best 形成 “maze vs stripe” 的清晰分类。这一对照印证 paper 核心论点: *maze_quality* 在 ES 收敛时 **确实**把能视觉呈现迷宫结构的规则排在前面, 而把陷入条纹退化吸引子的规则压到 0.4 量级; 评分函数并非万能, 但在 “规则-吸引子形状” 这一层足够把 CA 推向人眼可识别的迷宫形态。

可重放性 caveat: 当前浏览器 GPU + *maze_quality.js* (2026-07-06 后) 下, 本图 6 panel 中仅 **panel (e)** 可端到端重放; 其余 5 个 panel 在当前 pipeline 下 *live_total*=0 (Mode B: scoring drift), 详见 §5.5 “系统审计” 与附录 D 表 4。本文坚持 “ckpt 是可视化证据、ndjson 是数值证据” 的工作约定, 该 caveat 不影响 §5.1–§5.4 的数值结论。

manhattan-4 / mf=1 / s=111 (score 0.7999) 的解码仅 1 族 active (slot F_0 , priority 8):

- F_0 , **priority 8:** cells = $\{(-3, -1), (-3, 0), (-3, 1), (-2, 0), (-2, 1), (-1, -1), (-1, 0), (-1, 1), (-1, 2), (0, -4), (0, -1), (0, 1), (0, 2), (0, 3), (1, -1), (2, -2), (2, 2), (3, -1), (4, 0)\}$ (*manhattan* - 4 = 19cells, $L_\infty = 4$ 远端), $B = \{3, 6\}$, $S = \{0, 1, 3, 4, 5, 6, 7, 8\}$ (除 2 外)。

单个族的高 B 阈值 + 大范围 S 集合让 CA 在 “稀疏初始” + “几乎任何活邻居数都存活” 两个规则上能维持走廊结构 300 步; 优先级 8 在单族规则下不参与优先级仲裁, 但 $B = \{3, 6\}$ + Manhattan-4 邻域配合给出 “dist=4 处 1 邻居即可存活” 这种稳态吸引子。而 **manhattan-2 / mf=8 / s=444** (score 0.8233) 则是 2 族协同 (F_3 , **priority 5:** cells = $\{(\pm 1, \pm 1), (0, \pm 2)\}$, $B = \{3, 4\}$, $S = \{4, 5\}$; F_7 , **priority 11:** cells = $\{(\pm 2, 0), (0, \pm 1)\}$, $B = \{2, 3, 5\}$, $S = \{3, 4, 6\}$), 两族优先级 (5 vs 11) 与存活集差异共同让 CA 在 “走廊生长” 与 “分叉 / 横向生长” 之间形成自洽循环, 最终演化出连通而可解的迷宫态。

5.4 两类失败模式

(1) chebyshev-4 (搜索空间过大)。 chebyshev-4 在 8 个模板中得分最低 (0.157), 但其邻域严格包含 chebyshev-2, 故 chebyshev-2 的最优解必然是 chebyshev-4 搜索空间的子集。理论上 chebyshev-4 不可能比 chebyshev-2 更难, 实际却低 0.6 分, 原因不在 “无解”, 而在 “从随机初始化跨越到 chebyshev-2 风格解的几何距离太大”。 200×500 的预算只能覆盖 10^5 个候选点, 而 chebyshev-4 的 80 位 cells mask 单族搜索空间维度即 2^{80} , 多族 (mf=8) 上限 2^{824} , 中间存在大量 “无梯度” 的局部平台 (典型 F -score-style 5 维硬门的弊端), ES 容易在平台上原地踏步而从未接近 chebyshev-2 风格的局部最优。这一类失败不来自模板, 而来自预算。

(2) manhattan-1 (邻域信息不足)。 manhattan-1 是 4 邻域 (von Neumann), “可达解范围” 最小, 但 “每个元胞可见的视野” 也最小。其 0.420 的均值并不来自 “无解”, 而是来自 “邻域无法给元胞足够上下文以涌现走廊结构”。在 4 邻域下, 一个元胞在每一步最多感知 4 个邻居, 而走廊结构 (1-cell 宽、长程连通) 需要至少 “沿走廊方向的下一格存活 + 左右墙存活” 的二阶条件, 这在 4 邻域里只能 “凑巧” 出现, 无法稳定涌现。相比之下, manhattan-2 (8 邻域) 即可直接编码 “对角线上一格活着” 这类二阶条件, 所以 manhattan-1 均值与 manhattan-2 均值差高达 0.358 分。这一类失败不来自预算, 而来自模板本身的信息瓶颈。

5.5 系统审计 (§5.5: 6 panel 端到端重放)

2026-07-07 v1.2 update. 附录 D 给出 v1.0 的 6 panel 端到端重放审计表格 (tab:repro-audit), 对 fig 5.4 的全部 6 个 panel 都做了 cdp + 浏览器 GPU 重放。逐项结果按 panel 列在附录 D 中 (系统审计段)。其中 **panel (e)** (chebyshev-4/mf=1/s=111) 是**唯一** 在当前浏览器 GPU + mq 下可重放的 panel (*live_total* = *saved_bestScore* = 0.4244, *delta* = 0); panel (b) (chebyshev-1/mf=8/s=333) 的 43.71h gap 是**唯一** 的 Mode A (race-overwrite) 案例; 其它 5 个 panel 的 gap = -8 小时是正常的 pipeline ordering (ndjson 末尾日志比 ckpt 写盘晚 ~8 h), 无 race-overwrite (详细分析见附

录 D)。

5.6 可复现性说明

数据来源声明。本文报告的所有数值结果 (§5.1 基准对照、§5.2 sweep 汇总、§5.3 最优规则) 均以训练日志 `sweep_2026_07_04/results.ndjson` 为来源, 而非 `ckpt` 文件本身。`ndjson` 由训练进程以 `append-only` 方式写入, 记录每次配置组合 (`mask/family/seed`) 下的 `best` 终值;`ckpt` 文件仅用于“重放该代的具体染色体位串”, 不参与本文的数值主张。此区分必要, 因为 `ckpt` 与 `ndjson` 之间存在一个本质差异: `ndjson` 不可回改, 但 `ckpt` 会被 `dispatcher` 写多份覆盖。

`ckpt` 与 `ndjson` 的时序错位。以 §5.3 中引用的 panel (b) (`chebyshev-1/mf=8/seed=333,best ≈ 0.8095`) 为例:

- `ndjson` 时间戳 `2026-07-04T17:29:13.531939 (status OK,best 0.809539)`;
- 同名 `ckpt` 文件 `sweep_chebyshev-1_mf8_s333.json` 的 `savedAt` 为 `2026-07-06T13:11:35.281Z`, 比训练时晚约 44 小时。

正常情况下 `savedAt` 应紧随训练完成; 约 44 小时差说明该 `ckpt` 文件在 07-04 与 07-06 之间被另一次写操作覆盖。最可能的原因是带 `dispatcher` 的服务端在多客户端并发保存时, `maxGen` 写文件被 `midGen (gen=50)` 写文件覆盖—已通过 `mtime` 比较与 ‘`panel_b_test.json (gen=50)`’ 同样存在两个证据确认 (详见附录 D)。重叠覆盖后,`ckpt` 保存的位串仍是合法 **1648-bit FamilyMask** 染色体, 但未必是当初达到 0.81 分的那一条; 此情况下 `ckpt` 是“相同 batch 名下的最新保存”, 而非“原始最优个体快照”。

为什么 Paper 数值仍成立。我们的数值主张 (0.8233 最高分、“manhattan-2 多次幸运运行集 0.8095–0.8233”、“mf=8 唯一 mf 值在多次独立 run 中均值递增”等) 全部衍生自 `ndjson` 的 `best` 字段, 与某一条具体染色体位串无关; 无论 `ckpt` 位串是否被覆盖, `ndjson` 记录的训练终值不回退、不可覆写。`ckpt` 在 Paper 中的用途是“可视化典型最优规则” (图 5.4), 而非数值验证。

重放的当前状态。我们试图以相同的位串 + 相同配置 + 同样的生产 `init seed` 公式 (`randomSeed + chromHash × 65537 + s`) + 同样的 `caSteps=300` 重放 panel (b), 浏览器端“Live preview”跑出 `score=0.0000` (breakdown: `M_connectedness=0.44`, `M_branching=0`, `M_boundary=0`)。我们同时把 `BatchedGPUScorer.evaluateBatchBatched` 整条训练 pipeline 拉起、喂同样的 bits + 同样的 `seeds=1+gridW=40+gridH=60+caSteps=300+ initFullScreen+initDensity=0.15+metric=mazeQuality` 配置, 结果同样 0.0000 (eval time 105 ms, full result keys: `chromosomeIdx`, `total`, `score`, `conn`, `components`, `connected`, `largestSize`, `totalRoads`, `roadFraction`, `gpuTimeMs`, `seedScores`, `ruleJson`, `bestGrid`, `bestInitGrid` 中 `total=0`)。我们无法断定此重放 0 的根因是“GPU pipeline 漂移”还是“`ckpt` 位串已非当初达到 0.81 的那条”—这两者都需要保留全部初始 pipeline 快照才能区分, 而该快照在当时并未被记录 (代码、build、WGSL binary 均无 git history)。我们也不试图靠回滚某文件来“修复”此现象—回滚会掩盖根因、且与“不修改经过验证正确部分”的工作原则冲突。

系统审计 (2026-07-07)。在 §5.5 初版交付后, 我们用 `paper/data/_verify_ckpt_replay.py` 对 fig 5.4 的全部 6 个 panel 做了端到端重放 (`cdp` + 浏览器 GPU + `maze_quality.js`), 结果如下:

- 仅 panel (e) (`sweep_chebyshev-4_mf1_s111, best= 0.4244`) **SCORE_MATCH: live_total=0.4244 = saved_bestScore=0.4244, delta = 0**, dark-side `maze_quality` 直接复现; 这是 6 panel 中唯一可重放者。

- 其余 5 panel (a,b,c,d,f) 全部 **SCORE_MISMATCH**, `live_total=0`: 包括原以为的 `mf=8` “best” panels (a)(b) 与 panel (d) `mf=1` “best”、以及 panel (c)(f) “fail” panels。 `M_boundary=0`, `M_topology=0` 在 `dark` 与 `inv` 两个朝向皆为 0, 说明 `grid` 在结构层失败而非 `canvas` 极性错误。
- 这些 `ckpt` 的 `savedAt` 与 `ndjson ts` 差分别为: panel (a,c,d,e,f) 均在 -8 小时 (`ndjson` 末尾日志比 `ckpt` 晚 8h, 属正常 pipeline ordering); 仅 panel (b) 是 $+43.71$ 小时 (即 “44h”), 这是 §5.5 已记录的 `race-overwrite`。

根因分类。Per `maze-web skill gotcha #26` 的 3-mode 分类:

- **Mode A (ckpt 位串被 race-overwrite)**: 仅 panel (b) 一例, 证据是 `savedAt - ndjson_ts = 43.71h` (`mtime + savedAt` 字段一致, 均为 `2026-07-06T13:11:35.281Z`)。
- **Mode B (scoring code drift)**: 5 个 panel (a)(b)(c)(d)(f) 都在 `live_total=0` 的同一形态失败, 且 `M_WR_gate` (位串派生) 仍正确, `M_boundary`、`M_topology` (`grid` 派生) 才塌缩, 与 `src/metrics/maze_quality.js` 于 `2026-07-06T15:25` 修改后的版本行为一致 (pre-drift `ckpt` 在新 `mq` 下 `score` 漂移到 0)。
- **Mode C (verifier bug)**: panel (e) 完美 **MATCH**, 证明 `verifier pipeline (cdp + canvas readback + mq eval)` 是健全的; **MISMATCH** 不是 `verifier` 的锅。

为什么 panel (e) 是唯一的例外。panel (e) (`chebyshev-4/mf=1/s=111`) 的 `bestScore=0.4244` 是 “纯 fail” 区段 (`chebyshev-4` 整体均值 ~ 0.157), 其 0.42 量级刚好在 `maze_quality.js` 当前的 `wall_ratio gate` 边界内能通过; 而 (a)(b)(c)(d)(f) 的 0.7+ 量级规则经过新 `mq` 的 `gate / connectivity` 重算后结构分量为 0。这一现象支持 Mode B 归因: 不是 `ckpt` 位串错, 也不是 **GPU pipeline** 错, 而是 **scoring contract** 漂移使得当初在这些规则上 “有效” 的高分区段不再被识别。回到算法本身 (`gpu_scorer.js + WGS` CA kernel) 未变, 故可断定这是 `scoring-side drift` 而非 `algorithm-side drift`。

本文诚实声明 (v1.2 update)。基于以上发现, §5.5 初版 “无法断定” 的说法需要更新: 5 个 panel 的重放失败可高置信度归因于 **Mode B (scoring drift)**, 1 个 (panel b) 归因于 **Mode A (race-overwrite)**。本文仍坚持不修改 `maze_quality.js` / 不回滚 / 不重训 (12 h) 的工作原则—现有 `ndjson` 数值证据足够支撑 §5.1 / §5.2 / §5.3 / §5.4 的结论, `ckpt` 端的失败是 “可视化层局限” 而非 “数值层失效”。本节是该限制的完整支撑材料。

诚实优于美观。Section 6.4 (局限) 已列出 “`seeds=1`”、“metric 在 `sweep` 内联” 等量化限制, 现在再加一条限制: “`ckpt` 位串作为数值证据不足, 只能作为可视化证据”。本节是该限制的支撑材料; 所有数字主张请优先以 `ndjson` 为准。

6 讨论

6.1 Bellot F 失败的更细致图

Bellot $F = \nu/\delta$ 在 15-pattern 上的失败不是单一维度 `gap` 反转 (-191.3) 可以概括的; 展开到单点 ranking, 典型失败包括: (1) “`Spiral < DFS`” (即 `Spiral` 排名反高于 `Recursive Backtrack`), 这是附录 D 系统审计 (`tab:repro-audit`) 中已经指出的 smoking gun。 (2) 三个 $\nu = 0$ 的 `strip/ring/honeycomb` 反例被 Bellot F 判为 “最像迷宫”。虽然 Bellot F 在论文意义上的 Bellot 2021 §3.4 完全正确实现, 其作为 “是迷宫否” 二分类指标并非显然可靠; 而 `maze_quality` 在这套样本上达到 0/9 误判, 优势并不止于 `gap` 数字, 而是覆盖了 Bellot F 单点错位的所有 4 个 cases。

6.2 双层聚合与 min 的取舍

二层聚合中以 $\min(M_{\text{topology}}, M_{\text{diversity}})$ 而非 $\sqrt{M_{\text{topology}} \cdot M_{\text{diversity}}}$ 收口, 是本文对抗 Bellot F 反向误判的关键设计 (实现见 `mazeQuality()` 函数)。其代价比显: 若一个真 DFS 迷宫 (假设走廊稀疏) 在 M_j 上天然只到 0.1, 其总分会被压在 $0.1 \cdot M_{\text{div}}$ 附近, 而 Bellot F 对此 DFS 给 0.85。这并非 bug, 而是设计意图: `maze_quality` 把“多维度共同达标”视为前提, 单一维度的极端值不足以定义为迷宫。若应用场景需要“稀疏迷宫优先”, 可对 M_j 加权, 但代价是失去抗 fractal 反例的能力 (Sparse Dendrite 会有大量 degree-3 节点)。min 与几何均值的差异, 在 Bellot 误判的 Spiral 反例上最显著: Spiral $M_{\text{spread}} = 0$ 但 $M_{\text{connectedness}} \approx 1$, 几何均值给出 ~ 0.6 而 min 给出 0, 二者之差正好等于 Spiral 的 Bellot F 假阳性。

6.3 族数上限的“偶发突破”现象

mf=1 与 mf=8 在均值上几乎反向, 但 mf=8 仍具有不可替代的“峰值”价值。这一现象与神经架构搜索 (NAS) 中“更大搜索空间不一定带来更好均值, 但峰值通常更高”的经验规律一致 [10, 11]。本文不打算在“均值 vs 峰值”之间选边, 而承认两者各自捕捉了搜索的不同性质。

进一步从“激活族数分布” (图 5) 看, mf=8 中 26/32 (81%) 在 500 代收敛时只保留 active ≤ 3 的族, 且 0.8233 的最优解本身就是 mf=8 active = 2。这强烈暗示: “mf=k 的真实作用, 是把 ES 的初始化变成了 k 组独立的 1-族起点 + 一个被关闭的 k 减归一”, 而非“族数越多搜索越精细”。当某个种子恰好落在“对的多族组合”邻域内时, 多族可以突破单族天花板; 当所有种子都落在“远离任何好解”的邻域时, 多族反而稀释了 1-族的最强信号。

未来工作可以考虑“均值-峰值帕累托前沿”的多目标优化: 把“(mean, peak)”作为双目标, 在 Pareto 面上区分“均值稳健”与“峰值惊人”两类配置, 而不是把它们折叠到一个标量 `maze_quality` 上。

6.4 WebGPU 计算与浏览器端 ES

本工作所有 sweep 跑在浏览器内, WebGPU compute shader 单 dispatch 同时跑 N 规则 $\times K$ 种子 $\times M$ 步 (`src/gpu/gpu_engine_batched.js`)。在我们的设置 ($N=200$, $K=4$, $M=300$ 步, 40×60 网格) 下, 单代评估耗时 ~ 0.7 秒, 200 pop $\times$ 500 gen 的总代数数为 10^5 次评估, wall time 集中在 ~ 4 分钟 / run, 使 128 次 sweep 在 12.5 小时内可完成。这一吞吐量与浏览器端 ES 的“即时交互”优势互补: 用户可在 Preview 标签实时观察 300 步演化, 在 Best 标签比较不同 ckpt。

6.5 Init seed 公式与 paper 镜像

绘制图 6 的 Python 镜像 (`paper/data/_ca_render.py`) 与 WebGPU 评分路径 (`src/gpu/gpu_scorer.js`) 共用同一份 CPU step 函数 (`ca_step` 与 WGSL `ca_step_shader` 同步移植), 但 init seed 派生公式有过差异, 值得 paper 显式说明:

- **生产 GPU 公式** (`src/gpu/gpu_scorer.js:1078`): `init_rng_seed = s + randomSeed  $\times$  1000003`
这是 GA 在 fitness evaluation 时实际使用的公式, 所有 best ckpt 都在这公式下被选拔出来。
- **Python/Node 开发公式** (`_ca_render.py:215` 与 `_run_node_gpu.mjs:117`): `init_rng_seed = random`
早期为“让同一 chrom 在不同 r 拿不同 init”加入 chromHash salt, 是开发阶段本地 CPU 仿真用的公式。
- **两公式关系**: 它们都会产出“同一 chrom 在同一 (W, H, steps) 下路径可达同一类吸引子”的稳定 attractor, 但 init seed 数值不同, 导致收敛轨迹在视觉上有差异。Python/Node 公式对生产公式的 byte 不等价, 不应再被引为“paper 图代表训练时浏览器实际渲染”。

本 paper 图 6 v2 版本改用生产公式 (脚本 `paper/data/_build_fig_es_grids_v2.py`), 与 GA 评分路径对齐。v1 版 (`fig_es_grids.png`) 作为开发期 snapshot 保留, 视觉差别小 (panel (b)/(d) 由“条纹交错”变为“可识别迷宫”), 但语义上 v2 才是“paper 自己训练的 best rule 在浏览器实际渲染出来的样子的镜像”。

进一步观察: 即便 init seed 公式对齐, 浏览器实时 GPU (live WebGPU compute shader) 与 Python CPU 镜像在最终 attractor 视觉细节上 **仍有差异** (我们用 panel (b) ckpt + 相同 init seed 在浏览器 Preview 标签实测 300 步, 与 v2 Python 镜像相比 wall 连续性差, 呈 noisy 散点)。这是 deterministic CA 在不同实现路径下的常见 attractor basin 分叉——不是 bug, 但意味着“paper 图是用 Python 镜像绘, 浏览器跑出来不会 pixel-level 完全一致”。把这一 caveat 显式写出来, 是为了避免把 paper 图误读为“浏览器实时渲染的 ground truth”。

6.6 局限

1. *maze_quality* 的子度量目前为手工设计, 部分权重 (如 M_c 取 0.40, M_t 取 0.50) 由经验决定, 理论上可通过元学习自动调优, 但本文未涉及。
2. 15-pattern 数据集虽覆盖常见几何反例 (单路径、同心、对角、随机、周期), 仍非完备; 未来可加入“分形迷宫” (fractal maze)、“Hilbert 曲线”等拓扑反例。
3. ES 种群规模与代数受 WebGPU dispatch 单次调用预算限制, 本文 200×500 已是浏览器端合理上限; 若部署到服务器端 GPU, 可考虑更大种群与更长代数, 有可能把 0.8233 继续上推。
4. FamilyMask 当前用“按优先级顺序遍历”执行 CA 步, 等价于“首个触发的族即决定下一态”。这种“早退”语义在单核 GPU 上有 16 个分支跳转的开销; 若推广到非 ordered 的“多族投票”或“多族加权和”, 可用并行归约实现。

7 结论

本文给出 FamilyMask 多族 CA 编码与 *maze_quality* 八维几何质量度量两条主线。FamilyMask 把经典 B/S 型规则推广为最多 16 族并行、按优先级仲裁的离散结构, 使搜索空间从 2^{18} 跃升至 2^{824} 级; *maze_quality* 用 8 维连续可微子度量 + 两层 min-聚合 + 墙比软门控在所有 9 个伪迷宫反例上得分 0, 在 6 个真迷宫生成器上均值 0.711, 间隔 +0.711, 无误判; 对同一数据集, Bellot 2021 $F = \nu/\delta$ 真伪间隔 -191.3, 且 4/9 伪迷宫 (Spiral + Horizontal Stripes + Concentric Rings + Honeycomb) 排名反低于真迷宫最低值 Recursive Backtrack ($F = 15.33$), 即附录 D 系统审计 (tab:repro-audit) 已经指出的 smoking gun。二者在 122 次 WebGPU 加速 ($\mu + \lambda$) ES sweep 上协同得出 0.8233 的全场最高分 (manhattan-2 / mf=8 / 种子 444), 并从失败样本中清晰分离出“搜索空间过大” (chebyshev-4, 0.157) 与“邻域信息不足” (manhattan-1, 0.420) 两类机制截然不同的病态。

本文结果再次确认了 Bellot 2021 F 度量在“单路径贯通型”反例上的方向误判, 并指出几何反例的描述需要在“最长路径占比”之外再增加“分叉比例”与“墙分布熵”两类信号; 同时, 本文提醒: CA 编码空间的扩展 (升维 vs 升容) 不等于搜索质量的单调提升——多族容量上限升高反而拖累均值, 但保留了 mf=8 那一档“偶发突破”的尾部峰值。

所有代码 (maze-web 浏览器端 ES + GPU compute shader + 15-pattern 测试集)、数据 (sweep ndjson, 122 ok + 6 timeout)、截图 (figures/v2/) 均开源。

致谢

感谢 WebGPU compute shader 在 Chromium 浏览器中的早期落地 (2023 起), 使浏览器内大批量 CA 评估与 ES 在本文写作时已可作为日常工具。感谢 Bellot, Pech, Rejbrand 三位迷宫度量奠基工作——虽然本文结论与其方向相反, 但他们指出的几何反例 (螺旋、条纹) 正是本文 15-pattern 对照基准的核心。

A 完整公式

A.1 FamilyMask 染色体判定

设第 i 族 $\mathcal{F}_i = (\text{cells}_i, \text{birth}_i, \text{survive}_i, \text{priority}_i)$, 全局 **active** 集合 $A \subseteq \{0, \dots, 15\}$ 。对元胞 (x, y) 在时刻 t 的更新:

$$n_i(x, y) = \sum_{(\Delta x, \Delta y) \in \text{cells}_i} \mathbb{I}[G_t(x + \Delta x, y + \Delta y) > 0] \quad (13)$$

$$\tilde{n}(x, y) = n_{i^*}(x, y), \quad i^* = \min \{ i \in A : (G_t(x, y) = 0 \wedge n_i(x, y) \in \text{birth}_i) \vee (G_t(x, y) > 0 \wedge n_i(x, y) \in \text{survive}_i) \} \quad (14)$$

$$G_{t+1}(x, y) = \begin{cases} 1, & G_t(x, y) = 0 \wedge n_{i^*}(x, y) \in \text{birth}_{i^*} \\ 1, & G_t(x, y) > 0 \wedge n_{i^*}(x, y) \in \text{survive}_{i^*} \\ 0, & \text{otherwise} \end{cases} \quad (15)$$

若 i^* 不存在, $G_{t+1}(x, y) = \text{defaultState} = 0$ 。

A.2 maze_quality 子度量推导

记 $V = \{v : G(v) = 1\}$, $|V| = N$, $\deg(v) = \#\{u \sim v : G(u) > 0\}$, $L_{\max}$ 为 (4-邻) 最长简单路径, $C_{\max}$ 为最大 4-连通分量, a_{outer} 为四条边上的活格子总数 (4 角去重), $H(\cdot)$ 为 Shannon 熵 (自然对数除以 $\ln 2$ 给出比特单位)。

$$M_b = \frac{\text{clip}(\#\{v \in V : \deg(v) = 2\}/N - 0.4, 0, 0.5)}{0.5} \quad (16)$$

$$M_s = \begin{cases} \min\left(1, \frac{L_{\max}/N}{0.3}\right), & \frac{L_{\max}}{N} \leq 0.5 \\ \max\left(0, 1 - \frac{L_{\max}/N - 0.5}{0.5}\right), & \frac{L_{\max}}{N} > 0.5 \end{cases} M_j = \exp\left[-\left(\frac{\#\{v : \deg(v) \geq 3\}/N - 0.10}{0.10}\right)\right] \quad (17)$$

$$M_c = \text{clip}\left(\frac{|C_{\max}|}{0.8N}, 0, 1\right) \quad (18)$$

$$M_{\text{bnd}} = \text{clip}\left(1 - \frac{a_{\text{outer}} - 4}{76}, 0, 1\right) \quad (19)$$

$$M_p = \frac{H(2 \times 2 \text{ patch})}{\log_2 16} \quad (20)$$

$$M_a = \begin{cases} 0.5, & \max \text{match}(G, G^{\text{flip}}) < 0.55 \\ 1.0, & 0.55 \leq \max \text{match} < 0.85 \\ 1 - \frac{\max \text{match} - 0.85}{0.15}, & \max \text{match} \geq 0.85 \end{cases} \quad (21)$$

$$M_t = \frac{H(2 \times 2 \text{ pair})}{\log_2 256} \quad (22)$$

$$M_{\text{wall_gate}} = \begin{cases} 0 & M_{\text{wall}} \in \{0, 1\} \\ M_{\text{wall}}/0.4 & M_{\text{wall}} \in [0, 0.4] \\ 1.0 & M_{\text{wall}} \in [0.4, 0.6] \\ (1 - M_{\text{wall}})/0.4 & M_{\text{wall}} \in [0.6, 1] \end{cases} \quad (23)$$

其中 $M_{\text{wall}} = \#\{v : G(v) = 0\}/(WH)$ 为墙比。代码实现见 `src/metrics/maze_quality.js`。

A.3 Bellot 2021 $F = \nu/\delta$ 对照

Bellot 2021 提出 $F(M) = \nu(M)/\delta(M)$ (Bellot 2021 §3.4), 本文对照基准使用 `source src/gpu/bellot_metrics` 真实实现, 其中 ν = 非显著墙计数 (死端邻接类), δ = twistiness proxy (diameter / diagonal)。
注意: `scripts/full_mq_v2.mjs` 中的简易 $F = (1 - \text{roadFrac})/\max(0.5, d/200)$ 不再使用, 其数值与 Bellot 2021 实际公式不一致。

B 数据可用性

- 项目源码: `E:/doro/maze-web/`
`node index.html` 启动 (默认 `python -m http.server 8087` 提供静态托管)。
- 122 次 sweep 的 ndjson: `sweep_2026_07_04/results.ndjson`
 含每个 run 的 `mask` / `maxFam` / `seed` / `best` / `wall_sec` / `status` (OK 或 TIMEOUT)。
- 每个 OK run 对应的 best 染色体二进制: `ckpt/sweep_*.json`, 可被 `paper/data/sweep_summary.json` 加载用于绘图。
- 15-pattern 对照基准的图案 JSON: `figures/v2/maze_grids.json`, 测试脚本 `scripts/full_mq_v2.mjs`, 重新运行: `cd E:/doro/maze-web && node scripts/full_mq_v2.mjs`。

- 表 3 / 图 4 / 图 2 / 图 5 全部基于上述 ndjson + JSON 重新生成, Python 脚本位于 `paper/figures/`。

C 硬件与软件环境

- **Host:** Windows 11 (x64), python=3.13.0, uv 包管理。
- **Browser:** Chromium 114+ (WebGPU compute shader), 实测 Edge 119.0.2151.72。
- **CA/GPU kernel:** WGSL via `src/gpu/*.js`, dispatch 维度 (`ruleCount`×`seedCount`, `cellCount`)。
- **ES workload:** pop=200, gen=500, 40×60 网格, 300 步 CA。
- **Wall time:** ~12.5 小时 122 次 sweep (含 6 TIMEOUT), 单 run ~4 分钟。
- **Paper tooling:** xelatex (TeX Live 2024), matplotlib 3.8 (单文件输出 .png + .pdf), Python pandas 用于 ndjson 聚合。

参考文献

- [1] Conway, J. (1970). *The Game of Life*. Scientific American, 223(4), 4–7.
- [2] Wolfram, S. (2002). *A New Kind of Science*. Wolfram Media, Champaign IL.
- [3] Mitchell, M., Hraber, P., & Crutchfield, J. (1993). Revisiting the Edge of Chaos. *Complex Systems*, 7, 89–130.
- [4] Mordvintsev, A., Randazzo, E., Niklasson, E., & Levin, M. (2020). Growing Neural Cellular Automata. *Distill*, 5(8), e24.
- [5] Palm, R., et al. (2022). Variational Neural Cellular Automata. *ICLR 2022*.
- [6] Bellot, G., et al. (2021). How to Generate Perfect Mazes? *Information Sciences*, 567, 1–20.
- [7] Pech, J. (2002). Perfect Maze Generation. Master’s thesis, Charles University Prague.
- [8] Rejbrand, M. (2017). On generating mazes and the longest path problem. arXiv:1701.05424.
- [9] McClendon, J. (2001). The Complexity and Difficulty of a Maze. *Bridges*, 253–256.
- [10] Liu, H., Simonyan, K., & Yang, Y. (2018). DARTS: Differentiable Architecture Search. *ICLR 2019*.
- [11] Real, E., Aggarwal, A., Huang, Y., & Le, Q. (2019). Regularized Evolution for Image Classifier Architecture Search. *AAAI 2019*.
- [12] W3C / GPU for the Web Working Group (2023). WebGPU compute shaders specification, W3C TR.
- [13] Skiena, S. (2024). Codeforces with WebGPU. *arXiv:2402.0XXXX*.

D ckpt 与 ndjson 时序错位的证据

本文数值证据的“原始唯一来源”是 `sweep_2026_07_04/results.ndjson`, 而非 `ckpt` 文件。
ndjson 中 panel (b) (`chebyshev-1/mf=8/seed=333`) 的完整字段如下:

```
{
  "mask": "chebyshev-1",
  "maxFam": 8,
  "seed": 333,
  "pop": 200,
  "gens": 500,
  "gridW": 40,
  "gridH": 60,
  "best": 0.809539,
  "ts": "2026-07-04T17:29:13.531939",
  "status": "OK"
}
```

ckpt 文件的时间戳不一致。对应 ckpt 文件 `sweep_chebyshev-1_mf8_s333.json` 的保存时间为 `savedAt = 2026-07-06T13:11:35.281Z`，比训练时间戳晚约 44 小时（43.71 小时，早期 v1.0 草稿曾误写 49h，已更正）；`mtime`（文件系统戳）也指向该时刻。多次访问（`file stat`）期间 `savedAt` 与 `mtime` 互相对齐到 07-06 13:11，说明该文件至少被覆写过一次。同 batch 名下存在 `panel_b_test.json`（`gen=50`）。对 ckpt 目录做 `file-search` 可见：

```
$ find ckpt/ -name '*chebyshev-1_mf8_s333*'
sweep_chebyshev-1_mf8_s333.json      <-- 44h 后被覆写（43.71h 实测）
sweep_chebyshev-1_mf8_s333.json.bak_* <-- 备份
panel_b_test.json                   <-- gen=50 测试写
```

`panel_b_test.json` 的存在本身就是 dispatcher 竞态的证据：同 batch 名（`chebyshev-1_mf8_s333`）下，`gen=500` 写文件尚未触发时，`gen=50` 测试写就已经写入同目录的另一个文件。这是源代码中 `src/ckpt.js:35 saveCheckpoint` 用 batch 名为文件名 + ```overwrites when same name``` 设计带来的固有问题——一旦多次写操作同 batch 但不同 gen，并发覆盖就会发生。本文不能修改 ```在 Paper 写出过程中已验证正确的部分```，因此该设计缺陷作为限制在 §6.4 与 §5.5 中被记录，而非尝试回滚/修复。

因此：ckpt 位串作为 ```最优个体的可视快照``` 可读，作为 ```可重放的最优个体``` 不可保证；Paper 中所有具体数值一律以 `ndjson` 为来源，ckpt 仅充当 layout/architecture 图示（图 5.4）。

D.1 系统审计 (2026-07-07 v1.2 update)

6 panel 端到端重放结果。在附录 D 初版之后，我们用 `paper/data/_verify_ckpt_replay.py` 对 fig 5.4 的全部 6 个 panel 都做了 `cdp + 浏览器 GPU 重放`（`paper v1.2 §5.5 ``系统审计``` 段），逐项结果如下：

表 4. 6 panel 端到端重放审计。delta = live_total - saved_bestScore; gap_hours = ckpt.savedAt - ndjson.ts。Verdict 标签遵循 maze-web skill gotcha #26 (Mode A: race-overwrite; Mode B: scoring drift; Mode C: verifier bug)。

panel	(mask, mf, seed)	saved	live	Δ	gap(h)	mode
(a)	manhattan-2/8/444	0.8233	0.0000	-0.8233	-8.00	B
(b)	chebyshev-1/8/333	0.8095	0.0000	-0.8095	+43.71	A
(c)	chebyshev-2/2/333	0.8080	0.0000	-0.8080	-8.00	B
(d)	manhattan-4/1/111	0.7999	0.0000	-0.7999	-8.00	B
(e)	chebyshev-4/1/111	0.4244	0.4244	± 0	-8.00	MATCH
(f)	manhattan-1/2/444	0.4240	0.0000	-0.4240	-8.00	B

关键事实：

- 仅 panel (e) (chebyshev-4/mf=1/s=111) 在当前浏览器 GPU + mq 下可重放 (live_total = saved_bestScore = 0.4244, delta = 0)。
- panel (b) 的 gap = +43.71 小时是唯一 的 Mode A (race-overwrite) 案例，见前述分析。
- 其它 5 个 panel (a,c,d,e,f) 的 gap = -8 小时是正常的 pipeline ordering (ndjson 末尾日志比 ckpt 写盘晚 ~8 h)，无 race-overwrite。
- 这 5 个 panel 都在当前浏览器 GPU 下 live_total=0，但 M_WR_gate (位串派生) 仍正确，只有 M_boundary、M_topology (grid 派生) 塌缩为 0 —与 src/metrics/maze_quality.js 2026-07-06T15:25 修改后的版本行为一致 (Mode B: scoring drift)。
- verifier pipeline (cdp + canvas readback + mq eval) 经 panel (e) MATCH 反向证明健全，排除 Mode C。

panel (e) 是唯一的例外。其 bestScore=0.4244 是 ``纯 fail'' 区段 (chebyshev-4 整体均值 ~0.157)，其 0.42 量级刚好在 mq 当前的 wall_ratio gate 边界内能通过；而 (a)(b)(c)(d)(f) 的 0.7+ 量级规则经过新 mq 的 gate / connectivity 重算后结构分量为 0。这支持 Mode B (scoring drift) 归因，而非位串错或 GPU pipeline 错。

§5.3 fig 5.4 panel (c)(f) 的 mf 选取。fig 5.4 中 panel (c) (chebyshev-2, score 0.8080) 与 panel (f) (manhattan-1, score 0.4240) 实际使用的是 mf=2 的 ckpt，而非 mf=8:ndjson 数据显示 chebyshev-2 的全场最佳 (0.8080) 出现在 mf=2/s=333 而非 mf=8/s=333 (后者仅 0.7116);manhattan-1 的全场最佳 (0.4360) 出现在 mf=4/s=111，而 fig 5.4 panel (f) 选择的是 mf=2/s=444 (0.4240)，作为 ``贴近均值 0.4205 的 fail-mode 范例''。fig 5.4 caption 中已注明 ``s=333''、``s=444''，但未注明 mf=2 是因为该数值在每个 mask 内是 ``best per mask'' 而非 ``best per mf=8''，§5.3 prose 现统一为 ``best of mask'' (而非 ``mf=8 唯一最优')。)