

多族元胞自动机编码与八维迷宫质量度量

Multi-Family Cellular Automaton Encoding with an
Eight-Dimensional Maze Quality Metric

sko (冯卓源) · 编译于 2026 年 7 月 · FamilyMask / maze_quality (maze-web)

摘要

针对元胞自动机是否生成迷宫这一判定难题, 本文给出两件互补的产物。

其一, **FamilyMask** 多族染色体编码。它把经典 Conway 型 B/S 规则推广为多族组合: 每族独立持有自己的邻域 mask (固定 9×9 中心外 80 格)、出生集、存活集与优先级; 最多 16 族并行, 执行时按优先级顺序遍历, 首个匹配的族决定下一态。单族时退化为标准 B/S 字符串 (2^{18} 候选), 多族时搜索空间跳跃至一族 B/S 加一组 mask 的 2^{103} 候选级 ($1 \text{ active} + 80 \text{ cells} + 9 \text{ B} + 9 \text{ S} + 4 \text{ priority} = 103 \text{ bits}$, 见 `src/search/rule_chromosome.js::SL0T_BITS`)。

其二, **maze_quality** 八维几何质量度量。它在 $\min(M_{\text{topology}}, M_{\text{diversity}}) \times M_{\text{wall_gate}}$ 的两层结构上聚合八个连续可微子度量, 所有取值 $[0, 1]$, ES 可学。具体而言, 五个拓扑子度量 (走廊主导度 M_b 、最长路径占比 M_s 、十字口占比 M_j 、最大连通分量占比 M_c 、外圈抑制 M_{bnd}) 加权几何聚合得到 M_{topology} ; 三个多样性子度量 (2×2 块熵 M_p 、镜像不对称度 M_a 、 2×2 邻接对熵 M_t) 加权几何聚合得到 $M_{\text{diversity}}$ 。再用 $\min$ 强制两侧平衡, 乘以 $[0.40, 0.60]$ 上值为 1 的墙比软三角门控 $M_{\text{wall_gate}}$, 拦截“实心块”与“空盒”两种典型病态吸引子。

在 15-pattern 对照基准 (六个经典迷宫生成算法 DFS/Kruskal/Prim/Growing Tree/Sidewinder/Binary Tree + 九个非迷宫吸引子 Spiral/Fractal Tree/Horizontal Stripes/ Random Noise (50 上, **maze_quality** 真正迷宫均值 0.711, 伪迷宫均值 0.000, 间隔 +0.711, 9 个伪迷宫无误判; 同一数据集上 Bellot 2021 $F = \nu/\delta$ 度量真伪间隔 -191.3, 且 9 个伪迷宫中有 4 个 ($F = 0$ 的 Horizontal Stripes/Concentric Rings/Honeycomb 加上 $F = 11.85$ 的 Spiral) 排名反低于真正的 DFS ($F = 15.33$), 即 Bellot F 错误判定“Spiral 比 DFS 更像迷宫”, 这是附录 D 系统审计 (`tab:repro-audit`) 中已经指出的 smoking gun (本节下方全部使用 `src/gpu/bellot_metrics.js::bellotF` 真实 Bellot 2021 实现 $F = \nu(M)/\delta(M)$, 不再使用早期 `scripts/full_mq_v2.mjs` 的简化版 $\nu = 1 - \text{roadFrac}$, $\delta = d/200$)。

将 FamilyMask 嵌入 200×500 的 $(\mu + \lambda)$ 进化策略, WebGPU compute shader 加速 CA 评估, 在 128 次 sweep ($8 \text{ 距离模板} \times 4 \text{ 族数上限} \times 4 \text{ 随机种子}$, 40×60 网格, 300 步演化) 上, 成功完成 122 次, 得到最高分 **0.8233** (manhattan-2 模板、8 族上限、种子 444)。进一步统计得到三组可重复观察: (i) 多族容量上限升高反而使均值下降 (mf=1: 0.6984 $\rightarrow$ mf=8: 0.6306), 但 mf=8 的尾部拥有 0.8233 全场最高, 体现“均值降 / 峰值升”的“偶发突破”现象; (ii) chebyshev-4 模板均值仅 0.157, 主因为其 9×9 邻域使单族搜索空间维度达 2^{103} , 远大于 10^5 次评估预算可跨越的初始化-最优距; (iii) manhattan-1 (4 邻域 von Neumann) 模板均值仅 0.420, 原因是 4 邻域 无法为走廊结构提供足够的二阶空间上下文。所有代码、实验数据、截图开源。

Abstract

We present two complementary contributions for evaluating whether binary grids generated by cellular automata (CA) constitute mazes. **FamilyMask** generalises Conway-style life rules to

a multi-family chromosome: each of up to sixteen families owns its own neighbourhood mask (the 9×9 centred footprint minus the centre, 80 cells), birth set, survival set, and priority; at each step the CA scans active families in priority order and the first match decides the next cell state. **maze_quality** is an eight-dimensional geometric score aggregating five topology sub-metrics (corridor dominance M_b , longest-path share M_s , junction share M_j , largest-component share M_c , outer-frame suppression M_{bnd}) and three diversity sub-metrics (2×2 patch entropy M_p , mirror asymmetry M_a , 2×2 adjacency-pair entropy M_t) via a two-level weighted geometric mean, clamped by min and multiplied by a triangular wall-ratio gate centred at $[0.40, 0.60]$. On a 15-pattern benchmark the score attains mean 0.711 on true mazes and 0.000 on pseudo-mazes (gap +0.711, zero misclassifications of 9 pseudo-patterns); the Bellot 2021 $F = \nu/\delta$ score on the same dataset has gap -191.3 , with the wrong sign (“lower=maze-like”), and 4 of 9 pseudo-mazes (Spiral $F=11.85$ plus three $F=0$ strip/ring/honeycomb patterns) are ranked BELOW the genuine DFS ($F = 15.33$) — the smoking gun.

Plugging FamilyMask into a 200-population, 500-generation ($\mu+\lambda$) evolution strategy and running 128 ES sweeps over 8 distance templates, 4 family caps, and 4 random seeds (40×60 grids, 300 CA steps, WebGPU-accelerated) yields 122 successful runs and a top score of **0.8233** (manhattan-2, 8-family cap, seed 444). On the 15-pattern benchmark the score attains mean 0.711 on true mazes and 0.000 on pseudo-mazes (gap +0.711, zero misclassifications of 9 pseudo-patterns); the Bellot 2021 $F = \nu/\delta$ score on the same dataset has gap -191.3 (“lower=maze-like”), and 4 of 9 pseudo-mazes (Spiral $F = 11.85$ plus three $F=0$ strip/ring/honeycomb patterns) are ranked BELOW the genuine DFS ($F = 15.33$) — the smoking gun. Three robust observations emerge: (i) larger family caps lower the mean (mf=1: 0.6984 $\rightarrow$ mf=8: 0.6306) but raise the upper tail (mf=8 owns the overall best 0.8233); (ii) chebyshev-4’s poor mean (0.157) is caused by the the 9×9 neighbourhood implying a 2^{103} candidate space (per family) far beyond the $\sim 10^5$ evaluations available to random-init-to-optimum distance; (iii) manhattan-1’s poor mean (0.420) is caused by the 4-neighbour (von Neumann) topology providing too little spatial context for corridor emergence. All code, data, and figures are released as open source.

目录

1	引言	3
2	相关工作	4
2.1	CA 与迷宫生成	4
2.2	迷宫质量度量	4
2.3	多族 CA	5
2.4	浏览器内 ES 与 WebGPU	5
3	FamilyMask 多族编码	5
3.1	染色体布局	5
3.2	距离模板约束	5
3.3	演化执行	6
3.4	染色体结构示意图	6
4	maze_quality 八维几何度量	7

4.1	设计原则	7
4.2	五个拓扑子度量	7
4.3	三个多样性子度量	8
4.4	二层聚合	8
5	实验评估	10
5.1	实验设置	10
5.2	big_sweep 结果 (500×2000 , 部分完成)	11
5.3	旧 sweep 统计 (200×500 , $n=122$)	12
5.4	Mask $\times$ Family Cap 消融分析	13
5.5	Mini-sweep 网格结果 (8 mask templates)	14
5.6	Big Sweep 对比小结	14
6	讨论	14
6.1	Family Cap 的“均值降/峰值升”悖论	14
6.2	两类失败模式的机制分离	15
6.3	Bellot F 的 smoking gun: 单路径反例上的方向误判	15
6.4	Big Sweep 的意义: 200×500 已接近饱和	16
6.5	局限与未来工作	16
7	结论	17
	致谢	17
A	完整公式	18
A.1	FamilyMask 染色体判定	18
A.2	maze_quality 子度量推导	18
A.3	Bellot 2021 $F = \nu/\delta$ 对照	19
B	数据可用性	19
C	硬件与软件环境	19
D	ckpt 与 ndjson 时序错位的证据	20
D.1	系统审计	21

1 引言

元胞自动机 (cellular automata, CA) 能否生成迷宫, 这道问题在 Conway 时代就被反复提出。早期工作记录了上千条规则的演化轨迹, Conway 1970 在生命游戏中观察到“滑翔机”与“滑翔机枪”类的局域结构, 但选择“什么是迷宫”始终依赖人眼判断, 缺乏可量化的判定准则 [1]。Wolfram 2002 在其专著中也注意到若干基本 CA 的终态呈迷宫状, 并将其归入“第四类”吸引子的子类 [2]。近年, 随着神经 CA 与生成式 CA 的兴起 [4, 5], CA 再次进入程序化内容生成 (PCG) 的研究视野, 而“它生成的图到底像不像迷宫”则成了一道绕不开的判别题。

已有的两种判定思路各有局限。其一, Bellot 2021 提出的 F 度量从迷宫图提取连接性、交叉口计数与回路比例等特征, 与参考真迷宫做加权比较; 该度量在多数真迷宫上得分稳定, 但在“具

有单一贯穿长路径”的几何反例(螺旋、同心回路、对角条纹)上,因“最长路径占比”优势反而给高分,方向发生反转[6]。其二,Pech 2002 与 Rejbrand 2017 提出在生成阶段直接约束路径结构(强制单连通、强制 T 形分叉比例)[7, 8],这类硬约束对生成器侵入性强,无法直接移植到没有显式构造步骤的 CA 演化系统。

本文绕开上述两个方向,从两条线分别入手。**第一条线**是把 B/S 型生命周期规则推广为 **FamilyMask** 多族组合(见 3),族之间用优先级仲裁,使搜索空间从单条 B/S 字符串(2^{18} 候选)跃升到一族 B/S 加一组邻域 mask 的 2^{103} 级别,为更复杂的涌现留出空间。**第二条线**是提出 **maze_quality** 八维几何质量度量(见 4),子度量全部连续可微(取值 $[0, 1]$,ES 可学),两层加权几何聚合避免单边 exploit,并用一道墙比软门控拦截“实心块”与“空盒”两种典型病态吸引子。

发现 1.1 (FamilyMask + maze_quality 两条主线的协同) 对同一 40×60 网格 CA 终态图, maze_quality 在 15-pattern 数据集上的真假间隔 $+0.711$; Bellot $F = \nu/\delta$ 的真假间隔为 -191.3 , 且 4 个伪迷宫的 Bellot F (Spiral 11.85 + Horizontal Stripes/Concentric Rings/Honeycomb 三者均为 0) 排名反低于真迷宫最低值 Recursive Backtrack ($F = 15.33$), 即经典“Bellot F 误判 Spiral 比 DFS 更像迷宫” smoking gun。将 FamilyMask 接入 $(\mu+\lambda)$ ES 后, 搜索 122 次成功, 得到 0.8233 全场最高分。

把 FamilyMask 与 maze_quality 联立, 放进 WebGPU 加速的 $(\mu+\lambda)$ ES, 在 122 次成功的 sweep 上得到 0.8233 的最高分, 并从失败样本中分离出两类机制不同的病态: 搜索空间过大 (chebyshev-4, 均值 0.157) 与 邻域信息不足 (manhattan-1, 均值 0.420)。前者来自 10^5 级 ES 预算与 2^{103} 级单族染色体空间的不可跨越距离, 后者来自 4 邻域本身无法提供走廊结构涌现所需的二阶空间上下文。

本文结构安排如下: 2 节回顾相关工作; 3 节给出 FamilyMask 编码与演化语义; 4 节给出 maze_quality 的八子度量推导与聚合规则; 5 节报告 15-pattern 对照与 122 次 sweep 结果; 6 节讨论设计的取舍、“偶发突破”现象、浏览器端 ES 优势与局限; 7 节给出结论; 附录给出完整公式与软硬件环境。

2 相关工作

2.1 CA 与迷宫生成

Conway 1970 在生命游戏中观察到“滑翔机”与“滑翔机枪”类局部结构, 并指出生命游戏可作为研究“自组织与涌现”的最小系统[1]; 但 Conway 本身没有把 B3/S23 与迷宫生成做直接对应。Wolfram 2002 在其专著中系统分类了基本 CA 在多初始下的终态, 其中若干(尤其 Rule 30、Rule 110、Rule 184)的终态图呈现出类迷宫的几何(走廊、死端、分叉都有), 但选择“哪条规则生成的是迷宫”仍依赖人眼, 作者承认没有给出形式化的判定准则[2]。Mitchell 等 1993 用遗传算法在 CA 密度分类问题上进行搜索, 展示了“计算涌现”在简单规则空间中的可行性[3], 其目标函数(密度分类准确率)与本文“迷宫质量”目标有结构上的相似性, 但搜索结果并非几何上可读的迷宫。

2.2 迷宫质量度量

Bellot 2021 提出基于路径计数与回路比例的 F 度量[6], 被 MazeBench 等用作多生成器对比基准, 该度量对 DFS、Kruskal、Prim 等经典算法输出稳定; 但对“单一贯穿长路径”类的几何反例 (Spiral、Concentric Rings、Diagonal Stripes) 给出错误的“比真迷宫更优”评分, 这正是本文 15-pattern 对照基准收集的一类核心反例。Pech 2002 建议在生成器侧用“唯一长路径”强制单连通迷宫[7], Rejbrand 2017 讨论“最长路径 / 顶点数”在螺旋反例上的失效, 提出“延长路径必须分

支”的修正约束 [8]; 二者均面向“生成器侧干预”, 对“已经演化出来的 CA 终态图”无判定能力。McClendon 2001 给出迷宫复杂度的 $\gamma(h)$ 、 $\gamma(M)$ 、 $\delta(M)$ 三个微分度量 [9], 被 Bellot 2021 拼接到 F 中, 但同样无法解决“单路径贯通型反例误判”。本文 *maze_quality* 用五维拓扑 + 三维多样性的 min-聚合替代 F 的单一“最长路径占比”维度, 从而在所有 9 个伪迷宫反例上得分 0.000, 0 个误判。

2.3 多族 CA

多族规则系统在周期边界 CA (Margolus 1984) [14] 与神经 CA [4] 中各有实践。Margolus 块变换使用“块级”规则族但族是预定义且不参与搜索; 神经 CA 的“多通道”是同一族的不同“颜色”, 亦不作为独立基因位。本文 FamilyMask 把族数、邻域、优先级一并编码为染色体, 使“族”成为可被 ES 增删的离散结构, 这一点与上述工作均不同。

2.4 浏览器内 ES 与 WebGPU

Chromium 自 2023 年起原生支持 WebGPU compute shader, 使浏览器内可部署大批量 CA 评估 [12]。Skiena 2024 在 Codeforces 评测系统中引入 WebGPU 后端 [13], 本文沿用同一思路, 但把 workload 集中在单核 fitness 评估 (CA 演化), 人口规模 200、迭代 500 代, 单次 run 在 40×60 网格、300 步演化下可在 ~ 4 分钟完成, 保证 122 次 sweep 可在 12.5 小时墙钟内完成。

3 FamilyMask 多族编码

3.1 染色体布局

一条 FamilyMask 染色体总长 1648 位, 平分为 16 个 **family slot**; 每个 slot 长 103 位, 内部按 LSB $\rightarrow$ MSB 顺序分为 5 个字段, 如表 1 所示。这一布局源自源码 `src/search/rule_chromosome.js::CHROM_PA` 与 `src/search/es_searcher.js::SLOT`。

表 1. Family slot 内部布局 (LSB $\rightarrow$ MSB, 共 103 位)

字段	位宽 (位)	取值范围
active	1	$\{0, 1\}$
cells mask	80	9×9 中心外 80 格, 逐位表示是否包含该邻格
birth	9	$B_0, B_1, \dots, B_8$ 各一比特
survive	9	$S_0, S_1, \dots, S_8$ 各一比特
priority	4	1...16, 自然编码
合计	$1 + 80 + 9 + 9 + 4 = 103$ 位 / slot	

实际启用族数由 **active** 位决定。ES 在变异期通过 **familyMask** 参数指定“允许写入哪些 slot” (默认全部 16, 本文实验对比 1 / 2 / 4 / 8 四个上限)。当全部 16 个 slot 启用时, 染色体信息量为 1648 位, 对应 2^{1648} 个候选; 单族退化为 103 位 (2^{103} 个候选), 仍远大于经典 B/S 字符串 (2^{18}) 的规模。

3.2 距离模板约束

cells mask 的 80 位表示一个 9×9 邻域 (中心 ± 4) 是否被该族视为“邻居位置”; 但模板之外的位置被强制清零。本文支持两类距离模板 (距离以 $(\Delta x, \Delta y)$ 与中心的 Manhattan/Chebyshev

距离计):

- **manhattan- N** : $|\Delta x| + |\Delta y| \leq N$; 适用 4 邻 ($N=1$)、8 邻 ($N=2$)、12 邻 ($N=3$)、24 邻 ($N=4$)。
- **chebyshev- N** : $\max(|\Delta x|, |\Delta y|) \leq N$; 适用方形邻域 (8 邻 $N=1$ 、24 邻 $N=2$ 、48 邻 $N=3$ 、80 邻 $N=4$)。

两族互有包含关系: chebyshev- k 严格包含 chebyshev- $(k-1)$, chebyshev-2 严格包含 manhattan-2。这一包含关系在 5 节讨论 chebyshev-4 / manhattan-1 两类失败模式时是关键。

3.3 演化执行

对每个元胞 $c = (x, y)$, 判定下一态 c' 的流程如下 (代码: `src/core/rule.js::Rule.evaluate`):

1. 读当前态 `self = G(x, y)`, `self ∈ {0, 1}`。
2. 按 **priority 升序** 遍历所有 **active** 族; 每个族独立计算该族 `cells` 子集内的活邻居数 $n = \sum_{(\Delta x, \Delta y) \in \text{cells}} \mathbb{K}[G(x + \Delta x, y + \Delta y) > 0]$ 。
3. `self=0` 时检查 $n \in \text{family.birth}$, `self=1` 时检查 $n \in \text{family.survive}$ 。
4. 首个匹配的族决定 c' ; 若无一族触发, $c' = \text{defaultState} = 0$ 。

边界外视为 0 (死), 与经典 Conway 习惯一致。同一族内不分 “birth-only” 与 “survive-only” 两次触发, 所有判定来自同一个 `cells` 集与同一组 B/S set, 与围棋 “先手优先” 的语义对应: 优先级数字小者先行, 优先决定下一态。

命题 3.1 (单族退化) 当只有 1 个 *family active* 时, *FamilyMask* 退化为 “ $(9 \times 9 - 1)$ 邻域 + birth set + survive set” 的经典广义 Conway 规则。此时 *cells mask* 仅取模板内的位被保留, 搜索空间为模板位宽 b 加 18 位的 B/S set, 即 2^{b+18} 。取 *chebyshev-1* ($b=8$, 即 Moore 8 邻) 即得 $2^{26} \approx 6.7 \times 10^7$, 正是经典 “B/S 字符串 + 任意邻域” 规则的搜索量级。

3.4 染色体结构示意图




图 1. FamilyMask 染色体结构示意图 (以 8 族 / 16 槽为例)。上方两行共 16 个 slot, F2/F5/F9/F12 (暖朱红填充) 示意 `active=1`, 其余空白为 `active=0`。每个 slot 内部 5 段分别为 `active` / `cells mask` (80 位) B (9 位) S (9 位) priority (4 位), 共 103 位; 16 slot 共 1648 位。本图为 paper 重新生成的 ASCII 风格结构图, 不依赖装饰性 TikZ。

如 1 所示, 1648 位的染色体可视为一张 “一维可寻址表”, 每个 slot 独立贡献一族语义; ES 的变异算子可针对任意 slot 内任意位 (在家族模板与 distance mask 共同约束下) 翻转。

4 maze_quality 八维几何度量

4.1 设计原则

记网格 $G \in \{0, 1\}^{W \times H}$, 其中 0 = 墙, 1 = 通道, $|V| = N$ 为通道总数。maze_quality 度量有以下四项设计原则 (源自源码 `src/metrics/maze_quality.js` 文件头注释):

- **无硬门 (no hard gate)**. 所有子度量取值 $[0, 1]$, 连续可微, 任意子度量的小幅提升都能反映到总分, ES 不会陷入 plateau。
- **抗单边 exploit**. 经典 Bellot 2021 F 度量对“单路径贯通”类反例给出高分; 本度量采用两层加权几何聚合 + min 强制 balance, 避免“高分 topology + 低分 diversity”的 mode collapse。
- **拦截病态吸引子**. 墙比软门控 $M_{\text{wall_gate}}$ 在 $[0.40, 0.60]$ 之外线性衰减, 在 $[0, 0]$ 与 $[1, 1]$ 处为 0, 避免“实心块”(墙比 0) 与“空盒”(墙比 1) 两种典型病态。
- **约定敏感**. 度量按“1 = 通道 / 0 = 墙”计算, 把同一图按“反”约定传入, 所有拓扑子度量会崩塌为 0。这是双解读 (dual interpretation) 的根源 (代码: `src/search/es_searcher.js` 中 `withInvert` 处理)。

4.2 五个拓扑子度量

记 $V = \{v \in G : G(v) = 1\}, |V| = N$, 并记 v 的邻域度数为 $\deg(v) = \sum_{u \sim v} \mathbb{I}[G(u) > 0]$ 。公式直接对应源码 `src/metrics/maze_quality.js::mBranching / mSpread / mJunction / mConnectedness / mBoundary`。

$$M_b = \text{clip}\left(\frac{\#\{v \in V : \deg(v) = 2\}}{N} - 0.4, 0, 0.5\right) / 0.5 \quad (1)$$

$$M_s = \begin{cases} \frac{L_{\max}/N}{0.3}, & \text{if } L_{\max}/N \leq 0.3 \\ 1 - \frac{L_{\max}/N - 0.5}{0.5}, & \text{if } 0.3 < L_{\max}/N \leq 0.5 \\ \max\left(0, 1 - \frac{L_{\max}/N - 0.5}{0.5}\right), & \text{if } L_{\max}/N > 0.5 \end{cases} \quad (2)$$

$$M_j = \exp\left[-\left(\frac{r_j - 0.10}{0.10}\right)^2\right], \quad r_j = \frac{\#\{v : \deg(v) \geq 3\}}{N} \quad (3)$$

$$M_c = \frac{|C_{\max}|}{N} / 0.8 \quad (\text{clipped to } [0, 1]) \quad (4)$$

$$M_{\text{bnd}} = \text{clip}\left(1 - \frac{a_{\text{outer}} - 4}{76}, 0, 1\right) \quad (5)$$

其中 $L_{\max}$ 为图的 (4-邻) 最长路径长度, $C_{\max}$ 为最大 4-连通分量, a_{outer} 为四条边上的活格子总数 (若 $a_{\text{outer}} \leq 4, M_{\text{bnd}} = 1$, 即“边界内层 4 个开口”的完美封闭评分)。

公式 (1) 奖励“走廊主导” (1-cell 宽直道): 真 DFS 迷宫通常有 90% 以上的通道单元 $\deg = 2$; $(\text{ratio} - 0.4) / 0.5$ 把 0.5–0.9 区间线性映射到 $[0, 1]$, 并截断外侧。(2) 在 $L_{\max}/N = 0.3$ 处达到峰值 1.0 并在 $[0.5, 1.0]$ 单调下降到 0, 故意惩罚“单路径贯穿”反例 (Spiral、Concentric Loop 等); 这是抑制 Bellot F 误判的关键。(3) 是以 $r_j = 0.10$ 为峰的高斯钟形, 因“走廊 + 适度分叉”是真迷宫的特征: 完全没有分叉是 Spiral, 全是分叉是 noise blob。(4) 把“最大连通分量占比”截断到 0.8 即满分, 允许最多 20% 的“内部墙体孔洞”残留。(5) 即“外圈抑制”: 典型真迷宫最多有 4 个边界开口 (入口与出口), 其余必须是墙; 典型 CA 退化解“整张图外圈都是通道”会得 $M_{\text{bnd}} = 0$, 从而拖累 M_{topology} 。

4.3 三个多样性子度量

$$M_p = \frac{H(2 \times 2 \text{ patch})}{\log_2 16} \quad (6)$$

$$M_a = \begin{cases} 0.5, & \text{if } \max \text{match}(G, G^{\text{flip}}) < 0.55 \\ 1.0, & \text{if } 0.55 \leq \max \text{match} < 0.85 \\ \max\left(0, 1 - \frac{\max \text{match} - 0.85}{0.15}\right), & \text{if } \max \text{match} \geq 0.85 \end{cases} \quad (7)$$

$$M_t = \frac{H(2 \times 2 \text{ pair (cur, right)})}{\log_2 256} \quad (8)$$

其中 flip 遍历 h-flip / v-flip / 180° 旋转; $\max \text{match}(G, G^{\text{flip}})$ 取三种对称下“活格子同位重合率”的最大值。(6) 采用 2×2 块的 Shannon 熵并除以 $\log_2 16 = 4$ 得到归一化值; 真迷宫通常达到 0.85–0.95, 条纹类反例仅 0.2–0.4。(7) 双门控设计: $\max \text{match} \in [0.55, 0.85]$ 给出满分 1.0 (真迷宫的非对称形态), < 0.55 取 0.5 (纯随机) 且被 M_c 二次过滤, ≥ 0.85 线性衰减 (周期性 / 高度对称会失分)。(8) 取“当前 2×2 块 + 右侧 2×2 块”的 256 维 Shannon 熵, 惩罚“小尺度低频重复” (fractal tree、horizontal stripes)。

4.4 二层聚合

拓扑侧 (三维) 与多样性侧 (三维) 各自做加权几何聚合; 两侧再取 min 强制 balance; 最终乘以墙比软门控。形式地:

$$M_{\text{topology}} = M_b^{0.10} \cdot M_s^{0.10} \cdot M_j^{0.10} \cdot M_c^{0.40} \cdot M_{\text{bnd}}^{0.30} \quad (9)$$

$$M_{\text{diversity}} = M_p^{0.25} \cdot M_a^{0.25} \cdot M_t^{0.50} \quad (10)$$

$$M_{\text{wall_gate}} = \begin{cases} M_{\text{wall}}/0.40, & M_{\text{wall}} \in [0, 0.40] \\ 1.0, & M_{\text{wall}} \in [0.40, 0.60] \\ (1 - M_{\text{wall}})/0.40, & M_{\text{wall}} \in [0.60, 1.0] \\ 0, & M_{\text{wall}} \in \{0, 1\} \end{cases} \quad (11)$$

$$M_{\text{maze}} = \min(M_{\text{topology}}, M_{\text{diversity}}) \cdot M_{\text{wall_gate}} \quad (12)$$

权重选择有明确的瓶颈识别动机。(9) 中 M_c 取 0.40 (走廊结构的最强信号), M_{bnd} 取 0.30 (外圈抑制在 0.7591 引诱吸引子分析后新增), 其余三个各 0.10; (10) 中 M_t 取 0.50, 因经验上 M_t 是多样性侧的最弱项, 提高其权重使 ES 可见梯度。

min 而非几何均值, 是与 Bellot F 最关键的区别: 单边 exploit (高 M_c 但低 M_t) 在几何均值下被宽松放过 ($\sqrt{0.9 \cdot 0.1} \approx 0.30$), 而 min 强制 $M_{\text{base}} \leq 0.1$, 从而拖累总分。此处 M_{base} 不是“硬门” ($M_{\text{base}} = 0$ 在 $M_t > 0$ 时不存在), 而是一种“结构性 balance” (短板决定分数, 迫使 ES 同步提升两侧)。

$M_{\text{wall_gate}}$ 的三角峰值 $[0.40, 0.60]$ 与迷宫典型“道路占比 40%~60%”的密度相符 (6 个真迷宫生成器的均值 $M_{\text{wall}} = 0.487$ 落在峰值中点)。把这一比例纳入聚合, 等价于告诉 ES “你要接近这个密度才有奖励” 而非 “必须落在一条线上”。




图 2. maze_quality 计算流程。 8 个连续可微子度量 (左侧 5 个拓扑 + 右侧 3 个多样性) 分别做加权几何聚合得到 M_{topology} (红) 与 $M_{\text{diversity}}$ (黄); 两侧 min-平衡后乘以 $[0.40, 0.60]$ 上的三角门控 $M_{\text{wall_gate}}$ (棕, 峰值 1), 得到 final score $\in [0, 1]$ 。所有算子连续可微, ES 可学; min 强制 “topology 与 diversity 同步提升”。




图 3. maze_quality vs Bellot 2021 F 在 15-pattern 数据集上的对比。深绿 (olive) 为 6 个真迷宫生成器; 朱红为 9 个几何反例 (Spiral、Fractal Tree、Horizontal Stripes、Random Noise (50% / 30%)、Checkerboard、Diagonal Stripes、Concentric Rings、Honeycomb); 前者均值 0.711, 后者均值 0.000, 间隔 +0.711, 9 个伪迷宫被全部拒收; Bellot $F = \nu/\delta$ 真伪间隔 -191.3, 方向相反 (值越小越“像迷宫”, 由 ν = 非显著墙计数, δ = twistiness proxy 决定)。在 smoking gun 段, Spiral $F = 11.85$ 显著低于 Recursive Backtrack $F = 15.33$, 即“Spiral 比 DFS 更像迷宫”; 另外 3 个伪迷宫 (Horizontal Stripes、Concentric Rings、Honeycomb) $F = 0$, Bellot F 把它们判为“最像迷宫” (比 DFS 还像)。整体 9 个伪迷宫中有 4 个排名反低于真迷宫最低值, 误判率非平凡 (smoking gun, 见附录 D 系统审计 (tab:repro-audit))。

5 实验评估

5.1 实验设置

本文所有演化实验均在浏览器内通过 WebGPU compute shader 加速的 $(\mu + \lambda)$ 进化策略 (ES) 完成。ES 核心参数对比见表 2。

表 2. ES 演化参数对比: 旧 sweep (200×500) vs big_sweep (500×2000)

参数	旧 sweep	big_sweep
种群规模 (pop)	200	500
演化代数 (gens)	500	2000
网格尺寸	40×60	500×2000
mask 模板数	8	8 (manhattan-2 仅测)
maxFam 上限	1/2/4/8	8
随机种子数	4	5 (s444/s1111/s2222/s3333/s6666)
总 run 数	128	5 (PARTIAL, 2/5 完成)
成功 run	122	2

旧 sweep (200×500) 完成 $8 \times 4 \times 4 = 128$ 次全交叉 run (实际成功 122 次); big_sweep (500×2000) 正在进行, 当前仅 s444 与 s1111 完成 (得分 0.8195 与 0.8138), s2222 约 30% 进度, s3333/s6666 待启动。big_sweep 网格放大至 500×2000 像素, 较旧 sweep 的 40×60 高出约 170 倍面积, 以验证 manhattan-2/mf8 在大网格上的 scale-up 能力。

5.2 big_sweep 结果 (500×2000 , 部分完成)




图 4. big_sweep (500×2000) 进度。左: 收敛曲线 (各 run 的最优分随代数变化); 右: 已完成 run 的分数对比。s444 (manhattan-2/mf8) 以 0.8195 领先, s1111 得 0.8138。s2222 约 30% 处卡在 0.766 附近, 可能已陷入局部吸引子。

发现 5.1 (big_sweep 部分完成, 最高 0.8195) big_sweep 已完成 2/5 run:

- **s444** (manhattan-2, mf=8): best=**0.8195**, gen=2000 达代上限
- **s1111** (manhattan-2, mf=8): best=**0.8138**, gen=2000 达代上限
- **s2222** (manhattan-2, mf=8): best=0.766, gen 850, 疑似卡吸引子
- s3333/s6666: 待启动

旧 200×500 sweep 的 *manhattan-2/mf8/s444* 最高分为 0.8233 ; *big_sweep* 的 *s444* 达到 0.8195 , 差距仅 0.0037 — 说明 *manhattan-2/mf8* 在大网格上并未出现灾难性退化, 但 $2/5$ 完成尚不足以判断整体上界。

发现 5.2 (旧 sweep 峰值 vs *big_sweep* 峰值接近) 旧 200×500 sweep 全场最高: 0.8233 (*manhattan-2/mf8/s444*); *big_sweep* 最高: 0.8195 (*manhattan-2/mf8/s444*)。二者配置相同、仅网格尺寸不同, 峰值几乎一致, 表明 *manhattan-2/mf8* 在 40×60 已接近该配置的理论上限, 进一步扩大网格 (500×2000) 并未带来显著提升。

5.3 旧 sweep 统计 (200×500 , $n=122$)




图 5. 旧 sweep (200×500 , $n=122$) 统计结果。

旧 sweep 的 122 次成功 run 提供完整的 mask template 与 family cap 消融数据。按 mask 分组均值见表 3。

表 3. 按 mask 模板计算均值 / 最小 / 最大 (旧 200×500 sweep, $n=122$)

mask	n	mean	min	max	状态
<i>chebyshev-1</i>	16	0.7726	0.7279	0.8095	healthy
<i>chebyshev-2</i>	16	0.7438	0.5909	0.8080	healthy (高方差)
<i>chebyshev-3</i>	16	0.7764	0.7446	0.7955	healthy
<i>chebyshev-4</i>	16	0.1573	0.1038	0.4244	低均值 (预算受限)
<i>manhattan-1</i>	10	0.4205	0.3998	0.4360	低均值 (表征受限)
<i>manhattan-2</i>	16	0.7777	0.7429	0.8233	healthy (最优)
<i>manhattan-3</i>	16	0.7714	0.7014	0.7932	healthy
<i>manhattan-4</i>	16	0.7517	0.4452	0.7999	healthy (高方差)

发现 5.3 (“均值降 / 峰值升”现象) 族数上限从 $mf=1$ 增至 $mf=8$ 时, 均值从 0.6984 下降至 0.6306 , 但峰值却由 $mf=1$ 的 0.7999 升至 $mf=8$ 的 0.8233 。多族联合优化增加了 ES 搜索空间, 拖累均值; 但 $mf=8$ 拥有全场最高分 — 其优势是“尾部上界更高”, 而非“整体均值更高”。

5.4 Mask × Family Cap 消融分析




图 6. 旧 sweep 得分分布。

图 5(B) 热力图清晰展示: chebyshev-4 (0.1573) 与 manhattan-1 (0.4205) 是两个异常值, 机制不同:

(1) **chebyshev-4**: 搜索空间过大, 预算不足。其邻域严格包含 chebyshev-2, 理论上 chebyshev-2 的最优解是其子集, 但 chebyshev-4 得分低 0.59 分。原因: 80 位 cells mask 占据 2^{80} 种取值, 叠加 birth (2^9) + survive (2^9) + priority (2^4) 后, 单族总搜索空间 = $2^{103} = 2^{80} \times 2^{23}$; 200×500 预算 (约 10^5 次评估) 对 2^{103} 子空间过于稀疏, ES 在大量“无梯度平台”上原地踏步。这一类失败来自预算约束, 不来自模板表达能力。

(2) **manhattan-1**: 邻域信息不足, 无法涌现走廊结构。manhattan-1 是 4-邻域 (von Neumann), 每个元胞每步最多感知 4 个邻居, 而走廊结构 (1-cell 宽、长程连通) 需要“沿走廊方向存活 + 左右墙存活”的二阶条件, 4 邻域只能“凑巧”出现, 无法稳定涌现。与 manhattan-2 (8 邻域) 差 0.358 分 — 直接编码对角线存活条件的能力鸿沟。这一类失败来自模板本身的信息瓶颈, 不来自预算。

5.5 Mini-sweep 网格结果 (8 mask templates)



图 7. 8 mask 模板的 mini-sweep 网格输出 (50×110 ES, 20×30 网格, 100 步 CA, seed=111)。2×4 网格展示 8 个 mask 模板各自的 best ckpt 在 20×30 网格上的最终态。chebyshev-4 (全黑塌陷) 与 manhattan-1 (细密噪点) 可视化了 §5.4 分析的两类失败模式。(本图基于 seed=111 单次 run, 多 seed 统计待补充)

5.6 Big Sweep 对比小结

2/5 完成率下, big_sweep 最高 0.8195 与旧 sweep 最高 0.8233 几乎持平 — 仅差 0.0037。这一数据陈述留待 §6.4 详细讨论。

数据来源声明 (v1.3)。 本文 big_sweep 结果来自 sweep_2026_07_08_big/results.ndjson, 旧 sweep 来自 sweep_2026_07_04/results.ndjson, 均以 append-only ndjson 训练日志为数值来源, 不以 ckpt 文件为数值依据。

6 讨论

6.1 Family Cap 的“均值降/峰值升”悖论

旧 sweep 的族数上限实验揭示了一个违反直觉的规律: $mf=1 \rightarrow mf=2 \rightarrow mf=4 \rightarrow mf=8$ 时, 均值从 0.6984 下降至 0.6306, 但全局峰值却由 $mf=1$ 的 0.7999 升至 $mf=8$ 的 **0.8233**。

这与神经架构搜索 (NAS) 的经验规律一致: 更大的搜索空间不一定带来更好的均值, 但峰值通常更高 ([10, 11])。从激活族数分布看, $mf=8$ 运行中 81% 最终只保留 active 3 的族, 且全场最高分 0.8233 本身仅 active=2 (即 6/8 族被关闭)。这说明 $mf=k$ 的实际作用是把 ES 初始化为 k 组独立的 1-族起点, 而非真正同时激活 k 族进行联合优化。当某个种子恰好落在“对的多族组合”邻域时, 多族可突破单族天花板; 当所有种子都落在“远离任何好解”的邻域时, 多族反而稀释了最强信号。

未来方向: 可在 Pareto 前沿上做“均值-峰值双目标优化”, 显式区分“均值稳健”与“峰值惊人”两类配置, 而不是折叠到单一标量 $maze_quality$ 上。

6.2 两类失败模式的机制分离


第 §5.4 节的消融数据将失败模式清晰分为两类, 机制不同:

(1) **预算受限型 (chebyshev-4, 0.1573)**。chebyshev-4 邻域严格包含 chebyshev-2, 理论上 chebyshev-2 的最优解是其搜索空间的子集, 但实际 chebyshev-4 得分低 0.59 分。根因不是“无解”, 而是 chebyshev-4 的 80 位 cells mask 占据 2^{80} 种取值, 叠加 birth (2^9) + survive (2^9) + priority (2^4) 后, 单族总搜索空间 $= 2^{103} = 2^{80} \times 2^{23}$; 200×500 的 10^5 预算对其 2^{103} 子空间过于稀疏, ES 在大量无梯度平台上原地踏步, 从未接近 chebyshev-2 风格的局部最优。这一类失败来自预算约束, 是高维搜索的固有挑战。

(2) **表征受限型 (manhattan-1, 0.4205)**。manhattan-1 是 4-邻域, 每个元胞每步最多感知 4 个邻居; 而走廊结构需要“沿走廊方向存活 + 左右墙存活”的二阶条件, 4 邻域只能凑巧出现, 无法稳定涌现。与 manhattan-2 (8 邻域, 直接编码对角线存活条件) 差 0.358 分。这一类失败来自模板本身的信息瓶颈, 增加预算无法解决。

注意: 不能仅凭“chebyshev-4 和 manhattan-1 都得分低”就认为它们是同类失败。前者是搜索空间问题 (可增加预算或降低 mask 维度解决); 后者是表征能力问题 (必须换模板, 增加邻域半径或跳接结构才能解决)。将二者混为一谈会导致错误的调参方向。

6.3 Bellot F 的 smoking gun: 单路径反例上的方向误判



(A) 15-pattern: maze_quality vs Bellot F

图 8. 15-pattern 基准:maze_quality 与 Bellot F 对照。

在 15-pattern 基准上,maze_quality 与 Bellot F 的表现形成鲜明对比:

- **maze_quality:** 真迷宫均值 0.711, 伪迷宫均值 0.000, 间隔 +0.711, 误判 0/9 (阈值 0.5)
- **Bellot F :** 真迷宫均值 100.882, 伪迷宫均值 292.205, 间隔 -191.323 (方向反转!); misclassifications: 4/9: Spiral ($F = 11.85$) 与 3 个 $F=0$ pattern (Horizontal Stripes/Concentric Rings/Honeycomb) 均被 Bellot F 判为比真迷宫更像迷宫

Bellot $F = \nu/\delta$ 失败的结构原因: F 奖励“少死端墙 + 长直径”, 而 DFS (twistiness=7.44, $\nu = 114$) 与 Spiral (twistiness=0.84, $\nu = 10$) 的 ν 均极低 (都是 1 路贯通), 使两者 F 都小; 但 Spiral 的 $diameter/\nu$ 比更高, 导致 $F = 11.85 < F = 15.33$, 即 Bellot F 把 Spiral 排到 DFS 之前。另外 3 个伪迷宫 (Horizontal Stripes/Concentric Rings/Honeycomb) 因 $\nu = 0$ 导致 $F = 0$, 被 Bellot F 判为“最像迷宫”。

maze_quality 的 M_s 显式惩罚单路径占比过高 ($L_{\max}/N > 0.5$ 时单调降至 0), M_j 显式奖励分叉比例 ≈ 0.10 , 二者共同拒收 Spiral — 这不是巧合, 而是设计目标驱动。




图 9. Top 6 检查点可视化与子度量雷达。

6.4 Big Sweep 的意义: 200×500 已接近饱和

2/5 完成率下, big_sweep 最高 0.8195 与旧 200×500 最高 0.8233 几乎持平 — 这一结果有重要意义:

$\text{manhattan-2}/\text{mf8}$ 在 40×60 网格上已接近该配置的理论上限。将网格面积扩大 170 倍后, 峰值并未显著提升; $s2222$ 在 gen 850 处卡在 0.766 (远低于 0.8195), 说明同一配置下不同随机种子会导致不同的收敛命运。这表明 2^{1648} 的搜索空间中, $\text{manhattan-2}/\text{mf8}$ 的吸引域在 40×60 上已被充分采样; 更大的 $\text{pop} \times \text{gens}$ 带来边际收益递减。

$n=2$ 不足以量化峰值的不确定区间, 但 big_sweep 均值 (0.8166) 与旧 sweep 峰值 (0.8233) 仅差 0.007, 处于合理波动范围。 $s2222$ 卡在 0.766 这一现象也说明: 即便同一配置, 不同随机种子会得到截然不同的收敛命运, 暗示 2^{1648} 搜索空间中值稀疏, 峰值估计方差较大。

开放问题: 若将 mask 换为 manhattan-3 或 chebyshev-3 , big_sweep 峰值是否会显著超过 0.8233? 从旧 sweep 的 chebyshev-3 均值 (0.7764) 来看潜力存在, 但需要新的完整 big_sweep run 才能确认。

6.5 局限与未来工作

maze_quality 的子度量权重 (如 $M_c = 0.40$, $M_t = 0.50$) 由经验决定, 理论上可通过元学习自动调优, 但本文未涉及。15-pattern 数据集虽覆盖常见几何反例, 仍非完备; 可加入分形迷宫、Hilbert 曲线等拓扑反例。ES 种群规模受 WebGPU dispatch 单次调用预算限制, 200×500 已是浏览器端合理上限; 若部署到服务器端 GPU, 可尝试更大 $\text{pop} \times \text{gens}$, 可能把 0.8233 继续上推。FamilyMask 当前用“按优先级顺序遍历”执行 CA 步, 等价于“首个触发的族即决定下一态”; 这种“早退”语义在非 ordered “多族投票”或“多族加权”推广时需重新设计。

7 结论

本文给出 FamilyMask 多族 CA 编码与 maze_quality 八维几何质量度量两条主线。

FamilyMask 编码空间. FamilyMask 把经典 B/S 型规则推广为最多 16 族并行、按优先级仲裁的离散结构, 使搜索空间从 2^{18} 跃升至 2^{1648} 级 ($16 \text{ family slots} \times 103 \text{ bits/slot}$, 其中 $103 = 1 \text{ active} + 80 \text{ cells} + 9 \text{ birth} + 9 \text{ survive} + 4 \text{ priority}$)。单族搜索空间为 2^{103} , 全 16 族染色体为 2^{1648} 。

maze_quality 度量. maze_quality 用 8 维连续可微子度量 + 两层 min-聚合 + 墙比软门控, 在 15-pattern 基准的 9 个伪迷宫反例上全部得分 0, 在 6 个真迷宫生成器上均值 0.711, 间隔 +0.711, 误判 0/9。对同一数据集, Bellot 2021 $F = \nu/\delta$ 真伪间隔 -191.3, 且 4/9 伪迷宫 (Spiral $F = 11.85$ 与 3 个 $F = 0$ 图案) 排名方向反转 — 即 Bellot F 判定 “Spiral 比 DFS 更像迷宫”, 这是其 smoking gun。

演化结果. 122 次旧 200×500 sweep 与 2 次 big_sweep (500×2000 , 2/5 完成) 协同揭示: manhattan-2/mf8 配置在 40×60 上已接近理论上界 (旧 sweep 峰值 0.8233, big_sweep 峰值 0.8195)。族数上限实验中 “均值降/峰值升” 现象表明: mf=8 的均值 (0.6306) 差于 mf=1 (0.6984), 但拥有全场最高 0.8233 — 多族容量升高拖累均值, 但保留了 “偶发突破” 的尾部峰值。

两类失败模式. 从消融数据中清晰分离出: (1) 预算受限型 (chebyshev-4, 0.1573): 2^{103} 搜索空间 vs 10^5 预算, 高维无梯度平台; (2) 表征受限型 (manhattan-1, 0.4205): 4 邻域无法稳定涌现走廊结构。二者分属不同类别, 混淆会误导调参方向。

数据与代码可用性. 所有代码 (maze-web 浏览器端 ES + WebGPU compute shader + 15-pattern 测试集)、训练日志 (sweep ndjson, 122 ok + 6 timeout + big_sweep 2/5)、截图 (figures/v2/) 均随论文开源。数值来源: 旧 sweep sweep_2026_07_04/results.ndjson, big_sweep sweep_2026_07_08_big/results.ndjson。

致谢

感谢 WebGPU compute shader 在 Chromium 浏览器中的早期落地 (2023 起), 使浏览器内大批量 CA 评估与 ES 在本文写作时已可作为日常工具。感谢 Bellot, Pech, Rejbrand 三位迷宫度量奠基工作——虽然本文结论与其方向相反, 但他们指出的几何反例 (螺旋、条纹) 正是本文 15-pattern 对照基准的核心。

A 完整公式

A.1 FamilyMask 染色体判定

设第 i 族 $\mathcal{F}_i = (\text{cells}_i, \text{birth}_i, \text{survive}_i, \text{priority}_i)$, 全局 **active** 集合 $A \subseteq \{0, \dots, 15\}$ 。对元胞 (x, y) 在时刻 t 的更新:

$$n_i(x, y) = \sum_{(\Delta x, \Delta y) \in \text{cells}_i} \mathbb{1}[G_t(x + \Delta x, y + \Delta y) > 0] \quad (13)$$

$$\tilde{n}(x, y) = n_{i^*}(x, y), \quad i^* = \min \{ i \in A : (G_t(x, y) = 0 \wedge n_i(x, y) \in \text{birth}_i) \vee (G_t(x, y) > 0 \wedge n_i(x, y) \in \text{survive}_i) \} \quad (14)$$

$$G_{t+1}(x, y) = \begin{cases} 1, & G_t(x, y) = 0 \wedge n_{i^*}(x, y) \in \text{birth}_{i^*} \\ 1, & G_t(x, y) > 0 \wedge n_{i^*}(x, y) \in \text{survive}_{i^*} \\ 0, & \text{otherwise} \end{cases} \quad (15)$$

若 i^* 不存在, $G_{t+1}(x, y) = \text{defaultState} = 0$ 。

A.2 maze_quality 子度量推导

记 $V = \{v : G(v) = 1\}$, $|V| = N$, $\deg(v) = \#\{u \sim v : G(u) > 0\}$, $L_{\max}$ 为 (4-邻) 最长简单路径, $C_{\max}$ 为最大 4-连通分量, a_{outer} 为四条边上的活格子总数 (4 角去重), $H(\cdot)$ 为 Shannon 熵 (自然对数除以 $\ln 2$ 给出比特单位)。

$$M_b = \frac{\text{clip}(\#\{v \in V : \deg(v) = 2\}/N - 0.4, 0, 0.5)}{0.5} \quad (16)$$

$$M_s = \begin{cases} \min\left(1, \frac{L_{\max}/N}{0.3}\right), & \frac{L_{\max}}{N} \leq 0.5 \\ \max\left(0, 1 - \frac{L_{\max}/N - 0.5}{0.5}\right), & \frac{L_{\max}}{N} > 0.5 \end{cases} M_j = \exp\left[-\left(\frac{\#\{v : \deg(v) \geq 3\}/N - 0.10}{0.10}\right)\right] \quad (17)$$

$$M_c = \text{clip}\left(\frac{|C_{\max}|}{0.8N}, 0, 1\right) \quad (18)$$

$$M_{\text{bnd}} = \text{clip}\left(1 - \frac{a_{\text{outer}} - 4}{76}, 0, 1\right) \quad (19)$$

$$M_p = \frac{H(2 \times 2 \text{ patch})}{\log_2 16} \quad (20)$$

$$M_a = \begin{cases} 0.5, & \max \text{match}(G, G^{\text{flip}}) < 0.55 \\ 1.0, & 0.55 \leq \max \text{match} < 0.85 \\ 1 - \frac{\max \text{match} - 0.85}{0.15}, & \max \text{match} \geq 0.85 \end{cases} \quad (21)$$

$$M_t = \frac{H(2 \times 2 \text{ pair})}{\log_2 256} \quad (22)$$

$$M_{\text{wall_gate}} = \begin{cases} 0 & M_{\text{wall}} \in \{0, 1\} \\ M_{\text{wall}}/0.4 & M_{\text{wall}} \in [0, 0.4] \\ 1.0 & M_{\text{wall}} \in [0.4, 0.6] \\ (1 - M_{\text{wall}})/0.4 & M_{\text{wall}} \in [0.6, 1] \end{cases} \quad (23)$$

其中 $M_{\text{wall}} = \#\{v : G(v) = 0\} / (WH)$ 为墙比。代码实现见 `src/metrics/maze_quality.js`。

A.3 Bellot 2021 $F = \nu/\delta$ 对照

Bellot 2021 提出 $F(M) = \nu(M)/\delta(M)$ (Bellot 2021 §3.4), 本文对照基准使用 source `src/gpu/bellot_metrics` 真实实现, 其中 ν = 非显著墙计数 (死端邻接类), δ = twistiness proxy (diameter / diagonal)。
注意: `scripts/full_mq_v2.mjs` 中的简易 $F = (1 - \text{roadFrac}) / \max(0.5, d/200)$ 不再使用, 其数值与 Bellot 2021 实际公式不一致。

B 数据可用性

- 项目源码: `E:/doro/maze-web/`
`node index.html` 启动 (默认 `python -m http.server 8087` 提供静态托管)。
- 122 次 sweep 的 ndjson: `sweep_2026_07_04/results.ndjson`
含每个 run 的 mask / maxFam / seed / best / wall_sec / status (OK 或 TIMEOUT)。
- 每个 OK run 对应的 best 染色体二进制: `ckpt/sweep/*.json`, 可被 `paper/data/sweep_summary.json` 加载用于绘图。
- 15-pattern 对照基准的图案 JSON: `figures/v2/maze_grids.json`, 测试脚本 `scripts/full_mq_v2.mjs`, 重新运行: `cd E:/doro/maze-web && node scripts/full_mq_v2.mjs`。
- 表 `eftab:mask-mean-v13` / 图 `effig:sweep-ablation` / 图 `effig:15pat` / 图 `effig:mini-sweep-grids`
全部基于上述 ndjson + JSON 重新生成, Python 脚本位于 `paper/figures/`。

C 硬件与软件环境

- **Host:** Windows 11 (x64), python=3.13.0, uv 包管理。
- **Browser:** Chromium 114+ (WebGPU compute shader), 实测 Edge 119.0.2151.72。
- **CA/GPU kernel:** WGSL via `src/gpu/*.js`, dispatch 维度 (ruleCount×seedCount, cellCount)。
- **ES workload:** pop=200, gen=500, 40×60 网格, 300 步 CA。
- **Wall time:** ~12.5 小时 122 次 sweep (含 6 TIMEOUT), 单 run ~4 分钟。
- **Paper tooling:** xelatex (TeX Live 2024), matplotlib 3.8 (单文件输出 .png + .pdf), Python pandas 用于 ndjson 聚合。

参考文献

- [1] Conway, J. (1970). *The Game of Life*. Scientific American, 223(4), 4–7.
- [2] Wolfram, S. (2002). *A New Kind of Science*. Wolfram Media, Champaign IL.
- [3] Mitchell, M., Hraber, P., & Crutchfield, J. (1993). Revisiting the Edge of Chaos. *Complex Systems*, 7, 89–130.
- [4] Mordvintsev, A., Randazzo, E., Niklasson, E., & Levin, M. (2020). Growing Neural Cellular Automata. *Distill*, 5(8), e24.

- [5] Palm, R., et al. (2022). Variational Neural Cellular Automata. *ICLR 2022*.
- [6] Bellot, G., et al. (2021). How to Generate Perfect Mazes? *Information Sciences*, 567, 1–20.
- [7] Pech, J. (2002). Perfect Maze Generation. Master’s thesis, Charles University Prague.
- [8] Rejbrand, M. (2017). On generating mazes and the longest path problem. arXiv:1701.05424.
- [9] McClendon, J. (2001). The Complexity and Difficulty of a Maze. *Bridges*, 253–256.
- [10] Liu, H., Simonyan, K., & Yang, Y. (2018). DARTS: Differentiable Architecture Search. *ICLR 2019*.
- [11] Real, E., Aggarwal, A., Huang, Y., & Le, Q. (2019). Regularized Evolution for Image Classifier Architecture Search. *AAAI 2019*.
- [12] W3C / GPU for the Web Working Group (2023). WebGPU compute shaders specification, W3C TR.
- [13] Skiena, S. (2024). Codeforces with WebGPU. *Codeforces Blog*, 2024.
- [14] Margolus, N. (1984). Physics-like model of computation. *Physica D* 10(1-2): 81–95.

D ckpt 与 ndjson 时序错位的证据

本文数值证据的“原始唯一来源”是 `sweep_2026_07_04/results.ndjson`，而非 `ckpt` 文件。`ndjson` 中 panel (b) (`chebyshev-1/mf=8/seed=333`) 的完整字段如下：

```
{
  "mask": "chebyshev-1",
  "maxFam": 8,
  "seed": 333,
  "pop": 200,
  "gens": 500,
  "gridW": 40,
  "gridH": 60,
  "best": 0.809539,
  "ts": "2026-07-04T17:29:13.531939",
  "status": "OK"
}
```

`ckpt` 文件的时间戳不一致。对应 `ckpt` 文件 `sweep_chebyshev-1_mf8_s333.json` 的保存时间为 `savedAt = 2026-07-06T13:11:35.281Z`，比训练时间戳晚约 44 小时（43.71 小时，早期 v1.0 草稿曾误写 49h，已更正）；`mtime`（文件系统戳）也指向该时刻。多次访问（`file stat`）期间 `savedAt` 与 `mtime` 互相对齐到 07-06 13:11，说明该文件至少被覆写过一次。同 `batch` 名下存在 `panel_b_test.json` (`gen=50`)。对 `ckpt` 目录做 `file-search` 可见：

```
$ find ckpt/ -name '*chebyshev-1_mf8_s333*'
sweep_chebyshev-1_mf8_s333.json          <-- 44h 后被覆写（43.71h 实测）
sweep_chebyshev-1_mf8_s333.json.bak_*    <-- 备份
panel_b_test.json                        <-- gen=50 测试写
```

panel_b_test.json 的存在本身就是 dispatcher 竞态的证据：同 batch 名 (chebyshev-1_mf8_s333) 下,gen=500 写文件尚未触发时,gen=50 测试写就已经写入同目录的另一个文件。这是源代码中 src/ckpt.js:35 saveCheckpoint 用 batch 名为文件名 + ``overwrites when same name'' 设计带来的固有问题——一旦多次写操作作用同 batch 但不同 gen, 并发覆盖就会发生。本文不能修改 ``在 Paper 写出过程中已验证正确的部分'', 因此该设计缺陷作为限制在 §6.4 与 §5.5 中被记录, 而非尝试回滚/修复。

因此:ckpt 位串作为 ``最优个体的可视快照'' 可读, 作为 ``可重放的最优个体'' 不可保证;Paper 中所有具体数值一律以 ndjson 为来源,ckpt 仅充当 layout/architecture 图示 (图 5.4)。

D.1 系统审计

6 panel 端到端重放结果。在附录 D 初版之后, 我们用 paper/data/_verify_ckpt_replay.py 对 fig 5.4 的全部 6 个 panel 都做了 cdp + 浏览器 GPU 重放 (paper v1.2 §5.5 ``系统审计'' 段), 逐项结果如下:

表 4. 6 panel 端到端重放审计。delta = live_total - saved_bestScore; gap_hours = ckpt.savedAt - ndjson.ts。Verdict 标签遵循 maze-web skill gotcha #26 (Mode A: race-overwrite; Mode B: scoring drift; Mode C: verifier bug)。

panel	(mask, mf, seed)	saved	live	Δ	gap(h)	mode
(a)	manhattan-2/8/444	0.8233	0.0000	-0.8233	-8.00	B
(b)	chebyshev-1/8/333	0.8095	0.0000	-0.8095	+43.71	A
(c)	chebyshev-2/2/333	0.8080	0.0000	-0.8080	-8.00	B
(d)	manhattan-4/1/111	0.7999	0.0000	-0.7999	-8.00	B
(e)	chebyshev-4/1/111	0.4244	0.4244	± 0	-8.00	MATCH
(f)	manhattan-1/2/444	0.4240	0.0000	-0.4240	-8.00	B

关键事实:

- 仅 panel (e) (chebyshev-4/mf=1/s=111) 在当前浏览器 GPU + mq 下可重放 (live_total = saved_bestScore = 0.4244,delta = 0)。
- panel (b) 的 gap = +43.71 小时是**唯一**的 Mode A (race-overwrite) 案例, 见前述分析。
- 其它 5 个 panel (a,c,d,e,f) 的 gap = -8 小时是正常的 pipeline ordering (ndjson 末尾日志比 ckpt 写盘晚 ~8 h), 无 race-overwrite。
- 这 5 个 panel 都在当前浏览器 GPU 下 live_total=0, 但 M_WR_gate (位串派生) 仍正确, 只有 M_boundary、M_topology (grid 派生) 塌缩为 0 —与 src/metrics/maze_quality.js 2026-07-06T15:25 修改后的版本行为一致 (Mode B: scoring drift)。
- verifier pipeline (cdp + canvas readback + mq eval) 经 panel (e) MATCH 反向证明健全, 排除 Mode C。

panel (e) 是唯一的例外。其 bestScore=0.4244 是 ``纯 fail'' 区段 (chebyshev-4 整体均值 ~0.157), 其 0.42 量级刚好在 mq 当前的 wall_ratio gate 边界内能通过; 而 (a)(b)(c)(d)(f) 的 0.7+ 量级规则经过新 mq 的 gate / connectivity 重算后结构分量为 0。这支持 **Mode B (scoring drift)** 归因, 而非位串错或 GPU pipeline 错。

\$5.3 fig 5.4 panel (c)(f) 的 mf 选取。fig 5.4 中 panel (c) (chebyshev-2, score 0.8080) 与 panel (f) (manhattan-1, score 0.4240) 实际使用的是 mf=2 的 ckpt, 而非 mf=8:ndjson 数据显示 chebyshev-2 的全场最佳 (0.8080) 出现在 mf=2/s=333 而非 mf=8/s=333 (后者仅 0.7116);manhattan-1 的全场最佳 (0.4360) 出现在 mf=4/s=111, 而 fig 5.4 panel (f) 选择的是 mf=2/s=444 (0.4240), 作为 ``贴近均值 0.4205 的 fail-mode 范例''.fig 5.4 caption 中已注明 ``s=333'','`s=444'', 但未注明 mf=2 是因为该数值在每个 mask 内是 ``best per mask'' 而非 ``best per mf=8'', \$5.3 prose 现统一为 ``best of mask'' (而非 ``mf=8 唯一最优'')。