

FamilyMask 多族 CA 编码与 maze_quality 度量

在浏览器内用进化策略搜索迷宫生成的元胞自动机规则

FamilyMask multi-family CA chromosome and maze_quality:
evolving cellular-automaton maze rules in the browser

sko (冯卓源)*

2026-07-08 (paper v2.1)

摘要

本文解决一个具体的判定问题: 给定一个二值网格 (元胞自动机运行结果), 如何判断它是否构成一个迷宫? 这个判断并非一目了然, 因为 Conway 生命游戏的演化常常产生“看起来像迷宫, 实际不是”的吸引子 (实心块、空盒、规则条纹、随机噪声), 而“真迷宫”又有走廊结构、稀疏分叉、外圈封闭等拓扑约束。**FamilyMask 多族 CA 编码。**把经典 B/S 型规则推广为最多 16 族并行、按优先级仲裁的染色体: 每族独立持有自己的 9×9 邻域 mask (去掉中心 80 格)、出生集、存活集与优先级; CA 每步按优先级遍历 active 族, 首个匹配的族决定下一态。单族时退化为标准 B/S (2^{18} 候选), 多族时搜索空间跃升至 2^{103} 单族 / 2^{1648} 全染色体级 ($16 \text{ slot} \times 103 \text{ bits/slot}$, $103 = 1 \text{ active} + 80 \text{ cells} + 9 \text{ B} + 9 \text{ S} + 4 \text{ priority}$)。

maze_quality 八维几何度量。在 $\min(M_{\text{topology}}, M_{\text{diversity}}) \cdot M_{\text{wall_gate}}$ 的两层结构上聚合 8 个连续可微子度量: 5 个拓扑 (M_b 走廊主导度、 M_s 最长路径占比、 M_j 十字口占比、 M_c 最大连通占比、 M_{bnd} 外圈抑制) + 3 个多样性 (M_p 2×2 块熵、 M_a 镜像不对称度、 M_t 2×2 邻接对熵)。所有取值 $[0, 1]$, ES 可学; $\min$ 而非几何均值强制两侧平衡, 三角墙比门控 $M_{\text{wall_gate}}$ 拦截“实心块 / 空盒”病态吸引子。**v2.1 权重:** 5 个拓扑子度量加权几何聚合采用 $0.20/0.15/0.20/0.30/0.15$ ($M_b/M_s/M_j/M_c/M_{\text{bnd}}$), 是经过多轮实验、结合人眼评判迭代调优的结果, 让“分数排名与视觉评判一致”。 M_c 改为纯线性 (旧版有 /0.8 clip 导致 $M_c \in [0.8, 1.0]$ 全部饱和到 1.0); 旧版权重在 ES 跑出的 4 个真迷宫 ($M_c \in [0.74, 0.98]$) 实际无区分度, 新版下视觉上更接近迷宫形态的 (b) chebyshev-1 ($M_c = 0.98$) 升到榜首, 视觉上走廊感较弱的 (a) manhattan-2 ($M_c = 0.74$) 调整到第三, 完成了“分数排名与视觉评判一致”的关键修复。

15-pattern 对照基准。6 个真迷宫生成器 (DFS / Kruskal / Prim / Growing Tree / Sidewinder / Binary Tree) + 9 个几何反例 (Spiral / Fractal Tree / Horizontal Stripes / Random Noise 50% / Random Noise 30% / Checkerboard / Diagonal Stripes / Concentric Rings / Honeycomb)。**maze_quality** 真迷宫均值 0.711, 伪迷宫均值 0.000, 间隔 +0.711, 误判 0/9。同一数据集上 Bellot 2021 $F = \nu/\delta$ 真伪间隔 -191.3, 方向反转; 9 个伪迷宫中有 4 个 ($F=0$ 的 Horizontal Stripes / Concentric Rings / Honeycomb 加上 $F=11.85$ 的 Spiral) 排名低于真迷宫最低值 ($F=15.33$, DFS), 即 Bellot F 错误判定“Spiral 比 DFS 更像迷宫”。

两个规模的演化扫描。小范围 sweep: 128 次全交叉 ($8 \text{ mask} \times 4 \text{ maxFam} \times 4 \text{ seed}$, 40×60 网格, pop 200, gens 500), 122 次 OK, 最高分 0.8233 (manhattan-2 / maxFam=8 / seed=444)。大范围 sweep: 5 次 (manhattan-2 / maxFam=8 单配置, 500×2000 网格, pop 500, gens 2000, 5 随机种子), 5/5 完成, 最高分 0.8195 (seed=444), 5-run 均值 0.8020。两个 sweep 峰值差 0.0037, 表明 manhattan-2 / maxFam=8 在 40×60 网格上已接近该配置的理论上限。

两类失败模式。(1) chebyshev-4 均值 0.157: 9×9 邻域使单族搜索空间 2^{103} , 10^5 预算下 ES 在无梯度平台上原地踏步 — 预算受限型。(2) manhattan-1 均值 0.421: 4 邻域无法为走廊结构提供足够二阶空间上下文 — 表征受限型。二者分属不同类别, 混淆会误导调参方向。

Abstract

We study the problem of deciding whether a binary grid produced by a cellular automaton is a maze. Conway-style CA evolution tends to produce many “looks like a maze, isn’t” attractors (solid blocks, empty boxes, regular stripes, random noise), so the question needs a quantitative answer. Two contributions.

FamilyMask generalises Conway B/S rules to a multi-family chromosome. Up to 16 families run in parallel; each family owns its 9×9 neighbourhood mask (the centred footprint minus the centre, 80 cells),

*maze-web 项目作者与维护者, 所有实验数据、源码、复现脚本与本文 PDF 均开源。

birth set, survival set, and 4-bit priority. The CA scans active families in priority order each step; the first match decides the next cell. With one active family the rule space is the standard B/S string (2^{18}); with k active families it jumps to 2^{103} per family and 2^{1648} for the full 16-slot chromosome.

maze_quality is an eight-dimensional geometric score. Five topology sub-metrics (corridor dominance M_b , longest-path share M_s , junction share M_j , largest-component share M_c , outer-frame suppression M_{bnd}) form M_{topology} via weighted geometric mean. Three diversity sub-metrics (2×2 patch entropy M_p , mirror asymmetry M_a , 2×2 adjacency-pair entropy M_t) form $M_{\text{diversity}}$. The two sides are combined with min, then multiplied by a triangular wall-ratio gate $M_{\text{wall_gate}}$ on $[0.40, 0.60]$ that zeroes out solid blocks and empty boxes. All eight sub-metrics are continuous in $[0, 1]$, so evolution strategies can use them directly. The min (rather than geometric mean) is what blocks the failure mode where one side is high and the other is low. **v2.1 weights:** the five topology weights are (0.20, 0.15, 0.20, 0.30, 0.15) for ($M_b, M_s, M_j, M_c, M_{\text{bnd}}$), refined through multiple experimental rounds with human visual judgment as the ground truth, and M_c is now linear (a previous /0.8 clip saturated $M_c \in [0.8, 1.0]$ to 1.0, killing the dimension’s gradient). The new weights restore the visual-consistency invariant: chebyshev-1 (visually the most maze-like, $M_c = 0.98$) takes the top rank, while manhattan-2 ($M_c = 0.74$) drops to third, aligning the score ranking with the authors’ visual assessment.

15-pattern benchmark. Six classical maze generators (DFS, Kruskal, Prim, Growing Tree, Sidewinder, Binary Tree) and nine non-maze attractors (Spiral, Fractal Tree, Horizontal Stripes, Random Noise at 30% and 50%, Checkerboard, Diagonal Stripes, Concentric Rings, Honeycomb). *maze_quality* gives 0.711 on the true mazes and 0.000 on the pseudo-mazes, with zero misclassifications of the nine pseudo-patterns. The Bellot 2021 $F = \nu/\delta$ score on the same dataset has gap -191.3 and the wrong sign (“lower is more maze-like”), and four of nine pseudo-mazes (Spiral at $F=11.85$ plus three $F=0$ patterns) rank below the genuine DFS ($F=15.33$). That direction reversal is the smoking gun that motivates *maze_quality*.

Two scales of evolution sweeps. Small sweep: 128 full-factorial runs ($8 \text{ masks} \times 4 \text{ maxFam} \times 4 \text{ seeds}$, 40×60 grid, pop 200, gens 500), 122 OK, top score 0.8233 (manhattan-2, maxFam=8, seed 444). Large sweep: 5 runs (manhattan-2/maxFam=8 only, 500×2000 grid, pop 500, gens 2000, 5 random seeds), all 5 complete, top 0.8195 (seed 444), 5-run mean 0.8020. The two tops differ by 0.0037, so the 40×60 configuration is already near the configuration’s theoretical ceiling.

Two failure modes —and a clean diagnostic that distinguishes them. chebyshev-4 reaches mean 0.157 because its 9×9 neighbourhood gives a 2^{103} per-family space, and 10^5 evaluations are too sparse to escape the gradientless plateau (budget-limited failure, solvable by raising budget or shrinking the mask). manhattan-1 reaches 0.421 because 4-neighbour topology cannot sustain the second-order survival conditions that corridors need (representation-limited failure, requires a different template). Separating these two categories prevents wasted tuning effort in the wrong direction, and is one of the paper’s methodological contributions.

All code, data, figures, and the 15-pattern benchmark dataset are released as open source.

Contents

1 引言	4
1.1 问题: 元胞自动机生成的是迷宫吗?	4
1.2 已有工作的两个空缺	4
1.3 本文贡献	4
1.4 全文结构	4
2 相关工作	4
2.1 元胞自动机与迷宫	4
2.2 迷宫生成算法	5
2.3 几何度量	5
2.4 WebGPU compute shader	5
2.5 本文与已有工作的关系	5
3 FamilyMask 多族 CA 编码	5
3.1 设计动机	5
3.2 染色体结构	5
3.3 执行语义	6
3.4 搜索空间	6
3.5 实现	6
4 maze_quality 度量	7
4.1 问题与设计原则	7
4.2 五个拓扑子度量	7
4.3 三个多样性子度量	8
4.4 两层聚合	8
4.5 15-pattern 对照基准	9
4.6 maze_quality 与 Bellot F 的方向反转	12
5 实验评估	12
5.1 实验设置	12
5.2 大范围 sweep 5 个随机种子结果	13
5.3 小范围 sweep 全部 122 次 run	14
5.4 ES 跑出来的高分迷宫与重点特征分析	15
5.5 小范围 vs 大范围对比	16
5.6 数据来源声明	16
6 讨论	16
6.1 Family Cap 的“均值降 / 峰值升” Pareto 前沿	16
6.2 两类瓶颈机制的清晰分离	16
6.3 大范围 sweep 的含义: 40×60 网格上的性能上界	17
6.4 未来工作	17
7 结论	17
A 完整公式	18
A.1 FamilyMask 染色体判定 (完整形式)	18
A.2 maze_quality 子度量推导 (展开形式)	18
A.3 Bellot 2021 $F = \nu/\delta$	19
B 数据可用性	19
C 硬件与软件环境	20

1 引言

1.1 问题：元胞自动机生成的是迷宫吗？

元胞自动机 (Cellular Automaton, CA) 是离散动力系统, 用局部更新规则在网格上同步演化。最早被研究的 Conway “生命游戏” 是 B/S 字符串规则: 8 邻域下, 活细胞在 S 集合中邻居数时继续存活, 死细胞在 B 集合中邻居数时复活 [1]。这套规则在二维网格上能产生复杂图样, Wolfram 把它推广为四类动力学 [2]: 均匀, 周期, 混沌, 复杂 (生命游戏属于复杂类)。

CA 与迷宫生成在拓扑结构上很接近: 两者都关心二值网格, 都依赖邻域信息, 都讨论 “局部规则涌现全局结构”。但 CA 的动力学是双向的, 可以把 “看起来像迷宫的图样” 视为 CA 的吸引子。这就引出一个具体的判定问题: 给定一个 CA 终态 (二值网格), 怎么判断它是否构成迷宫?

直觉上, 这个问题应该很简单 — 数一下连通性、看一下走廊就行。但实际上, 至少有四类 CA 吸引子能骗过朴素判别:

- **实心块**. 墙比为 1, 整张图全黑, 拓扑完全退化。
- **空盒**. 墙比为 0, 整张图全白, 同样退化。
- **规则条纹 / 同心环 / 蜂巢**. 高度对称的几何反例, 看上去有结构, 但没有迷宫应有的一格宽走廊。
- **随机噪声**. 50% 密度的随机点能通过 “连通性 $\geq$ 阈值” 的检查, 但分叉过多, 不像迷宫。
要拒收这些反例, 需要一个同时刻画 “走廊结构” 和 “非平凡拓扑” 的度量, 还要在伪迷宫上判别失效。

1.2 已有工作的两个空缺

迷宫生成算法 (DFS [7], Kruskal, Prim, Growing Tree, Sidewinder, Binary Tree) 与 CA 演化都能产生二值网格, 但两者之间缺一个统一的 “是否迷宫” 判别器。Bellot 等人 2021 年提出的 $F = \nu/\delta$ 度量是当前学界常用的对照基线, 但它对 “少死端墙 + 长直径” 的几何反例 (条纹、环、蜂巢) 反而给出高分 [6], 方向反了。

CA 规则搜索的现有工作集中在经典 B/S 字符串 (2^{18} 候选), 用遗传编程或 ES 搜索 “自然涌现迷宫” 的规则 [8, 9], 但搜索空间太小 (B/S 字符串只能产生有限种动力学), 不可能涌现复杂走廊结构。FamilyMask 编码把搜索空间扩大到 2^{1648} , 同时保留 B/S 字符串作为单族退化情形。

1.3 本文贡献

本文给出两个互补的产物:

1. **FamilyMask 多族 CA 染色体**. 把经典 B/S 规则推广为最多 16 族并行、按优先级仲裁的染色体。每族独立持有邻域 mask、出生集、存活集与优先级。搜索空间 2^{103} 单族 / 2^{1648} 全染色体。
2. **maze_quality 八维几何度量**. 5 拓扑 + 3 多样性子度量, 两层加权几何聚合 + min 平衡 + 墙比三角门控, 全部连续可微, ES 可学。在 15-pattern 基准上, 真迷宫均值 0.711, 伪迷宫均值 0.000, 间隔 +0.711, 误判 0/9。同数据集 Bellot 2021 F 间隔 -191.3, 方向反转, 误判 4/9。
3. **两个尺度的演化扫描**. 小范围 (40×60 , 122 OK) 给出完整 (mask, maxFam) 消融数据, 最高分 0.8233 (manhattan-2 / maxFam=8 / seed 444)。大范围 (500×2000 , 5/5 OK) 验证 “同配置, 大网格” 的 scale-up, 最高分 0.8195, 5-run 均值 0.8020。两个 sweep 峰值差 0.0037, 表明小范围已接近该配置的上界。

1.4 全文结构

§2 介绍相关工作 (CA 与迷宫、FamilyMask 类编码、几何度量、ES 搜索)。§3 给出 FamilyMask 染色体的精确描述与执行语义。§4 给出 maze_quality 的 8 个子度量定义与两层聚合, 并在 15-pattern 基准上对比 Bellot 2021 F 。§5 报告两个 sweep 的实验设置、结果与对比。§6 讨论两类失败模式 (预算受限 vs 表征受限) 与大网格 scale-up 的含义。§7 总结。附录 A 给出完整公式; 附录 B 给出数据可用性; 附录 C 给出软硬件环境。

2 相关工作

2.1 元胞自动机与迷宫

Conway 1970 年提出 “生命游戏” 后, CA 在物理、生物学、计算机科学领域被广泛研究 [1]。Wolfram 2002 年的专著把 CA 动力学按行为分成 4 类 [2], 其中 “第 4 类” (复杂类) 包含能产生持久结构与局部混沌的规则。生命游戏属于第 4 类, 但单条 B/S 字符串的搜索空间只有 2^{18} , 涌现迷宫结构的概率极低。

Mitchell, Hraber 与 Crutchfield 1993 年用遗传算法在 2^{18} 的 B/S 字符串空间里搜索“密度稳态”规则 [3], 发现了接近 0.5 密度的边缘动力学。Rejbrand 2017 年的网页笔记记录了用 8 邻域 + 优先级机制涌现迷宫的具体 B/S 组合 [8], 但仍是单族 B/S 字符串的扩展, 不支持族间仲裁。

McClendon 2001 年讨论了迷宫“难度”的形式化定义 (McClendon Difficulty), 用 γ 度量死端墙密度 [9], 但与 Bellot 2021 的 ν 类似, 都是“越像迷宫值越大”的方向, 对几何反例同样失效。

2.2 迷宫生成算法

经典迷宫生成算法 (DFS, Kruskal, Prim, Growing Tree, Sidewinder, Binary Tree) 都能在 $O(n)$ 时间内生成“完美迷宫”(无环, 连通, 任意两点恰好一条路径)。Pech 2002 年的硕士论文是早期综述 [7], 详细比较了不同算法的走廊统计特征。

这些算法是 **真迷宫标签**的来源 — 本文 15-pattern 基准的 6 个 TRUE pattern 都由这些算法生成。

2.3 几何度量

Bellot 等人 2021 年的工作给出了 $F(M) = \nu(M)/\delta(M)$ 形式, 其中 ν 是“非显著墙”(死端邻接类)的计数, δ 是“twistiness proxy”(diameter / diagonal) [6]. 该论文用 9 个非迷宫反例测试 F , 报告“真迷宫值小, 伪迷宫值大”, 方向与直觉相反。本文 §4.4 在 15-pattern 基准上重复这个测试, 复现了 Bellot 论文报告的方向反转, 但同时报告 4/9 误判 (Spiral $F=11.85 + 3$ 个 $F=0$ 图案) 排名低于真迷宫最低值。

神经架构搜索 (NAS) 中, DARTS [10] 与 Regularized Evolution [11] 都观察到“更大搜索空间不一定带来更好均值, 但峰值通常更高”的现象。本文 §6.1 在 (mask, maxFam) 消融中复现了同样的现象 (mf=1 均值 0.6984 高于 mf=8 均值 0.6306, 但 mf=8 拥有全场最高 0.8233)。

2.4 WebGPU compute shader

WebGPU 是 W3C 标准, 2023 年正式发布 compute shader 规范 [12], 允许在浏览器内运行通用 GPU 计算。Skiena 2024 年讨论了 Codeforces 平台用 WebGPU 做大规模评估的实践 [13]. 本文所有 sweep 的 CA 评估都在浏览器 WebGPU compute shader 上完成, 单 run ~ 4 分钟 (40×60) / ~ 50 分钟 (500×2000).

2.5 本文与已有工作的关系

本文与已有工作有 3 个明确的区别:

1. **染色体结构**。已有工作集中在 B/S 字符串 (2^{18} 候选), 本文 FamilyMask 把搜索空间扩展到 2^{1648} 。
2. **度量方向**。Bellot F 是“值越小越像迷宫”(方向反), 本文 *maze_quality* 是“值越大越像迷宫”(方向正), 在 15-pattern 上达到 0/9 误判。
3. **计算平台**。已有 CA 演化工作多在 CPU / 服务器 GPU 上跑, 本文在浏览器内通过 WebGPU compute shader 完成, 单机 0 部署成本。

3 FamilyMask 多族 CA 编码

3.1 设计动机

经典 B/S 字符串把 8 邻域下活细胞和死细胞的“保留 / 翻转”决策压缩成两个 9-bit 集合, 搜索空间 2^{18} . 这个空间太小, 涌现复杂走廊结构 (1-cell 宽、长程连通、适度分叉) 的概率极低。Rejbrand 2017 年的网页笔记 [8] 通过堆叠多个 B/S 字符串 + 优先级机制来扩展空间, 但缺乏形式化的染色体描述。

FamilyMask 把这种“多 B/S 字符串 + 优先级”的想法形式化为一条染色体: 最多 16 族并行, 每族独立持有邻域 mask、出生集、存活集与优先级; CA 每步按优先级遍历 active 族, 首个匹配的族决定下一态。这套结构把搜索空间从 2^{18} 跃升至 2^{1648} ($16 \text{ slot} \times 103 \text{ bits/slot}$), 同时保留单族 B/S 字符串作为退化情形。

3.2 染色体结构

每条染色体由 16 个 **槽 (slot)** 组成, 每个槽对应一族规则 $\mathcal{F}_i = (\text{cells}_i, \text{birth}_i, \text{survive}_i, \text{priority}_i)$, 槽内数据布局为:

- **active** (1 bit): 1 = 启用该族, 0 = 禁用。
- **cells** (80 bits): 邻域 mask, 标记 9×9 中心外 80 格中的“参与决策”格点 (1 = 计入, 0 = 忽略)。
- **birth** (9 bits): 死细胞在邻域中“活邻居数 $\in \text{birth}$ 集合”时复活。9 位对应 8 邻域下活邻居数 $0 \sim 8$ 加上“中心也计入”的 1 位扩展 (兼容“8 邻域 + 中心”与“纯 8 邻域”两种约定)。

- **survive** (9 bits): 同上, 但用于活细胞的存活判定。
- **priority** (4 bits): 0–15 的优先级, 数值小者先匹配。
每槽固定 103 bits (= 1 + 80 + 9 + 9 + 4); 16 槽共 1648 bits。




Figure 1 FamilyMask 染色体结构示意图 (以 8 族 / 16 槽为例)。

上方两行共 16 个 slot, F2/F5/F9/F12 (暖朱红填充) 示意 **active=1**, 其余空白为 **active=0**。每个 slot 内部 5 段分别为 **active** / **cells mask** (80 位) / **B** (9 位) / **S** (9 位) / **priority** (4 位), 共 103 位; 16 slot 共 1648 位。

3.3 执行语义

记网格 $G \in \{0, 1\}^{W \times H}$, $A \subseteq \{0, 1, \dots, 15\}$ 为 active 族集合, cells_i 为族 i 的邻域 mask 集合 (80 个偏移量), birth_i 与 survive_i 分别为 $0 \sim 8$ 的子集加上“中心计入”位。CA 步 $t \rightarrow t+1$ 的更新规则:

$$n_i(x, y) = \sum_{(\Delta x, \Delta y) \in \text{cells}_i} \mathbb{I}[G_t(x + \Delta x, y + \Delta y) > 0] \quad (1)$$

$$i^* = \min \{ i \in A : (G_t(x, y) = 0 \wedge n_i(x, y) \in \text{birth}_i) \vee (G_t(x, y) > 0 \wedge n_i(x, y) \in \text{survive}_i) \} \quad (2)$$

$$G_{t+1}(x, y) = \begin{cases} 1, & G_t(x, y) = 0 \wedge n_{i^*}(x, y) \in \text{birth}_{i^*} \\ 1, & G_t(x, y) > 0 \wedge n_{i^*}(x, y) \in \text{survive}_{i^*} \\ 0, & \text{otherwise} \end{cases} \quad (3)$$

若 i^* 不存在 (即没有 active 族匹配), 元胞 (x, y) 退化为 **defaultState = 0** (墙)。

3.4 搜索空间

单族情形 ($|A| = 1$): 仅 cells mask 的 80 bits 与 B / S 的 9 bits 决定行为, 共 2^{98} 有效组合 (priority 与 “active” 不参与决策); 若进一步约束 cells mask 为 “8 邻域 (去掉中心)”, 退化为 2^{18} 标准 B/S 字符串。

多族情形 ($|A| = k$): 每族独立贡献 2^{103} 搜索空间, 全染色体 2^{1648} 。但 “早期匹配” 语义 ($i^* = \min\{\dots\}$) 使各族实际不独立, 优先级高的族会 “截断” 优先级低的族。

实际可遍历空间介于两者之间: ES 在 2^{1648} 的 “搜索空间大小” 上做随机游走, 但因 “早期匹配” 截断, 有效搜索路径远小于 2^{1648} 。这与神经架构搜索 (NAS) 中的情况类似: 更大的搜索空间不一定带来更好的均值, 但峰值通常更高 (本文 §6.1 在 (mask, maxFam) 消融中复现了这一点)。

3.5 实现

FamilyMask 在浏览器内通过 WebGPU compute shader 加速 CA 评估。每个 cell 的 update (1)–(3) 在 WGSL kernel 中并行执行, dispatch 维度 (ruleCount × seedCount, cellCount)。ES 评估的耗时瓶颈在 n_i 的邻域求和, 80 cells mask 在 40×60 网格上单步需要 ~ 0.1 ms (WebGPU, 主流 GPU)。

4 maze_quality 度量

4.1 问题与设计原则

给定一个 CA 终态 $G \in \{0,1\}^{W \times H}$ ($0 = \text{墙}$, $1 = \text{通道}$, $|V| = N$ 为通道总数), 需要一个标量分数 $M_{\text{maze}} \in [0, 1]$, 越大越像迷宫。maze_quality 度量有以下四项设计原则:

1. **连续可微, 无硬门**. 所有子度量取值 $[0, 1]$, 任意子度量的小幅提升都反映到总分, ES 不会卡在 plateau。
2. **抗单边 exploit**. Bellot 2021 F 度量对“单路径贯通”类反例给出高分; 本度量用两层加权几何聚合 + min 强制 balance, 避免“高分 topology + 低分 diversity”的 mode collapse。
3. **拦截病态吸引子**. 墙比软门控 $M_{\text{wall_gate}}$ 在 $[0.40, 0.60]$ 之外线性衰减, 在 0 与 1 处为 0, 拒收“实心块”(墙比 0) 与“空盒”(墙比 1)。
4. **约定敏感**. 度量按“ $1 = \text{通道} / 0 = \text{墙}$ ”计算, 把同一图按反约定传入, 所有拓扑子度量崩塌为 0。代码用 withInvert 处理双解读 [6] 提到的反约定情形。

4.2 五个拓扑子度量

记 $V = \{v \in G : G(v) = 1\}$, $|V| = N$, v 的邻域度数 $\deg(v) = \sum_{u \sim v} \mathbb{I}[G(u) > 0]$ 。公式直接对应源码 src/metrics/maze_quality.js 中的同名函数:

$$M_b = \text{clip}\left(\frac{\#\{v \in V : \deg(v) = 2\}}{N} - 0.4, 0, 0.5\right) / 0.5 \quad (4)$$

$$M_s = \begin{cases} \frac{L_{\max}/N}{0.3}, & \text{if } L_{\max}/N \leq 0.3 \\ 1 - \frac{L_{\max}/N - 0.5}{0.5}, & \text{if } 0.3 < L_{\max}/N \leq 0.5 \\ \max\left(0, 1 - \frac{L_{\max}/N - 0.5}{0.5}\right), & \text{if } L_{\max}/N > 0.5 \end{cases} \quad (5)$$

$$M_j = \exp\left[-\left(\frac{r_j - 0.10}{0.10}\right)^2\right], \quad r_j = \frac{\#\{v : \deg(v) \geq 3\}}{N} \quad (6)$$

$$M_c = \frac{|C_{\max}|}{N} \quad (\text{linear, no clip}) \quad (7)$$

$$M_{\text{bnd}} = \text{clip}\left(1 - \frac{a_{\text{outer}} - 4}{76}, 0, 1\right) \quad (8)$$

$L_{\max}$ 是 4 邻域下从任意起点出发的最长简单路径长度, $C_{\max}$ 是最大 4 连通分量, a_{outer} 是四条边上的活格子总数 (4 角去重); $a_{\text{outer}} \leq 4$ 时 $M_{\text{bnd}} = 1$, 对应“边界内层 4 个开口”的完美封闭。

每个子度量的设计动机:

- M_b **走廊主导度**. 真 DFS 迷宫通常 90% 以上通道单元 $\deg = 2$; $(\text{ratio} - 0.4)/0.5$ 把 $[0.5, 0.9]$ 区间映射到 $[0, 1]$, 截断外侧。
- M_s **最长路径占比**. 在 $L_{\max}/N = 0.3$ 处达峰值 1.0, 在 $[0.5, 1.0]$ 单调下降到 0, 故意惩罚“单路径贯穿”(Spiral, Concentric Loop)。
- M_j **十字口占比**. 以 $r_j = 0.10$ 为峰的高斯钟形; 完全没有分叉是 Spiral, 全是分叉是 noise blob, $r_j \approx 0.10$ 是“走廊 + 适度分叉”的真迷宫特征。
- M_c **最大连通占比**. v2.1 起改为纯线性 (旧版有 $/0.8 \text{ clip}$, 让 $0.80 \leq M_c \leq 1.0$ 全部饱和到 1.0, 丧失区分度); 现在 $0.92 \mapsto 0.92$, $1.0 \mapsto 1.0$ 。ES 输出大多数 $M_c \in [0.7, 1.0]$, clip 去掉后该维度能提供连续梯度。
- M_{bnd} **外圈抑制**. 典型真迷宫最多 4 个边界开口 (入口与出口); 典型 CA 退化解“整张图外圈都是通道”得 $M_{\text{bnd}} = 0$, 拖累 M_{topology} 。

4.3 三个多样性子度量

$$M_p = \frac{H(2 \times 2 \text{ patch})}{\log_2 16} \quad (9)$$

$$M_a = \begin{cases} 0.5, & \text{if } \max \text{ match}(G, G^{\text{flip}}) < 0.55 \\ 1.0, & \text{if } 0.55 \leq \max \text{ match} < 0.85 \\ \max\left(0, 1 - \frac{\max \text{ match} - 0.85}{0.15}\right), & \text{if } \max \text{ match} \geq 0.85 \end{cases} \quad (10)$$

$$M_t = \frac{H(2 \times 2 \text{ pair (cur, right)})}{\log_2 256} \quad (11)$$

flip 遍历 h-flip / v-flip / 180° 旋转, $\max \text{ match}(G, G^{\text{flip}})$ 取三种对称下“活格子同位重合率”的最大值。 M_p 用 2×2 块 Shannon 熵除以 $\log_2 16 = 4$ 得到归一化值; 真迷宫通常 0.85–0.95, 条纹类反例仅 0.2–0.4。 M_a 是双门控: $\max \text{ match} \in [0.55, 0.85]$ 给出满分 1.0 (真迷宫的非对称形态); < 0.55 取 0.5 (纯随机) 且被 M_c 二次过滤; ≥ 0.85 线性衰减 (周期性 / 高度对称会失分)。 M_t 取“当前 2×2 块 + 右侧 2×2 块”的 256 维 Shannon 熵, 惩罚“小尺度低频重复” (fractal tree, horizontal stripes)。

4.4 两层聚合

拓扑侧 (五维) 与多样性侧 (三维) 各自做加权几何聚合, 两侧再取 min 强制 balance, 最终乘以墙比软门控:

$$M_{\text{topology}} = M_b^{0.20} \cdot M_s^{0.15} \cdot M_j^{0.20} \cdot M_c^{0.30} \cdot M_{\text{bnd}}^{0.15} \quad (12)$$

$$M_{\text{diversity}} = M_p^{0.25} \cdot M_a^{0.25} \cdot M_t^{0.50} \quad (13)$$

$$M_{\text{wall_gate}} = \begin{cases} M_{\text{wall}}/0.40, & M_{\text{wall}} \in [0, 0.40] \\ 1.0, & M_{\text{wall}} \in [0.40, 0.60] \\ (1 - M_{\text{wall}})/0.40, & M_{\text{wall}} \in [0.60, 1.0] \\ 0, & M_{\text{wall}} \in \{0, 1\} \end{cases} \quad (14)$$

$$M_{\text{maze}} = \min(M_{\text{topology}}, M_{\text{diversity}}) \cdot M_{\text{wall_gate}} \quad (15)$$

权重调优过程。当前 5 权重 ($M_b, M_s, M_j, M_c, M_{\text{bnd}}$) = (0.20, 0.15, 0.20, 0.30, 0.15) 并非任意选定, 而是经过多轮实验调优的结果: 我们在每个候选权重集下重跑小范围 sweep, 把 ES top 跑出的迷宫与作者人眼评判对比, 迭代调整直至“排名靠前的迷宫视觉上确实最像迷宫, 排名靠后的确实最不像”。这一过程把人眼作为 ground truth, 避免了“权重与视觉评判不一致”的 mode collapse, 也是本文与 Bellot 2021 F 度量最关键的方法论差异: F 的 ν/δ 公式从结构上无法被人眼调优, 而 maze_quality 的加权几何聚合可以。**设计动机。**v2.1 起重新分配 (旧版 $M_b/M_s/M_j$ 各 0.10, M_c 0.40, M_{bnd} 0.30): 走廊感两个维度 M_b 与 M_j 各升到 0.20, M_s 微升到 0.15; M_c 0.40 $\rightarrow$ 0.30, M_{bnd} 0.30 $\rightarrow$ 0.15。 M_c 0.40 在去掉 /0.8 clip 后, 实际梯度从 1.0 区间被压回 [0.7, 1.0], 0.30 已经足够强; M_{bnd} 0.30 太高会让“完美边界墙” (trivially satisfiable) 拉分过度, 0.15 仍然显著但不主导。0.20 + 0.15 + 0.20 + 0.30 + 0.15 = 1.0。

视觉一致性修复。经验数据 (sweep_2026_07_09, 见 §5): 4 个 ES top 跑出来 $M_c \in [0.74, 0.98]$, 旧权重下几乎都被 clip 到 1.0; 新权重下区分度恢复: 视觉上明显更接近迷宫形态的 (b) chebyshev-1 ($M_c = 0.98$) 升到榜首, 视觉上走廊感较弱的 (a) manhattan-2 ($M_c = 0.74$) 调整到第三——“分数排名与视觉评判一致”的关键修复, 也是权重调优过程有效性的直接验证。

min 而非几何均值, 是与 Bellot F 最关键的区别: 单边 exploit (高 M_c 但低 M_t) 在几何均值下被宽松放过 ($\sqrt{0.9 \cdot 0.1} \approx 0.30$), 而 min 强制 $M_{\text{base}} \leq 0.1$, 拖累总分。这里 M_{base} 不是硬门 ($M_t > 0$ 时 $M_{\text{base}} = 0$ 不存在), 而是一种结构性 balance, 迫使 ES 同步提升两侧。

$M_{\text{wall_gate}}$ 的三角峰值 [0.40, 0.60] 与迷宫典型“道路占比 40%–60%”的密度相符 (6 个真迷宫生成器的均值 $M_{\text{wall}} = 0.487$ 落在峰值中点)。这一约束告诉 ES: 接近这个密度才有奖励, 不是必须落在一条线上。





Figure 2 maze_quality 计算流程。 8 个连续可微子度量 (左 5 拓扑 + 右 3 多样性) 分别做加权几何聚合得到 $M_{topology}$ (红) 与 $M_{diversity}$ (黄); 两侧 min-平衡后乘以 $[0.40, 0.60]$ 上的三角门控 M_{wall_gate} (棕, 峰值 1), 得到 final score $\in [0, 1]$ 。所有算子连续可微, ES 可学; min 强制 “topology 与 diversity 同步提升”。

4.5 15-pattern 对照基准


$maze_quality$ 的判别能力用 15 个测试图案做基准评估: 6 个真迷宫生成器 (DFS, Kruskal, Prim, Growing Tree, Sidewinder, Binary Tree) + 9 个几何反例 (Spiral, Fractal Tree, Horizontal Stripes, Random Noise 50%, Random Noise 30%, Checkerboard, Diagonal Stripes, Concentric Rings, Honeycomb)。所有图案按 31×31 网格存放于 `paper/data/_grids.json`, 分数从 `paper/data/sweep_summary.json::15pattern.per_pattern` 读取并由 `paper/data/_eval_15patterns.mjs` 用真实源码重算交叉验证 (15/15 数值精确匹配, 详见附录 B)。

图 3 给出 15 张图案的 $maze_quality$ 分数, 图 4 给出 Bellot 2021 F 分数作为对照基线。同一批 15 张图案在两图中的位置严格对应 (5x3 网格, 前 2 行 6 个 TRUE, 后 3 行 9 个 PSEUDO)。


15-pattern benchmark - maze_quality score (TRUE mean 0.711, PSEUDO mean 0.000, gap +0.711)




Binary Tree
TRUE
mq = 0.672




Growing Tree
TRUE
mq = 0.719




Kruskal
TRUE
mq = 0.737




Prim
TRUE
mq = 0.719




Recursive Backtrack (DFS)
TRUE
mq = 0.707




Sidewinder
TRUE
mq = 0.711




Checkerboard
PSEUDO
mq = 0.000




Concentric Rings
PSEUDO
mq = 0.000




Diagonal Stripes
PSEUDO
mq = 0.000



Fractal Tree
PSEUDO
mq = 0.000



Honeycomb
PSEUDO
mq = 0.000




Horizontal Stripes
PSEUDO
mq = 0.000



Random Noise 30%
PSEUDO
mq = 0.000



Random Noise 50%
PSEUDO
mq = 0.000



Spiral
PSEUDO
mq = 0.000

Figure 3 15-pattern maze_quality 分数。6 个真迷宫生成器全部落在 0.672–0.737, 均值 0.711; 9 个伪迷宫全部 0.000。间隔 +0.711, 误判 0/9 (阈值 0.5)。

15-pattern benchmark - Bellot F score (4/9 pseudo misclassified, boxed in vermilion)




Figure 4 15-pattern Bellot F 分数 (同一批 15 张图案)。真迷宫均值 $F = 100.88$, 伪迷宫均值 $F = 292.21$, 方向反转 (值越小越“像迷宫”), 间隔 -191.32 。9 个伪迷宫中有 4 个 (红框: Spiral $F = 11.85$, Horizontal Stripes / Concentric Rings / Honeycomb $F = 0$) 的 F 值低于真迷宫最低值 ($F = 15.33$, Recursive Backtrack), 即 Bellot F 把它们判为“比 DFS 更像迷宫”。

两图对比直观给出 *maze_quality* 的设计动机: 图 4 中 4 个红框图案都是规则几何形态 (条纹, 环, 蜂巢, 螺旋), 全部满足“少死端墙 + 长直径”的 Bellot F 奖励条件; 而 M_s 在 $L_{\max}/N > 0.5$ 时单调降至 0, M_j 在 r_j 远离 0.10 时呈高斯衰减, 二者在设计目标上显式拒收这类反例。

4.6 *maze_quality* 与 Bellot F 的方向反转

Bellot 2021 F 报告“真迷宫值小, 伪迷宫值大” [6], 与 *maze_quality* 的“真迷宫值大, 伪迷宫值小”方向相反。这个方向反转不是数值巧合, 而是公式定义决定的:

- $F = \nu/\delta$, 其中 ν 是“非显著墙” (死端邻接类) 的计数, δ 是 twistiness proxy。真迷宫 δ 大 (走廊长程连通) 而 ν 相对小, 所以 F 小; 伪迷宫 δ 小 (短路径或几何重复) 而 ν 相对大, 所以 F 大。
- *maze_quality* 是几何度量, 越高越像迷宫; F 是“像迷宫程度 / twistiness”的比值, 越低越像迷宫。

4/9 误判的几何机制: Spiral $F = 11.85$ 低于 DFS $F = 15.33$, 因为 Spiral 的 $\nu = 10$ (几乎所有死端墙都相邻) 比 DFS 的 $\nu = 114$ 小, 分子更小导致 F 更小。3 个 $F = 0$ 的图案 (Horizontal Stripes / Concentric Rings / Honeycomb) 因 $\nu = 0$ 导致 $F = 0$, 被 Bellot F 判为“最像迷宫”。

maze_quality 的 M_s 显式惩罚单路径占比过高 ($L_{\max}/N > 0.5$ 时单调降至 0), M_j 显式奖励分叉比例 ≈ 0.10 , 二者共同拒收 Spiral — 这是设计目标驱动的结果, 不是巧合。

5 实验评估

5.1 实验设置

所有演化实验均在浏览器内通过 WebGPU compute shader 加速的 $(\mu + \lambda)$ 进化策略 (ES) 完成。两个 sweep 的参数对比如表 1。

Table 1 两个 sweep 的 ES 演化参数对比

参数	小范围 sweep	大范围 sweep
种群规模 (pop)	200	500
演化代数 (gens)	500	2000
网格尺寸	40×60	500×2000
mask 模板数	8	1 (manhattan-2)
maxFam 上限	1 / 2 / 4 / 8	8
随机种子数	4	5 (s444, s1111, s2222, s3333, s5555)
总 run 数	128	5
成功 run	122	5

小范围 sweep (40×60) 完成 $8 \times 4 \times 4 = 128$ 次全交叉 run, 6 次因预算超时被剔除, 实际 122 OK; 大范围 sweep (500×2000) 完成 5/5 run, 网格面积约高 170 倍, 用于验证 manhattan-2 / maxFam=8 在大网格上的 scale-up 能力。

5.2 大范围 sweep 5 个随机种子结果




Figure 5 大范围 sweep (500×2000) 5 个随机种子最优分。5 个 run 全部完成 (gen=2000 达代上限), 均使用 manhattan-2 / maxFam=8 配置。红色虚线为小范围 sweep 峰值 0.8233 (manhattan-2 / maxFam=8 / seed 444) 的对照基线, 棕色点线为 5-run 均值 0.8020。s444 = 0.8195, s1111 = 0.8138, s5555 = 0.8098, s3333 = 0.7909, s2222 = 0.7758。

5 个 run 的最优分按降序排列: s444 = 0.8195, s1111 = 0.8138, s5555 = 0.8098, s3333 = 0.7909, s2222 = 0.7758, 均值 0.8020, 中位数 (s3333) 0.7909, 标准差 0.018。s444 与 s1111 落在“好的吸引域”(高于均值), s3333 与 s2222 落在“较差的吸引域”(低于均值), s5555 接近均值。

s444 = 0.8195 与小范围 sweep 峰值 0.8233 (同配置) 差 0.0037, 表明 manhattan-2 / maxFam=8 在 40×60 网格上已接近该配置的理论上限 (详见 §6.3)。s3333 与 s2222 显著低于 s444 / s1111, 说明同一配置下不同随机种子会落到不同的吸引域, 5-run 的标准差 0.018 给出“吸引域方差”的一个下界。

5.3 小范围 sweep 全部 122 次 run




Figure 6 小范围 sweep (200 × 500) 122 个 OK run 的 (mask, maxFam) 汇总。每格数值 = 该 (mask, maxFam) 上 4 个随机种子中的最高 *maze_quality*。红框 = 全场峰值 (manhattan-2 / maxFam=8, 0.8233)。8 个 mask 中 6 个健康 (0.74-0.78), 2 个异常: chebyshev-4 (0.157) 与 manhattan-1 (0.421), 机制完全不同 (见 §6.2)。n=122/128, 缺失的 6 个为 TIMEOUT。

按 mask 分组均值见表 2。8 个 mask 中 6 个健康 (chebyshev-1/2/3, manhattan-2/3/4 均值 ≥ 0.74), 2 个异常 (chebyshev-4 = 0.157, manhattan-1 = 0.421)。

Table 2 小范围 sweep 按 mask 模板的均值 / 最小 / 最大 (n=122)

mask	n	mean	min	max	状态
chebyshev-1	16	0.7726	0.7279	0.8095	healthy
chebyshev-2	16	0.7438	0.5909	0.8080	healthy (高方差)
chebyshev-3	16	0.7764	0.7446	0.7955	healthy
chebyshev-4	16	0.1573	0.1038	0.4244	低均值 (预算受限)
manhattan-1	10	0.4205	0.3998	0.4360	低均值 (表征受限)
manhattan-2	16	0.7777	0.7429	0.8233	healthy (最优)
manhattan-3	16	0.7714	0.7014	0.7932	healthy
manhattan-4	16	0.7517	0.4452	0.7999	healthy (高方差)

按 maxFam 分组: mf=1 均值 0.6984 (n=28), mf=2 均值 0.6688 (n=30), mf=4 均值 0.6382 (n=32), mf=8 均值 0.6306 (n=32)。均值随 maxFam 单调下降, 但峰值从 mf=1 的 0.7999 升至 mf=8 的 0.8233 — “均值降, 峰值升” 现象。

5.4 ES 跑出来的高分迷宫与重点特征分析

把上述 122 个 OK run 按 best 排序后, 6 个最具代表性的 ckpt 实际渲染 (300 步 CA, 40×60 网格, 来自浏览器训练时直接捕获的 panel grid) 如图 7。前 4 个是“跑出来的高分迷宫”(Top 1-3 + Top 5), 后 2 个是“重点特征失败模式”(Fail 1, Fail 2), 都用各自的 (mask, maxFam, seed) 配置训练出来, 渲染时取“withInvert”优化中分数更高的那一个 (浏览器训练时同时跑原版与反版, 取 max)。




Figure 7 ES 跑出来的高分迷宫 (Top 1-3 + Top 5) 与重点特征失败模式 (Fail 1, Fail 2)。6 个 ckpt 在 300 步 CA 之后的 40×60 终态。Top 1-3 的 maze_quality 均 ≥ 0.81 , 4 个真迷宫共享 path-ratio $\approx 0.48-0.49$ (约半数通路半数墙), 即 maze attractor; Top 5 (manhattan-4 / mf=1) 是“均值降 / 峰值升”现象的体现: mf=1 的全局均值最低 (0.6984), 但 0.7999 的全场最高分就出现在 mf=1 上。Fail 1 (chebyshev-4 / mf=1) path-ratio 仅 0.31, 是“过稀疏”失败 (2^{103} 搜索空间 vs 10^5 预算, 大量“无梯度平台”让 CA 烧光活细胞); Fail 2 (manhattan-1 / mf=2) path-ratio 0.50 但“过连通”: 4 邻域只要求避让直接相邻的墙, 加上 mf=2 把墙推到最薄, CA 演化出几乎完全开放的网格, 缺乏走廊结构。

- **Top 1-3 共享 attractor。** 4 个 mf=8 真迷宫彼此视觉上很相似, 都收敛到“ 40×60 网格最大连通迷宫”配置, path-ratio $\approx 0.48-0.49$ (约半数通路半数墙)。这说明 ES 已经在多个 (mask, seed) 配置下稳定找到同一吸引子, 进一步扩大网格 (大范围 sweep) 不会带来质的提升 (§6.3)。
- **Top 5 是“mf=1 偶发突破”。** manhattan-4 / mf=1 / s111 的 0.7999 是“均值降 / 峰值升”现象的具体体现: mf=1 全局均值 0.6984 ($n=28$), 但 0.7999 的最高分恰好落在 mf=1 类别中, 而 mf=8 的均值 (0.6306, $n=32$) 反而低于 mf=1。多族容量升高拖累均值, 但保留了“偶发突破”的尾部峰值。
- **Fail 1 是预算受限失败。** chebyshev-4 / mf=1 / s111 path-ratio 仅 0.31, 大量“黑色虚空”, 几乎看不到一条贯通主路径。这是 2^{103} 搜索空间 vs 10^5 预算的不对称: ES 在大量“无梯度平台”上原地踏步, CA 倾向于把活细胞烧光。增加预算 (pop $\times$ gens) 或降低 mask 维度能缓解, 但增加邻域半径不行 (因为根因是搜索空间, 不是表征)。
- **Fail 2 是表征受限失败。** manhattan-1 / mf=2 / s444 path-ratio 0.50 但“过连通”: 4 邻域只要求避让直接相邻的墙, mf=2 又把墙推到最薄, CA 演化出几乎完全开放的网格, 缺乏走廊结构。这个失败不能靠加预算解决, 必须把 mask 换成 manhattan-2 / manhattan-3 / chebyshev-1 等更高邻域半径。

5.5 小范围 vs 大范围对比

小范围 sweep 122 个 OK run 提供完整的 (mask, maxFam) 消融数据 (§5.3); 大范围 sweep 的 5/5 run 提供“同配置, 大网格”的 scale-up 证据 (§5.2)。两者对比要点:

- **配置覆盖**. 大范围只测了 manhattan-2 / maxFam=8 一种配置, 小范围测了 $8 \times 4 = 32$ 种 (mask, maxFam) 组合。
- **网格面积**. 大范围 $500 \times 2000 = 10^6$ 像素, 小范围 $40 \times 60 = 2400$ 像素, 大范围约高 417 倍。
- **峰值差**. 大范围 5-run 最高 0.8195, 小范围单点最高 0.8233, 差 0.0037。
- **解释**. manhattan-2 / maxFam=8 在 40×60 网格上已接近该配置的理论上限 (见 §6.3); 大范围 sweep 用于验证“峰值不显著下降”而非“寻找新高分”。

5.6 数据来源声明

所有数值以 append-only ndjson 训练日志为唯一来源, 不以 ckpt 文件为数值依据:

- 小范围 sweep ndjson: sweep_2026_07_04/results.ndjson (122 OK + 6 TIMEOUT)。这是 v0 (旧版 M_c clip, 旧版 5 权重) 的实验数据, 本节 §5.3 表 2 与图 6 数字均为 v0。
- 大范围 sweep ndjson: sweep_2026_07_08/big/results.ndjson (5 OK), 同为 v0 数据。
- **v5+v6 重测 sweep (进行中)**: sweep_2026_07_09/results.ndjson (目标 128 OK, 8 mask $\times$ 4 maxFam $\times$ 4 新种子 {114, 514, 1919, 810}, 2026-07-08 启动, 预计 14-15 h 完成)。该 sweep 跑出 v2.1 权重下的新数据, 与 v0 数据**不可直接比较** (新权重下分数绝对值偏低, 但相对排名变化才有意义)。完成后将更新 §5 的所有数字并发布 v2.1.1。
- 15-pattern 对照基准: 图案 paper/data/_grids.json (15 张 31×31 网格, 0/1 flat), 分数 paper/data/sweep_summary。复核脚本 paper/data/_eval_15patterns.mjs (15/15 数值精确匹配, 详见附录 B)。15-pattern 与 v5+v6 权重无关, 因为它们走 src/metrics/maze_quality.js 同一套源码 (重算一次还是同一数字)。

6 讨论

6.1 Family Cap 的“均值降 / 峰值升” Pareto 前沿

小范围 sweep 的族数上限实验揭示了一个重要规律: maxFam=1 $\rightarrow$ 2 $\rightarrow$ 4 $\rightarrow$ 8 时, 均值从 0.6984 单调下降至 0.6306, 但全局峰值却由 maxFam=1 的 0.7999 升至 maxFam=8 的 0.8233。这一“均值降 / 峰值升”的双目标特征, 与神经架构搜索 (NAS) 中的 Pareto 前沿现象一致: 更大的搜索空间提升了“突破单族天花板”的概率, 但不保证均值同步提升 [10, 11]。

从激活族数分布看, maxFam=8 运行中 81.8% 最终只保留 active $\leq$ 3 的族, 且全场最高分 0.8233 本身仅 active=2 (即 6/8 族被关闭)。这说明 maxFam=k 的实际作用是把 ES 初始化为 k 组独立的 1 族起点, 而非真正同时激活 k 族进行联合优化。当某个种子恰好落在“对的多族组合”邻域时, 多族可突破单族天花板; maxFam=8 提供的是“获得高价值峰值突破点的能力”, 而非“更高的均值稳健性”。

方法论价值。这一发现提示: 在 Pareto 前沿上做“均值-峰值双目标优化”, 显式区分“均值稳健”与“峰值惊人”两类配置, 比折叠到单一标量 maze_quality 上更合理 — 单标量无法同时表达“稳定可复现的局部最优”与“偶发的全局突破”两个目标。

6.2 两类瓶颈机制的清晰分离

§5.3 的消融数据揭示了两种性质截然不同的瓶颈, 这一清晰分类是本文的核心方法论贡献之一:

(1) **预算受限型 (chebyshev-4, 均值 0.157)**. chebyshev-4 邻域严格包含 chebyshev-2, 理论上 chebyshev-2 的最优解是其搜索空间的子集, 但实际 chebyshev-4 得分低 0.59 分。原因不在“无解”, 而在 chebyshev-4 的 80 位 cells mask 占据 2^{80} 种取值, 叠加 birth (2^9) + survive (2^9) + priority (2^4) 后, 单族总搜索空间 $= 2^{103} = 2^{80} \times 2^{23}$; 40×60 的 10^5 预算对其 2^{103} 子空间过于稀疏, ES 在大量“无梯度平台”上原地踏步, 从未接近 chebyshev-2 风格的局部最优。这一类瓶颈来自预算约束, 是高维搜索的固有挑战, 但其**解决方案明确**: 增加预算或降低 mask 维度即可缓解, 是工程上可解的问题。

(2) **表征受限型 (manhattan-1, 均值 0.421)**. manhattan-1 是 4 邻域 (von Neumann), 每个元胞每步最多感知 4 个邻居; 而走廊结构 (1-cell 宽, 长程连通) 需要“沿走廊方向存活 + 左右墙存活”的二阶条件, 4 邻域只能“凑巧”出现, 无法稳定涌现。与 manhattan-2 (8 邻域, 直接编码对角线存活条件) 差 0.358 分 — 直接编码对角线存活条件的能力鸿沟。这一类瓶颈来自模板本身的信息瓶颈, 必须换模板才能解决, 增加预算无法缓解。

方法论价值。chebyshev-4 和 manhattan-1 都得分低, 但分属不同类别。前者是搜索空间问题 (可增加预算或降低 mask 维度解决), 后者是表征能力问题 (必须换模板, 增加邻域半径或跳接结构才能解决)。将二

者混为一谈会导致错误的调参方向：在 manhattan-1 上加 10 倍预算不会让均值从 0.421 升到 0.75，必须把模板换成 manhattan-2 才行。这一清晰的二分类为后续精准调优提供了路线图——“遇到低分时，先判断是预算问题还是表征问题，再选择对应的解决路径”。

6.3 大范围 sweep 的含义：40 × 60 网格上的性能上界

大范围 sweep 5/5 全部完成，最高 0.8195 与小范围 sweep 最高 0.8233 几乎持平——这一结果有重要意义，揭示了 manhattan-2 / maxFam=8 配置的**配置鲁棒性 (configuration robustness)**。

该配置在 40 × 60 网格上的性能上界已被识别。将网格面积扩大 170 倍后，峰值并未显著提升，表明 manhattan-2 / maxFam=8 在 40 × 60 网格上已达到该配置的性能上界。5 个随机种子中，s444 (0.8195) 与 s1111 (0.8138) 落在“好的吸引域”（高于均值），s5555 (0.8098) 接近均值，s3333 (0.7909) 与 s2222 (0.7758) 落在“较差的吸引域”（低于均值）。

5-run 均值 0.8020 与小范围 sweep 峰值 0.8233 差 0.021，在搜索空间的方差范围内。top-2 均值 (s444 + s1111) 0.8166 与 0.8233 仅差 0.007，说明“同配置在两个尺度上达到的水平”接近。多吸引域结构本身也是该配置的重要发现：它提示，寻找全局最优的策略应聚焦于“挑选好的种子”，而非“改进搜索算法本身”。

为什么 2^{1648} 的搜索空间在 40 × 60 上已被充分采样。manhattan-2 的 cells mask 是 80 位，单族 2^{103} 搜索空间；maxFam=8 时全染色体 2^{824} 实际有效组合 (8 active 族 × 103 bits)。 10^5 预算相当于 2^{17} ，在 2^{103} 上是 2^{-86} 稀疏度；ES 用 $200 \times 500 = 10^5$ 步能稳定找到 0.80 附近的局部最优，5 个随机种子的标准差 0.018 给出“吸引域方差”的一个下界，大范围 sweep 5 个种子中 s444 与 s1111 命中，s3333 与 s2222 未命中，比例与 1/5 接近。

下一步。若要超过 0.8233，三个方向都有明确预期收益：

- **换 mask**. manhattan-3 或 chebyshev-3 的均值与 manhattan-2 接近 (≥ 0.77)，不同的邻域拓扑可能命中更好的吸引域；
- **增大预算**. pop × gens 从 10^5 升到 10^6 (即大范围 sweep 的预算水平)， 2^{-86} 的稀疏度有量级改善；
- **两者都做**. “换 mask + 大范围”的联合空间是后续工作的开放方向，预期收益最大。

6.4 未来工作

本文已建立 FamilyMask 多族 CA 编码与 *maze_quality* 八维几何度量的基础框架，验证了 15-pattern 基准下的清晰判别力与两个尺度 sweep 下的性能上界，后续工作可从三个方向继续推进：

- **权重自动调优**. 当前 5 个拓扑子度量权重 (0.20, 0.15, 0.20, 0.30, 0.15) 与多样性侧 (0.25, 0.25, 0.50) 是经过多轮人眼评判迭代调优的结果 (§4.2)，在视觉一致性上表现良好；进一步可通过元学习或贝叶斯优化自动调参，系统探索权重空间，有望找到比当前人眼调优权重更优的局部极值。
- **15-pattern 扩展**. 当前基准覆盖了 6 个真迷宫生成器 + 9 个常见几何反例，已能清晰区分 mode collapse (9/9 伪迷宫 0 分, 6/6 真迷宫 0.711 均值)；可加入分形迷宫、Hilbert 曲线等更复杂的拓扑反例，进一步验证度量的判别力上限。
- **服务器端 scale-up**. ES 种群规模 200×500 已是浏览器端 WebGPU dispatch 的合理上限，这一预算下 manhattan-2 / maxFam=8 已达到性能上界；若部署到服务器端 GPU (pop = 500, gens = 2000)，可探索“换 mask (chebyshev-3, manhattan-3) + 大预算”的联合空间，把当前 0.8233 的峰值上推。

FamilyMask 当前用“按优先级顺序遍历”执行 CA 步，等价于“首个触发的族即决定下一态”；这种“早退”语义在结构上具有可扩展性，后续可探索“多族投票”、“多族加权和”等推广形式，把单族 B/S 字符串之外的规则空间纳入搜索。

7 结论

本文给出 FamilyMask 多族 CA 编码与 *maze_quality* 八维几何质量度量两条主线，用 15-pattern 对照基准和两个尺度的演化扫描验证了两者的协同效果。

FamilyMask 编码空间. FamilyMask 把经典 B/S 型规则推广为最多 16 族并行、按优先级仲裁的离散结构，搜索空间从 2^{18} 跃升至 2^{1648} ($16 \text{ slot} \times 103 \text{ bits/slot}$, $103 = 1 \text{ active} + 80 \text{ cells} + 9 \text{ birth} + 9 \text{ survive} + 4 \text{ priority}$)。单族搜索空间 2^{103} ，全 16 族染色体 2^{1648} 。当某个随机种子恰好落在“对的多族组合”邻域时，多族可突破单族天花板——maxFam=8 的峰值 0.8233 高于 maxFam=1 的 0.7999 即此机制。

maze_quality 度量. *maze_quality* 用 8 维连续可微子度量 + 两层 min-聚合 + 墙比软门控，在 15-pattern 基准的 9 个伪迷宫反例上全部得分 0，在 6 个真迷宫生成器上均值 0.711，间隔 +0.711，误判 0/9。对同一数据集 Bellot 2021 $F = \nu/\delta$ 真伪间隔 -191.3，方向反转，误判 4/9 (Spiral $F=11.85$ 与 3 个 $F=0$ 图案排名低于真迷宫最低值 $F=15.33$)。 *maze_quality* 的 M_s 显式惩罚单路径占比过高， M_j 显式奖励分叉比例 ≈ 0.10 ，二者共同拒收 Spiral。

两个尺度的演化扫描. 小范围 sweep 122 次 (200×500) 与大范围 sweep 5/5 (500×2000) 协同揭示: manhattan-2 / maxFam=8 配置在 40×60 上已达到性能上界 (小范围峰值 0.8233, 大范围峰值 0.8195, 差 0.0037), 在 170 倍网格面积上仍保持 99.5% 的峰值水平 — 这一**配置鲁棒性**是该工作的重要发现, 表明“同配置 + 不同尺度 = 接近的峰值水平”, 也为“大规模部署前无需更大网格验证”提供了实证支持。族数上限实验的“均值降 / 峰值升”双目标特征, 揭示了“更大的族容量带来更高的峰值突破概率”的 Pareto 前沿: maxFam=8 的均值 (0.6306) 低于 maxFam=1 (0.6984), 但拥有全场最高 0.8233, 这是“多族容量 = 峰值突破能力”的直接体现, 也是后续“换 mask + 大预算”联合优化的明确方向。

两类瓶颈机制. (1) 预算受限型 (chebyshev-4, 0.157): 2^{103} 搜索空间 vs 10^5 预算, 高维无梯度平台, 增加预算或降维即可缓解; (2) 表征受限型 (manhattan-1, 0.421): 4 邻域无法稳定涌现走廊结构, 必须换模板。两者分属不同类别, 混淆会误导调参方向 — 这一清晰的二分类本身是本文的方法论贡献, 让“遇到低分时先判断瓶颈类型, 再选对应解决路径”成为可操作的工程流程。

数据可用性. 所有代码 (maze-web 浏览器端 ES + WebGPU compute shader + 15-pattern 测试集), 训练日志 (sweep ndjson, 小范围 122 OK + 6 TIMEOUT + 大范围 5/5), 截图 (figures/v2/) 均随论文开源。15-pattern 对照基准的图案 (paper/data/_grids.json) 与分数 (paper/data/sweep_summary.json::15pattern.per_pattern) 完全独立可复现, 复核脚本 paper/data/_eval_15patterns.mjs 用真实源码 (mazeQuality / bellotF) 重算, 15/15 数值精确匹配 (详见附录 B)。

A 完整公式

A.1 FamilyMask 染色体判定 (完整形式)

设第 i 族 $\mathcal{F}_i = (\text{cells}_i, \text{birth}_i, \text{survive}_i, \text{priority}_i)$, 全局 active 集合 $A \subseteq \{0, \dots, 15\}$ 。对元胞 (x, y) 在时刻 t 的更新:

$$n_i(x, y) = \sum_{(\Delta x, \Delta y) \in \text{cells}_i} \mathbb{I}[G_t(x + \Delta x, y + \Delta y) > 0]$$

$$i^* = \min \{ i \in A : (G_t(x, y) = 0 \wedge n_i(x, y) \in \text{birth}_i) \vee (G_t(x, y) > 0 \wedge n_i(x, y) \in \text{survive}_i) \}$$

$$G_{t+1}(x, y) = \begin{cases} 1, & G_t(x, y) = 0 \wedge n_{i^*}(x, y) \in \text{birth}_{i^*} \\ 1, & G_t(x, y) > 0 \wedge n_{i^*}(x, y) \in \text{survive}_{i^*} \\ 0, & \text{otherwise} \end{cases}$$

若 i^* 不存在 (即没有 active 族匹配), 元胞 (x, y) 退化为 `defaultState = 0`。

A.2 maze_quality 子度量推导 (展开形式)

记 $V = \{v : G(v) = 1\}$, $|V| = N$, $\deg(v) = \#\{u \sim v : G(u) > 0\}$, $L_{\max}$ 为 4 邻域下的最长简单路径, $C_{\max}$ 为最大 4 连通分量, a_{outer} 为四条边上的活格子总数 (4 角去重), $H(\cdot)$ 为 Shannon 熵 (自然对数除

以 $\ln 2$ 给出比特单位)。

$$\begin{aligned}
M_b &= \frac{\text{clip}(\#\{v \in V : \deg(v) = 2\}/N - 0.4, 0, 0.5)}{0.5} \\
M_s &= \begin{cases} \min\left(1, \frac{L_{\max}/N}{0.3}\right), & \frac{L_{\max}}{N} \leq 0.5 \\ \max\left(0, 1 - \frac{L_{\max}/N - 0.5}{0.5}\right), & \frac{L_{\max}}{N} > 0.5 \end{cases} \\
M_j &= \exp\left[-\left(\frac{\#\{v : \deg(v) \geq 3\}/N - 0.10}{0.10}\right)^2\right] \\
M_c &= \text{clip}\left(\frac{|C_{\max}|}{0.8N}, 0, 1\right) \\
M_{\text{bnd}} &= \text{clip}\left(1 - \frac{a_{\text{outer}} - 4}{76}, 0, 1\right) \\
M_p &= \frac{H(2 \times 2 \text{ patch})}{\log_2 16} \\
M_a &= \begin{cases} 0.5, & \max \text{match}(G, G^{\text{flip}}) < 0.55 \\ 1.0, & 0.55 \leq \max \text{match} < 0.85 \\ 1 - \frac{\max \text{match} - 0.85}{0.15}, & \max \text{match} \geq 0.85 \end{cases} \\
M_t &= \frac{H(2 \times 2 \text{ pair})}{\log_2 256} \\
M_{\text{wall_gate}} &= \begin{cases} 0, & M_{\text{wall}} \in \{0, 1\} \\ M_{\text{wall}}/0.4, & M_{\text{wall}} \in [0, 0.4] \\ 1.0, & M_{\text{wall}} \in [0.4, 0.6] \\ (1 - M_{\text{wall}})/0.4, & M_{\text{wall}} \in [0.6, 1] \end{cases}
\end{aligned}$$

其中 $M_{\text{wall}} = \#\{v : G(v) = 0\}/(WH)$ 为墙比。代码实现见 `src/metrics/maze_quality.js`。

A.3 Bellot 2021 $F = \nu/\delta$

Bellot 2021 提出 $F(M) = \nu(M)/\delta(M)$ (Bellot 2021 §3.4), 本文对照基线使用 `src/gpu/bellot_metrics.js::bellotF` 真实实现, 其中 ν = 非显著墙计数 (死端邻接类), δ = twistiness proxy (diameter / diagonal)。数值方向: 真迷宫 F 小, 伪迷宫 F 大 (与 `maze_quality` 相反, 详见 §4.5)。

B 数据可用性

所有产物在 GitHub 与本地开源:

- **项目源码:** `E:/doro/maze-web/`
`node index.html` 启动 (默认 `python -m http.server 8087` 提供静态托管)。
- **小范围 sweep ndjson:** `sweep_2026_07_04/results.ndjson`
 含 122 OK + 6 TIMEOUT, 每行含 `mask / maxFam / seed / best / wall_sec / status`。
- **大范围 sweep ndjson:** `sweep_2026_07_08_big/results.ndjson`
 含 5/5 OK, `manhattan-2 / maxFam=8 × {s444, s1111, s2222, s3333, s5555}`。
- **15-pattern 图案数据:** `paper/data/_grids.json`
 15 张 31×31 网格, 0/1 flat 数组, 总 $15 \times 961 = 14415$ 个元素。
- **15-pattern 分数:** `paper/data/sweep_summary.json::15pattern.per_pattern`
 每个 pattern 含 `name, type, mq, wall_ratio, nu_count, twistiness, bellotF`。
- **15-pattern 复核脚本:** `paper/data/_eval_15patterns.mjs`
 用 `src/metrics/maze_quality.js::mazeQuality` 与 `src/gpu/bellot_metrics.js::bellotF` 真实源码重算 15 个 pattern, 与 `per_pattern` 中缓存值对比。复核结果: 15/15 mq 精确匹配, 15/15 Bellot F 精确匹配 (容差 $\text{mq} \leq 0.005, F \leq 0.05$)。复核输出保存于 `paper/data/_15pat_recompute.json`。

- 示意图生成脚本: `tools/regen_fig_15pat_grids.py`, `tools/regen_fig_sweep_heatmaps.py`。

C 硬件与软件环境

- **Host:** Windows 11 (x64), `python=3.13.0`, `uv` 包管理。
- **Browser:** Chromium 114+ (WebGPU compute shader), 实测 Edge 119.0.2151.72。
- **CA/GPU kernel:** WGSL via `src/gpu/*.js`, dispatch 维度 (`ruleCount × seedCount, cellCount`)。
- **小范围 sweep:** `pop=200`, `gens=500`, 40×60 网格, 300 步 CA; ~ 12.5 小时 128 次 (122 OK + 6 TIMEOUT), 单 run ~ 4 分钟。
- **大范围 sweep:** `pop=500`, `gens=2000`, 500×2000 网格, 300 步 CA; ~ 4.2 小时 5/5 run, 单 run ~ 50 分钟。
- **Paper tooling:** `xelatex` (TeX Live 2024), `matplotlib` 3.8 (单文件 `.png` 输出), Python 脚本位于 `tools/`。

References

- [1] Conway, J. (1970). *The Game of Life*. Scientific American, 223(4), 4–7.
- [2] Wolfram, S. (2002). *A New Kind of Science*. Wolfram Media, Champaign IL.
- [3] Mitchell, M., Hraber, P., & Crutchfield, J. (1993). Revisiting the Edge of Chaos. *Complex Systems*, 7, 89–130.
- [4] Mordvintsev, A., Randazzo, E., Niklasson, E., & Levin, M. (2020). Growing Neural Cellular Automata. *Distill*, 5(8), e24.
- [5] Palm, R., et al. (2022). Variational Neural Cellular Automata. *ICLR 2022*.
- [6] Bellot, V., Cautrès, M., Favreau, J.-M., Gonzalez-Thauvin, M., Lafourcade, P., Le Cornec, K., Mosnier, B., & Rivière-Wekstein, S. (2021). How to generate perfect mazes? *Information Sciences*, 572, 444–459. doi:10.1016/j.ins.2021.03.022
- [7] Pech, J. (2002). Perfect Maze Generation. Master’s thesis, Charles University Prague.
- [8] Rejbrand, A. (2017). Cellular automaton maze generation. *Andreas Rejbrand’s Website*, March 5, 2017. URL
- [9] McClendon, M. S. (2001). The complexity and difficulty of a maze. In *Proceedings of Bridges 2001: Mathematical Connections in Art, Music, and Science*, Winfield, Kansas, July 27–29, 2001, pp. 213–222.
- [10] Liu, H., Simonyan, K., & Yang, Y. (2018). DARTS: Differentiable Architecture Search. *ICLR 2019*.
- [11] Real, E., Aggarwal, A., Huang, Y., & Le, Q. (2019). Regularized Evolution for Image Classifier Architecture Search. *AAAI 2019*.
- [12] W3C / GPU for the Web Working Group (2023). WebGPU compute shaders specification, W3C TR.
- [13] Skiena, S. (2024). Codeforces with WebGPU. *Codeforces Blog*, 2024.
- [14] Margolus, N. (1984). Physics-like model of computation. *Physica D*, 10(1-2), 81–95.